# Рекуррентные нейронные сети (RNN)
# Механизм внимания
# Архитектура трансформера

# Содержание

- **Закодировали, раскодировали**
- «Т» значит «Трансформер»

# Рассмотрим задачу машинного перевода

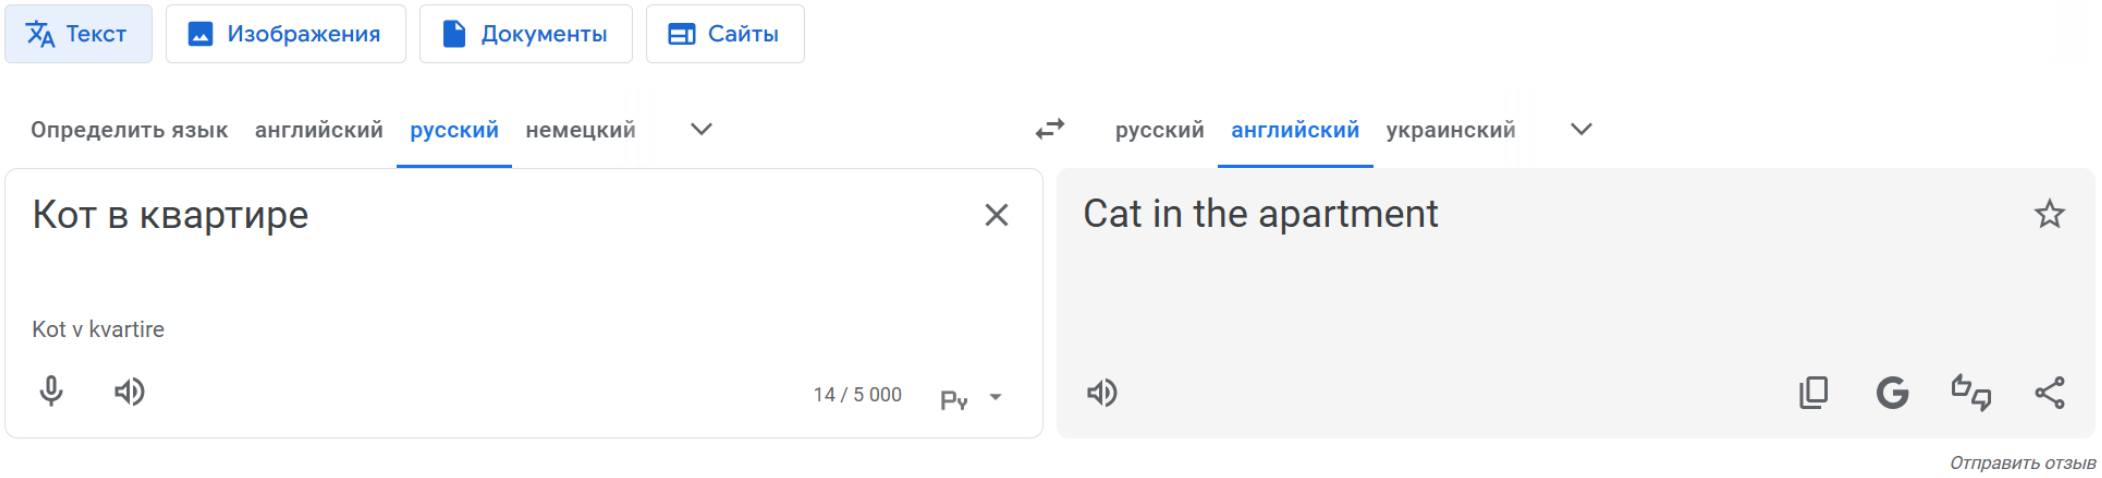

Рассмотрим задачу машинного перевода

Кот в квартире →

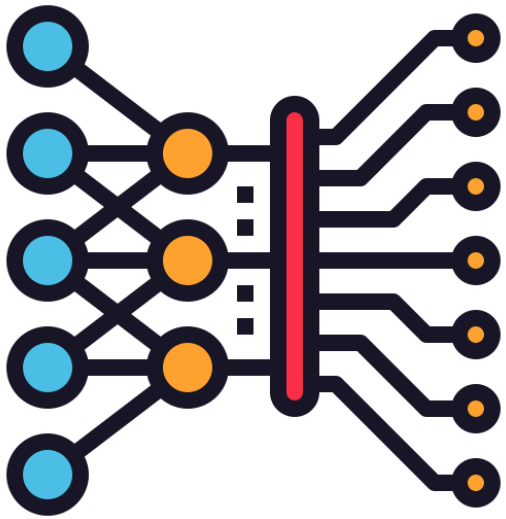

Рассмотрим задачу машинного перевода

Кот в квартире →

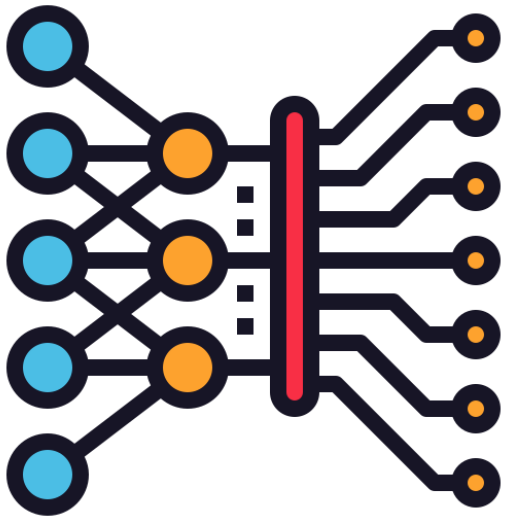

→

*Наша генерация*

*Известный перевод*

Cat in the apartment

Рассмотрим задачу машинного перевода

Кот в квартире →

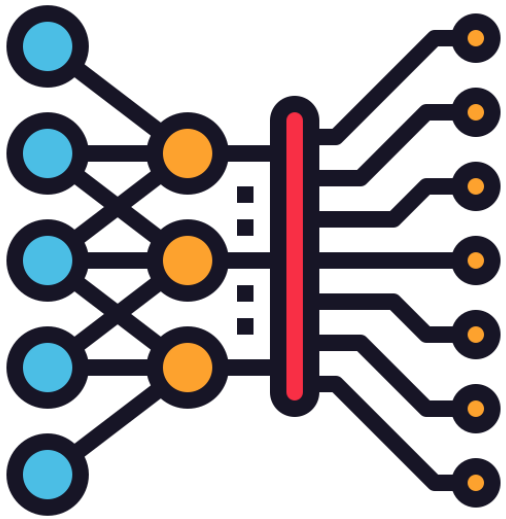

→ *Наша генерация*

Dog on the street

VS

*Известный перевод*

Cat in the apartment

Рассмотрим задачу машинного перевода

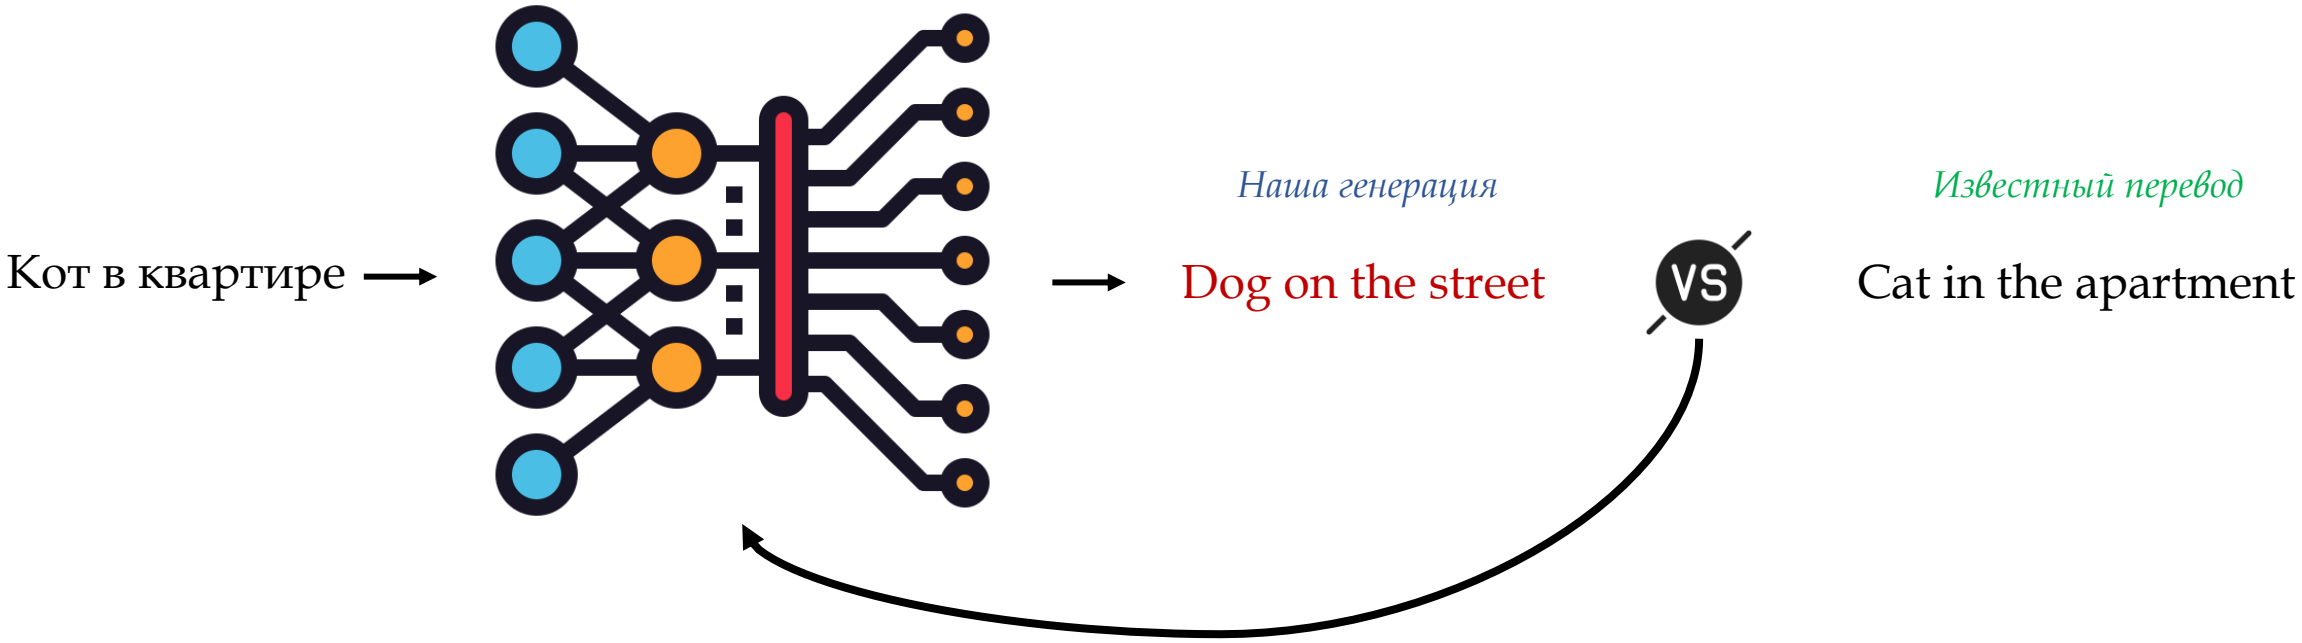

Рассмотрим задачу машинного перевода

Кот в квартире →

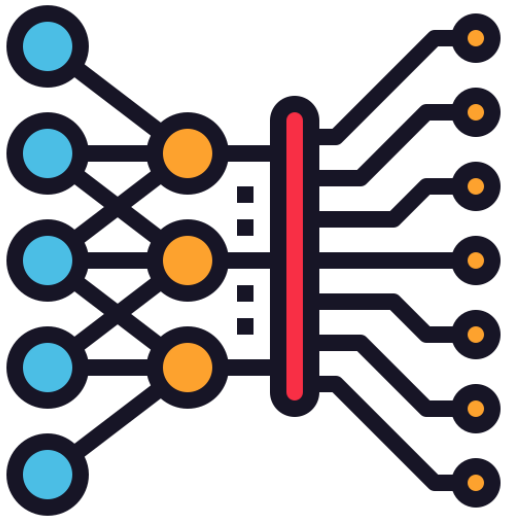

→ *Наша генерация*

Cat in the apartment

VS

*Известный перевод*

Cat in the apartment

Рассмотрим задачу машинного перевода подробнее

↑

Кот в квартире

Разобьем входной текст на токены

↑

Кот, в, квартире

↑

Кот в квартире

Каждому токену сопоставляем соответствующий ему эмбеддинг

(1,0,0), (0,1,0), (0,0,1)

↑

Кот, в, квартире

↑

Кот в квартире

Каждому токену сопоставляем соответствующий ему эмбеддинг

(1,0,0), (0,1,0), (0,0,1)

↑

Кот, в, квартире

↑

Кот в квартире

Каждому токену сопоставляем соответствующий ему эмбеддинг

(1,0,0), (0,1,0), (0,0,1)

↑

Кот, в, квартире

↑

Кот в квартире

Каждому токену сопоставляем соответствующий ему эмбеддинг

(1,0,0), (0,1,0), (0,0,1)

↑

Кот, в, квартире

↑

Кот в квартире

Закодируем смысл входного текста в векторе, представляющем его семантику

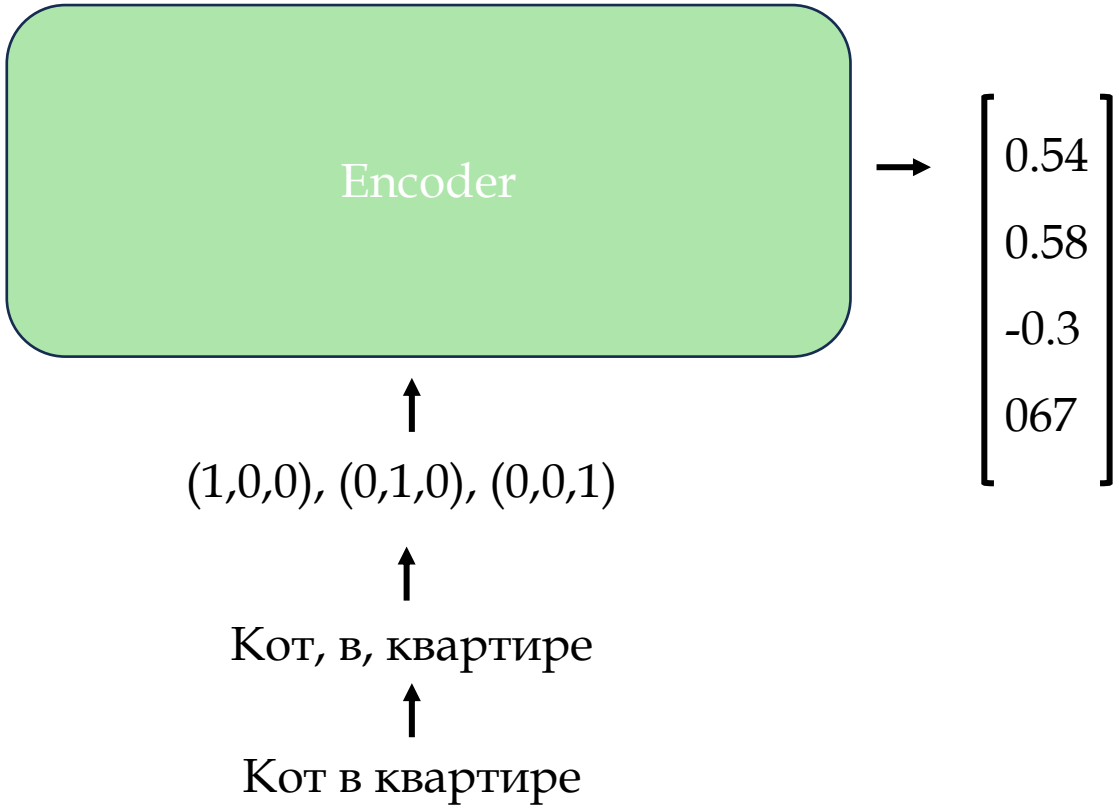

Эмбеддинг входного текста вместе со специальным токеном начала генерации подадим в декодировщик

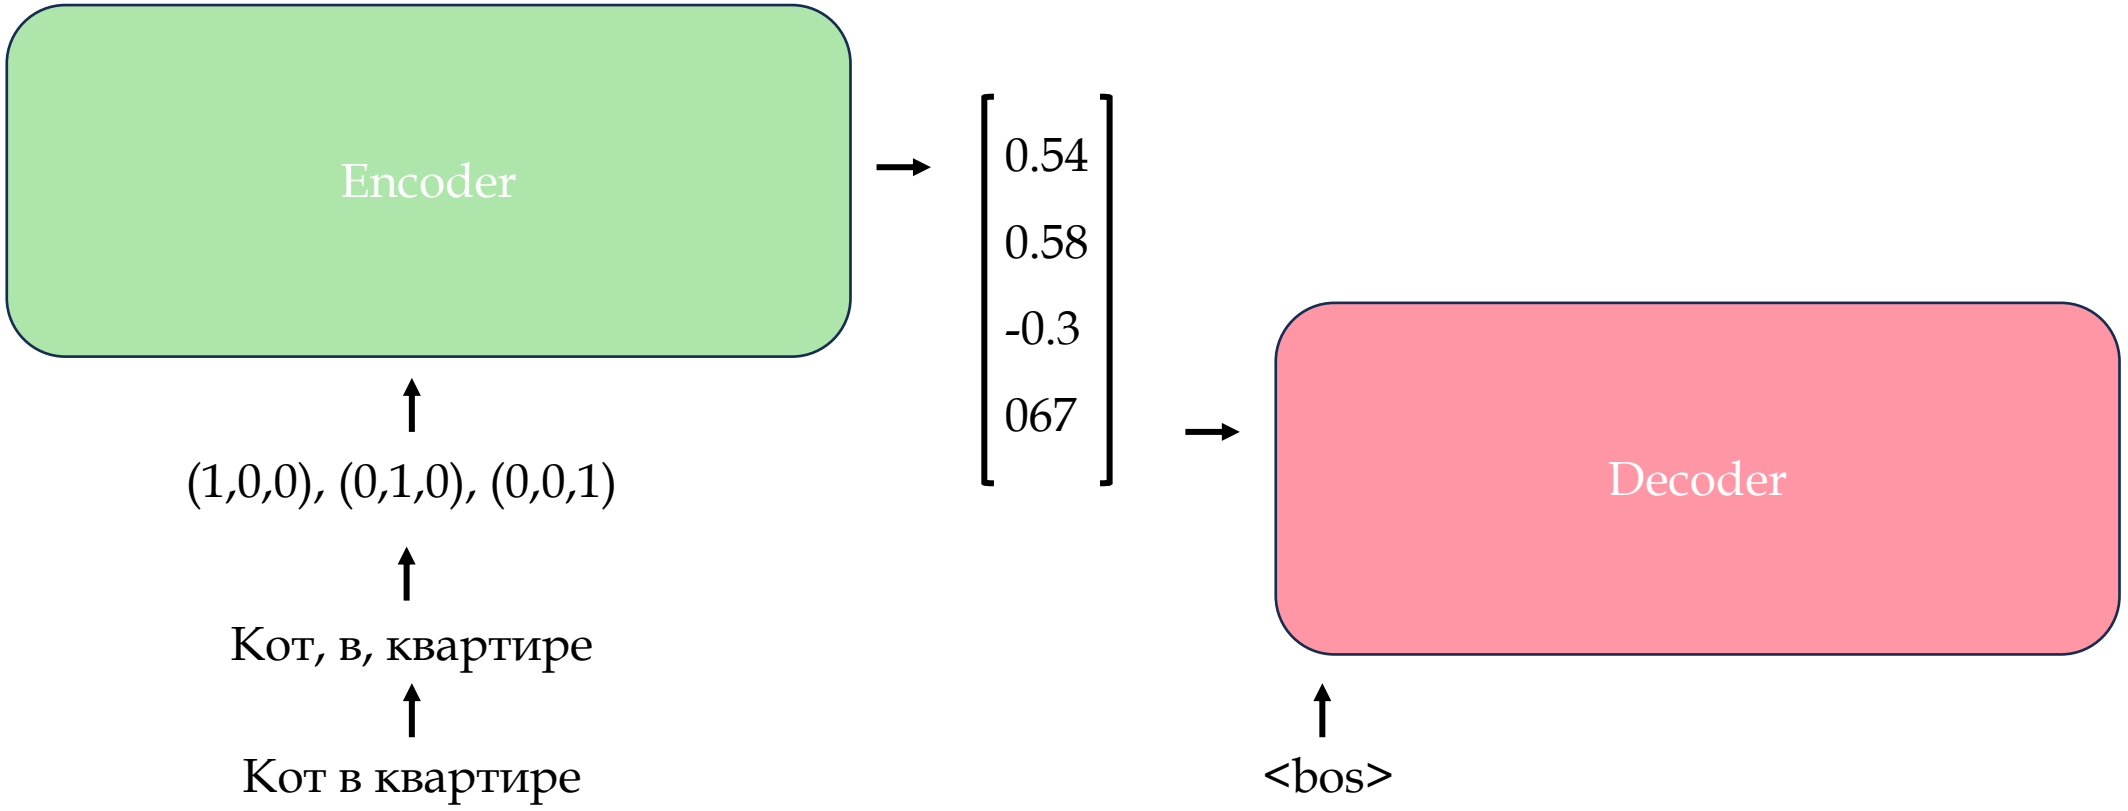

Декодировщик на своем выходном слое имеет проецирует ответ в пространство словаря.
В действительности мы лишь решаем задачу классификации!

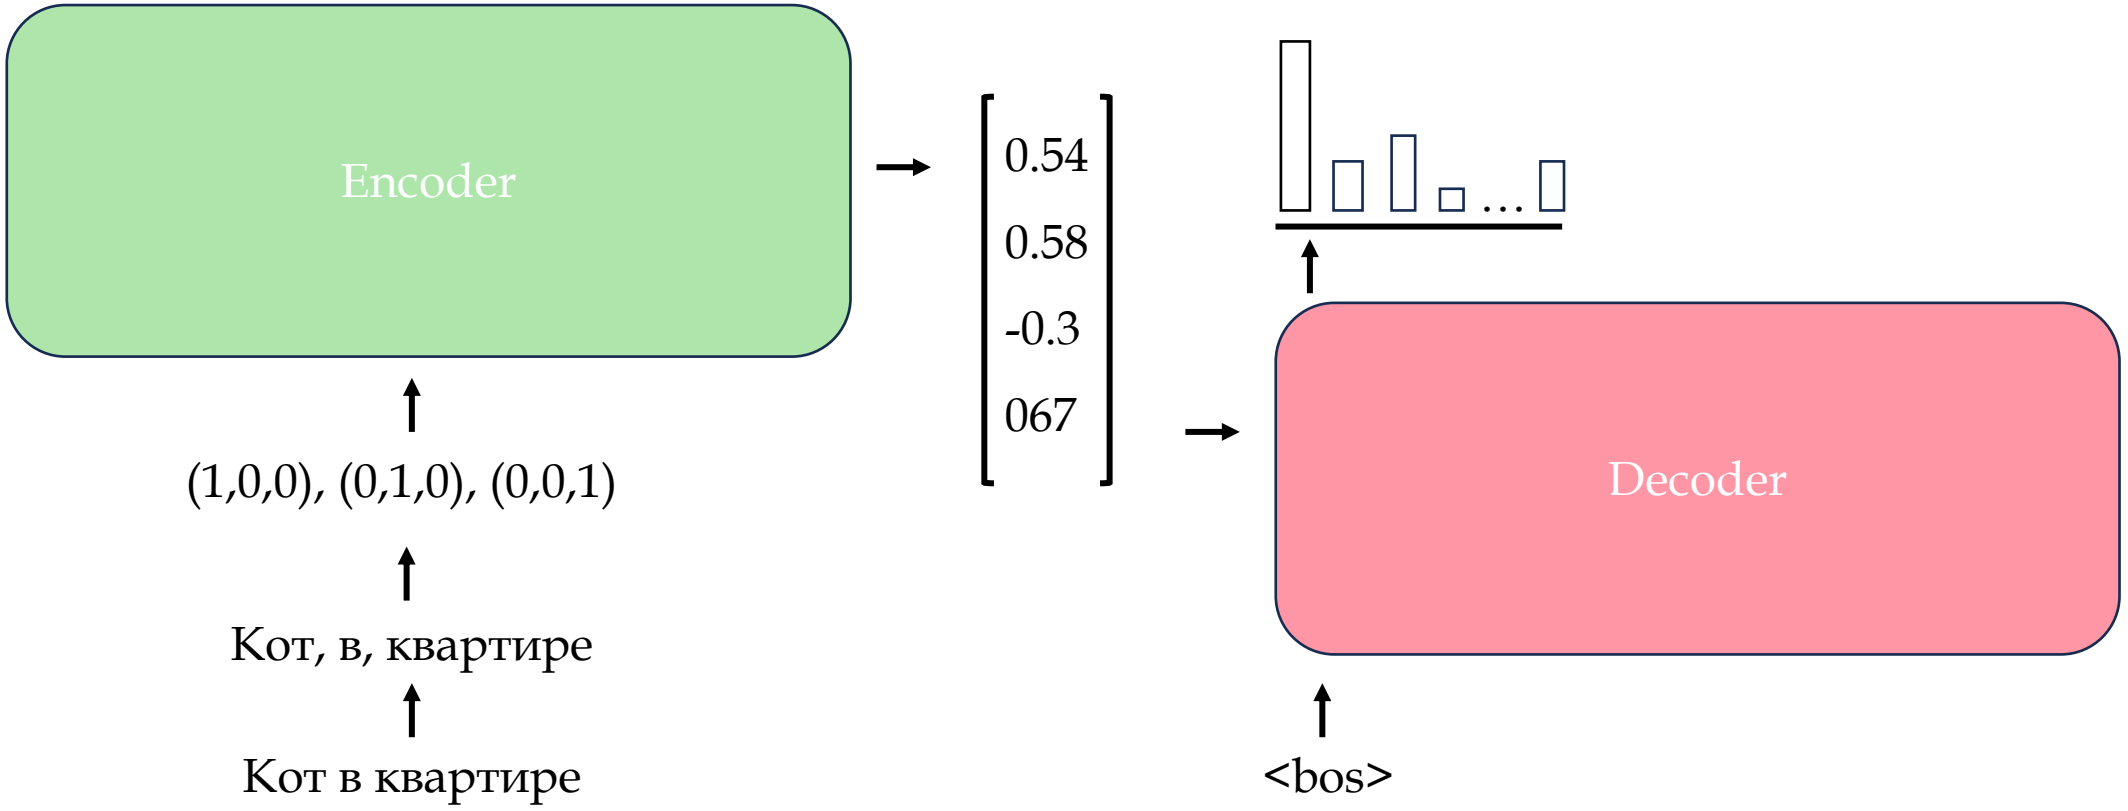

Декодировщик предсказывает следующий токен

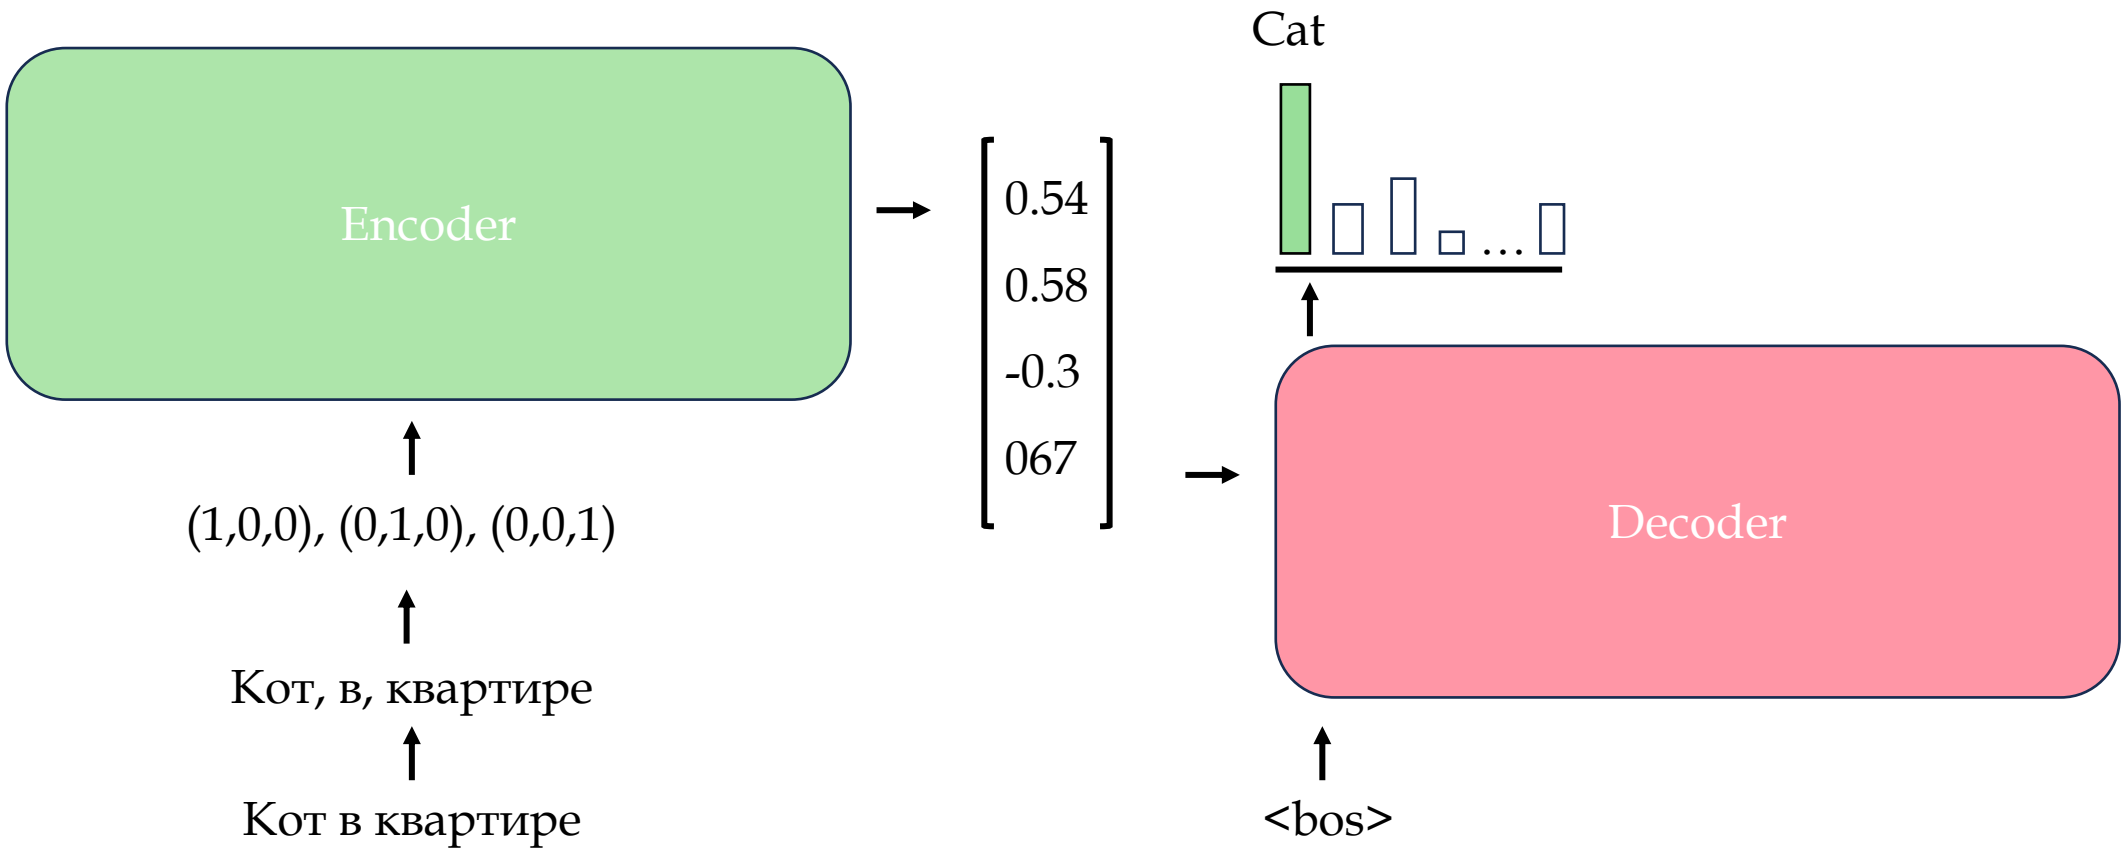

Декодировщик предсказывает следующий токен

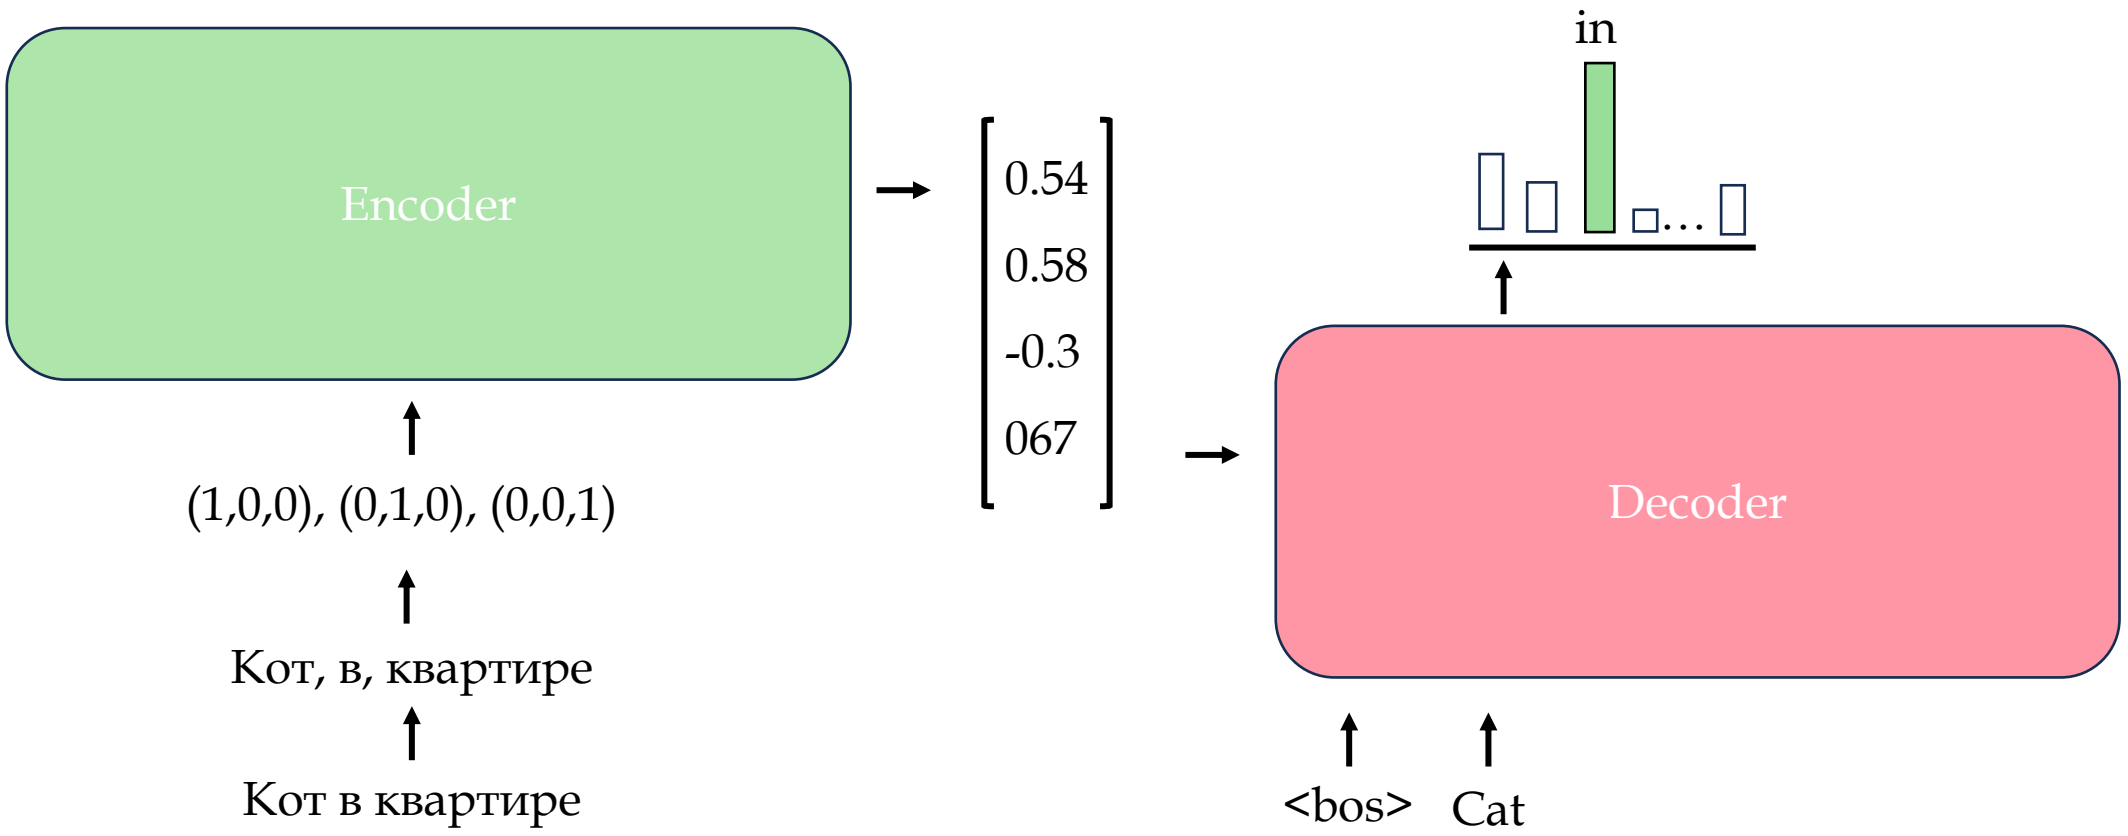

Декодировщик предсказывает следующий токен пока не сгенерирует специальный токен остановки генерации

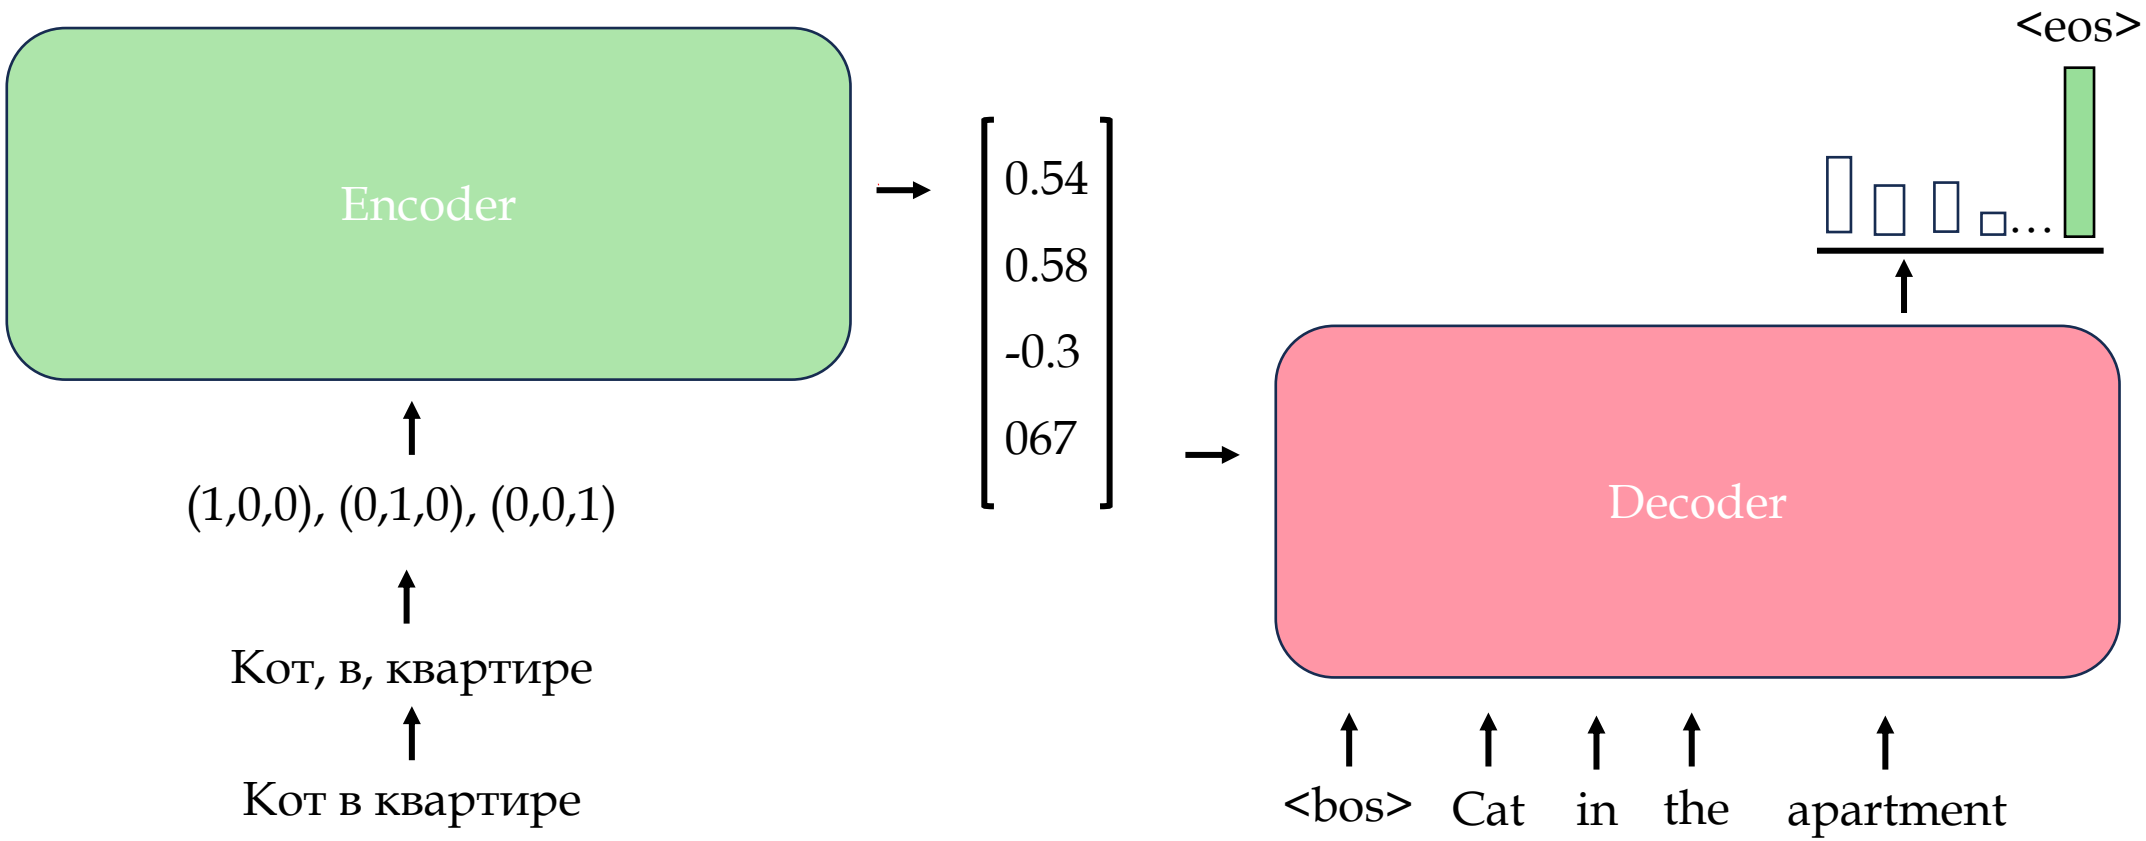

# Архитектура Кодировщика-Декодеровщика сопоставляет семантику данных

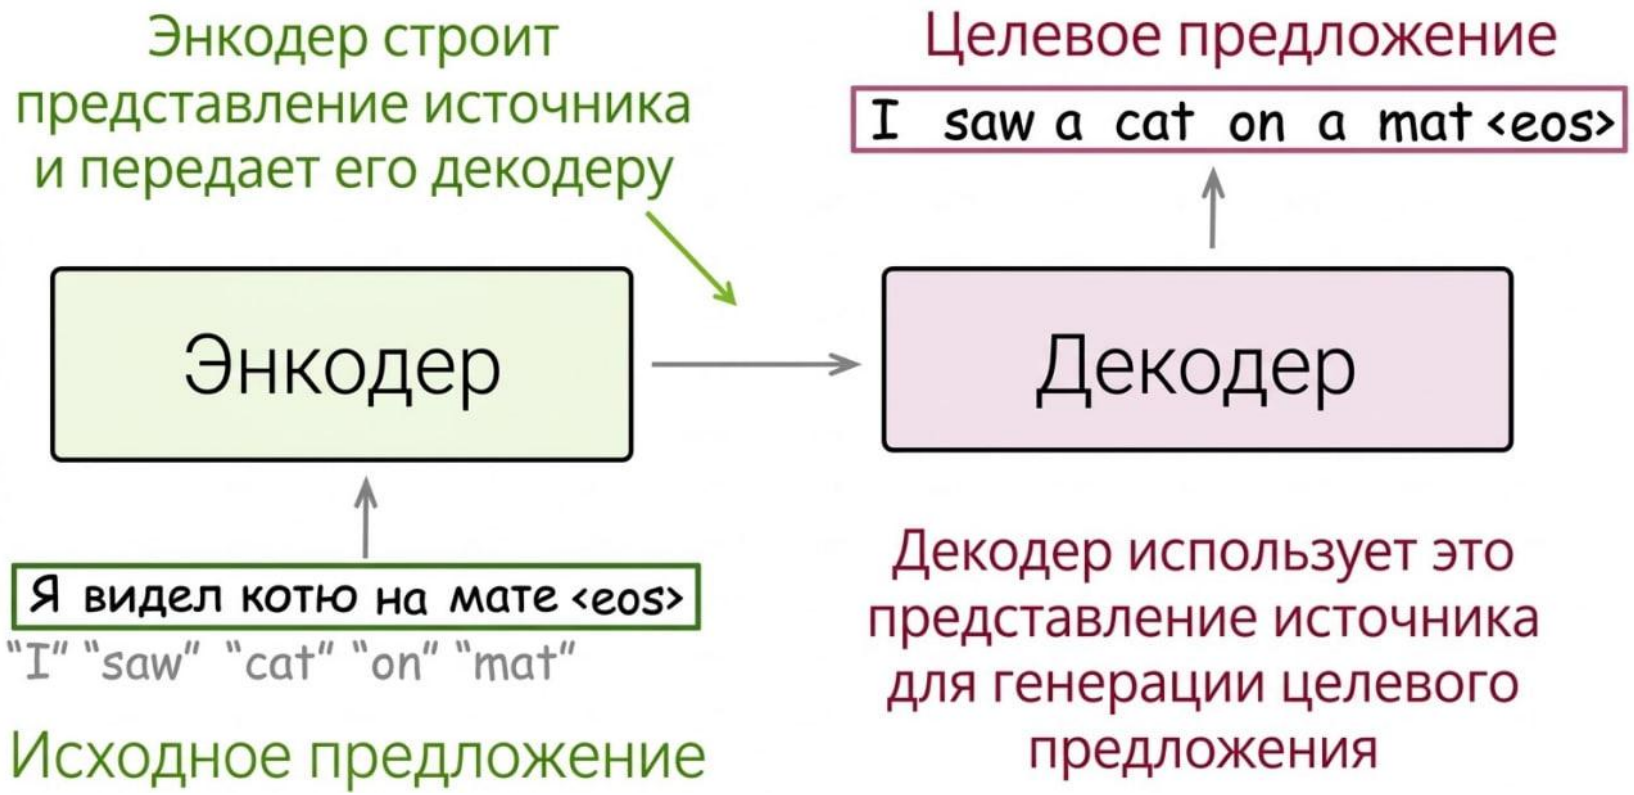


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Кодировщик предоставляет контекст для Декодиовщика

Language Models: $P(y_1, y_2, \dots, y_n) = \prod_{t=1}^{n} p(y_t | y_{<t})$

<u>Conditional</u>
Language Models: $P(y_1, y_2, \dots, y_n, | x) = \prod_{t=1}^{n} p(y_t | y_{<t}, x)$

condition on source $x$

Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Верхнеуровневый взгляд на задачу

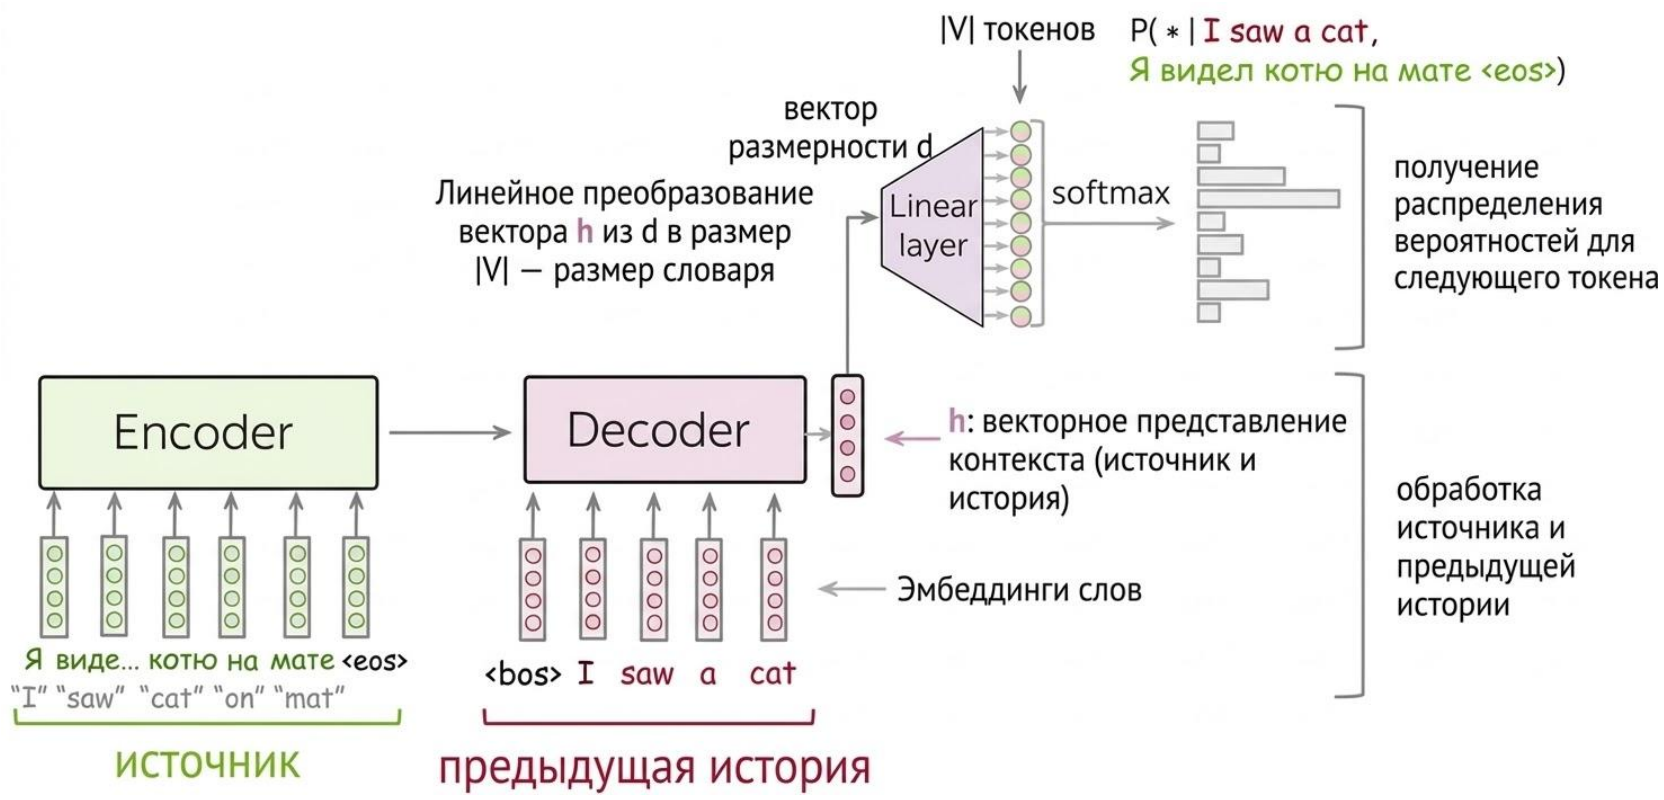


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Функция потерь – уже знакомая нам кросс-энтропия, мерящая расстояние между распределениями

Source sequence:

Я видел котю на мате <eos>

"I" "saw" "cat" "on" "mat"

Target sequence:

I saw a cat on a mat <eos>

one training example

one step for this example

previous tokens

we want the model to predict this

Model prediction: p( * |I saw a, Я ... <eos>)

Target

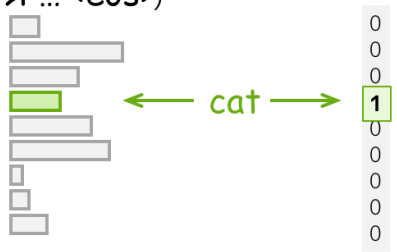


Loss = -log (p(cat)) → min

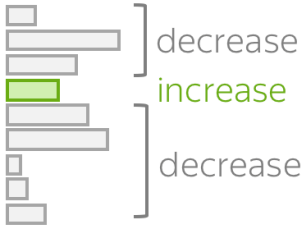


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

Базовыми блоками Энкодера-Декодера могут быть, например, Рекуррентные нейронные сети (RNN)

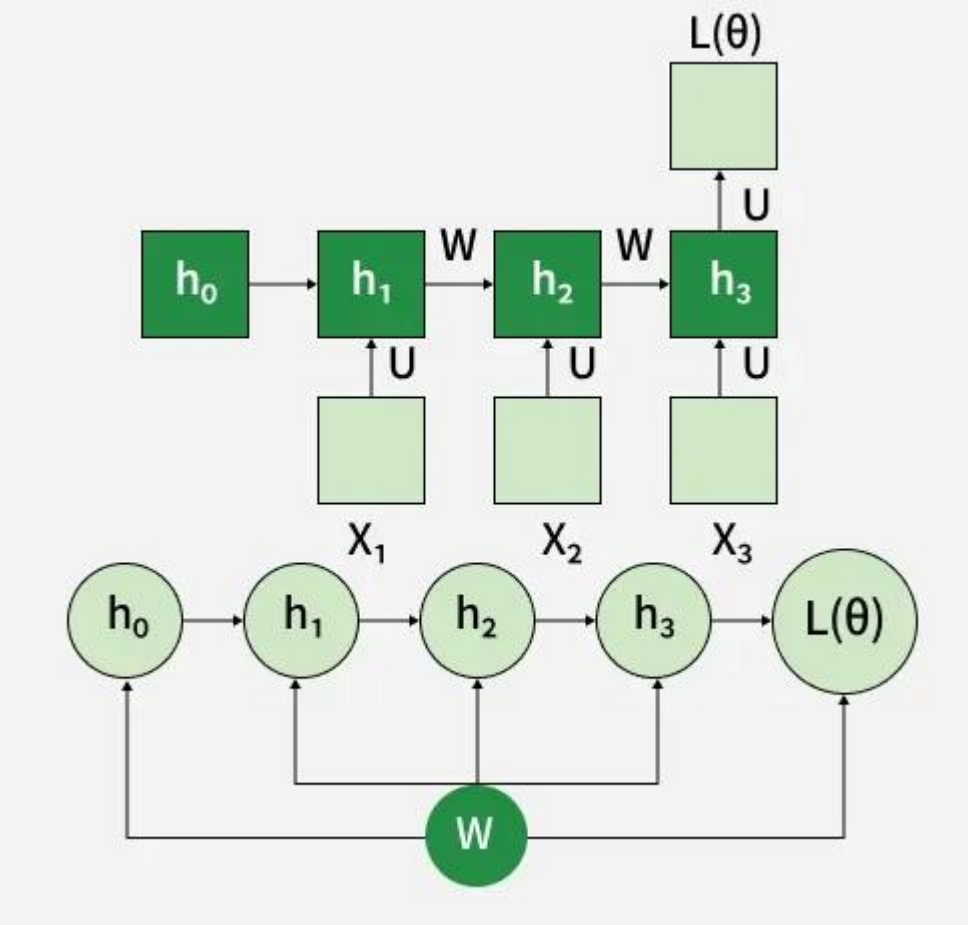


Source: https://www.geeksforgeeks.org/machine-learning/introduction-to-recurrent-neural-network/

# Рекуррентные нейронные сети (RNN) итеративно предсказывают очередной токен

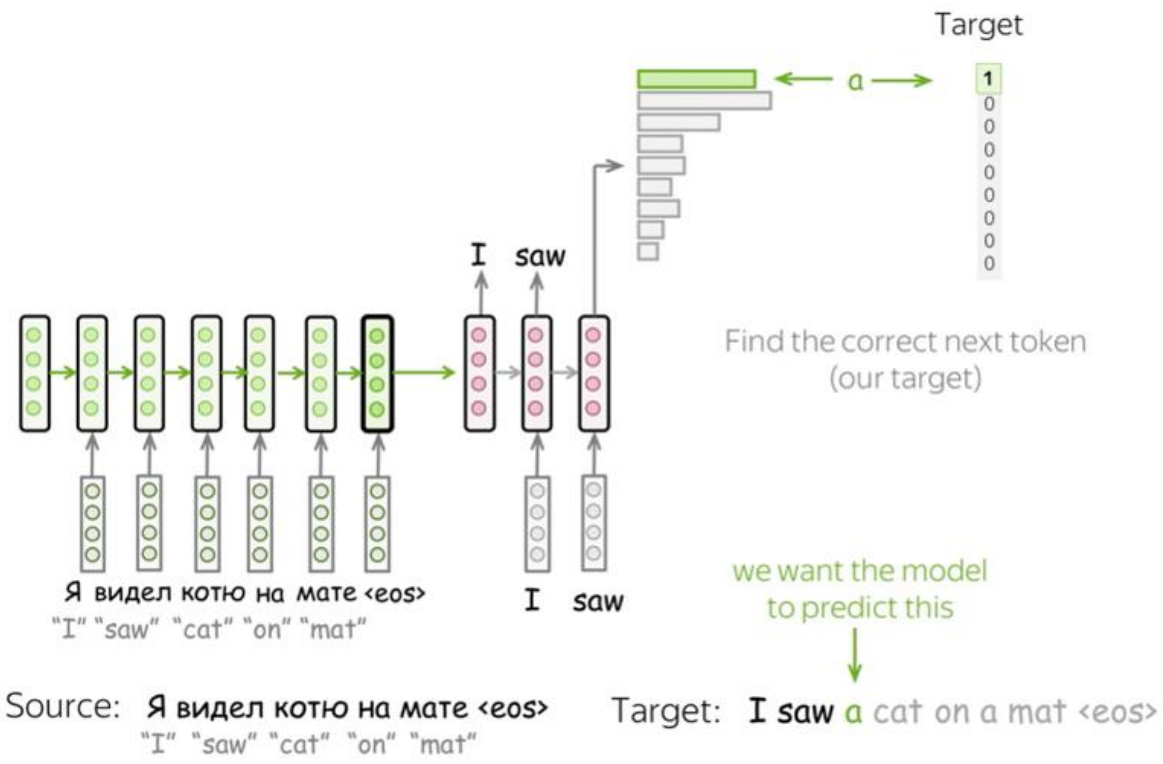


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Рекуррентные нейронные сети (RNN) итеративно предсказывают очередной токен

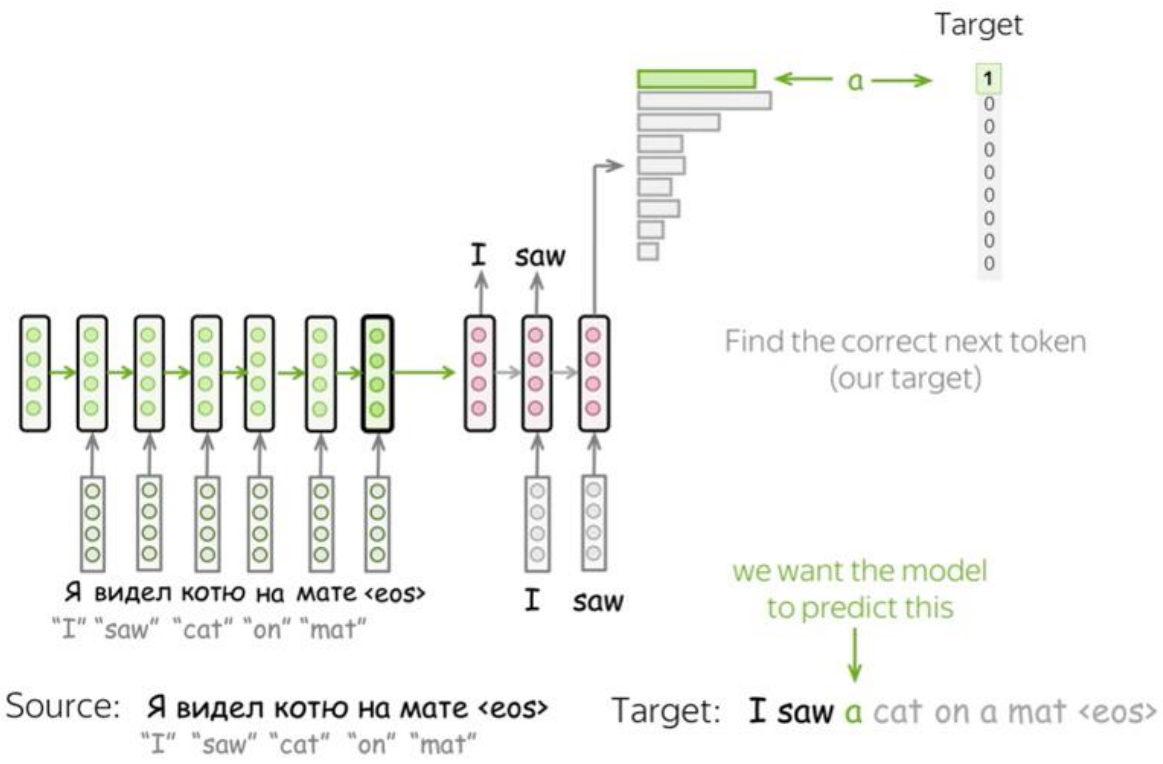


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Weight tying

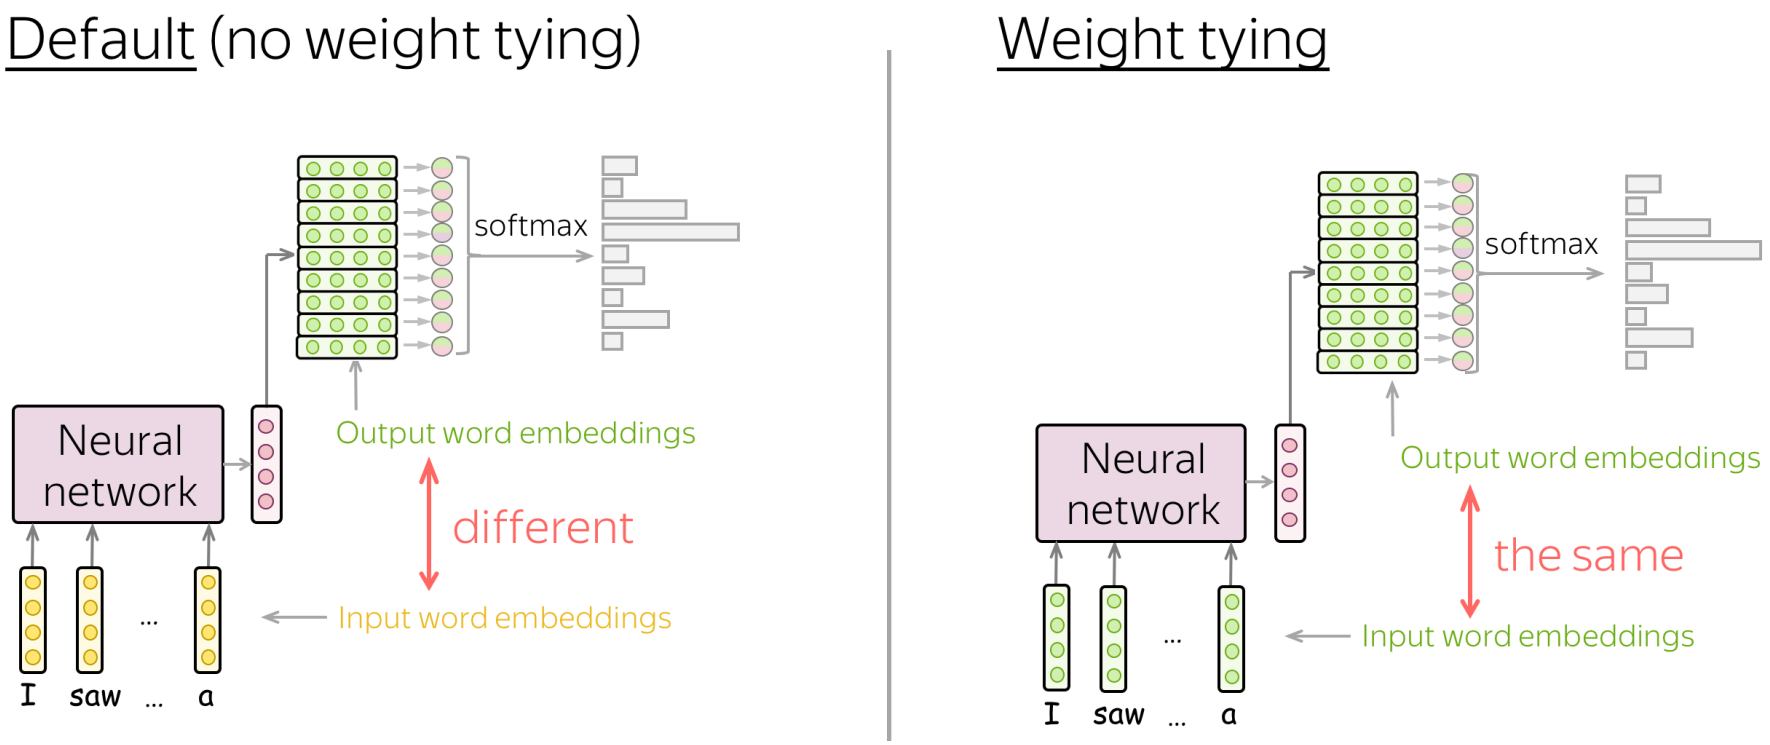


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Кодировщик-Декодировщик может базироваться на RNN

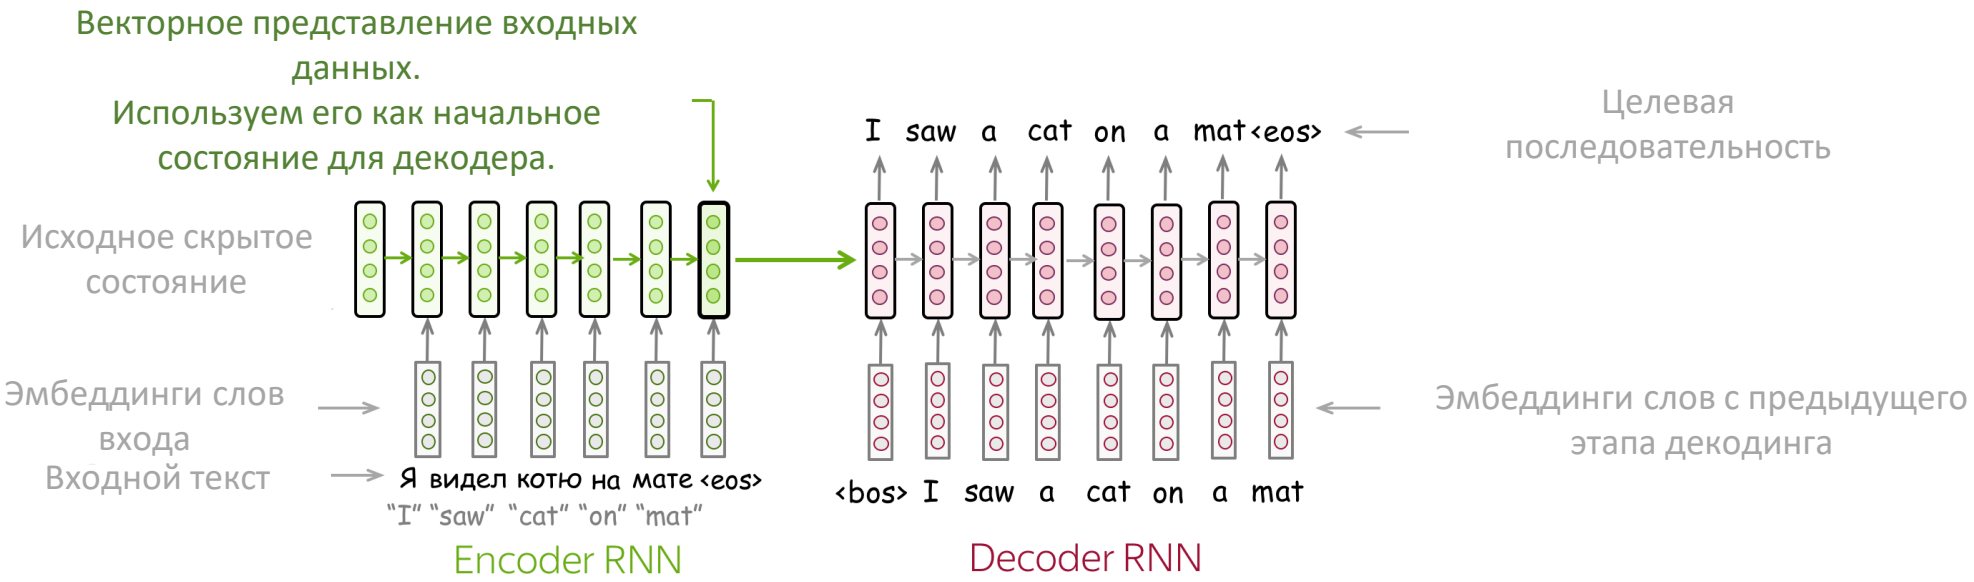


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Семантическое пространство эмбеддингов

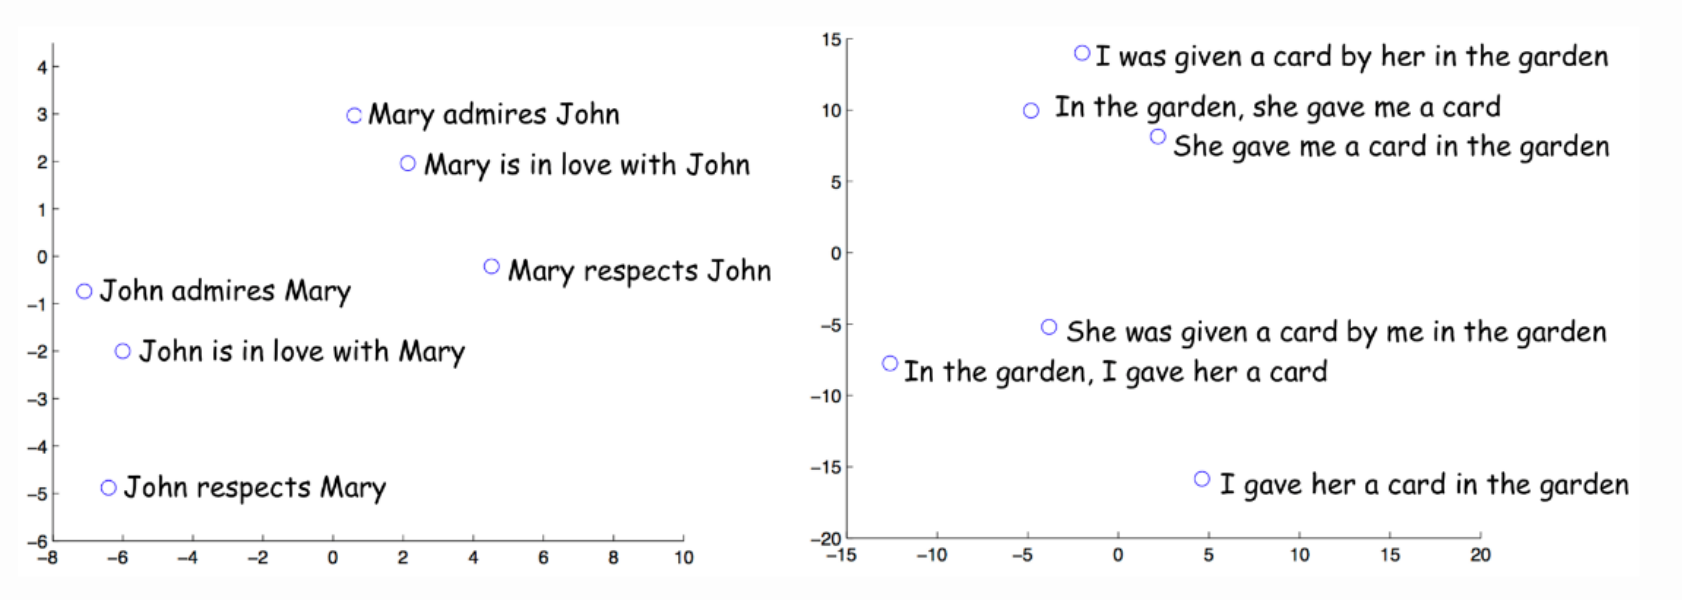


Source: Sequence to Sequence Learning with Neural Networks.

Во время обучения мы сравниваем предсказание с фактом и обновляем веса модели в зависимости от ошибки

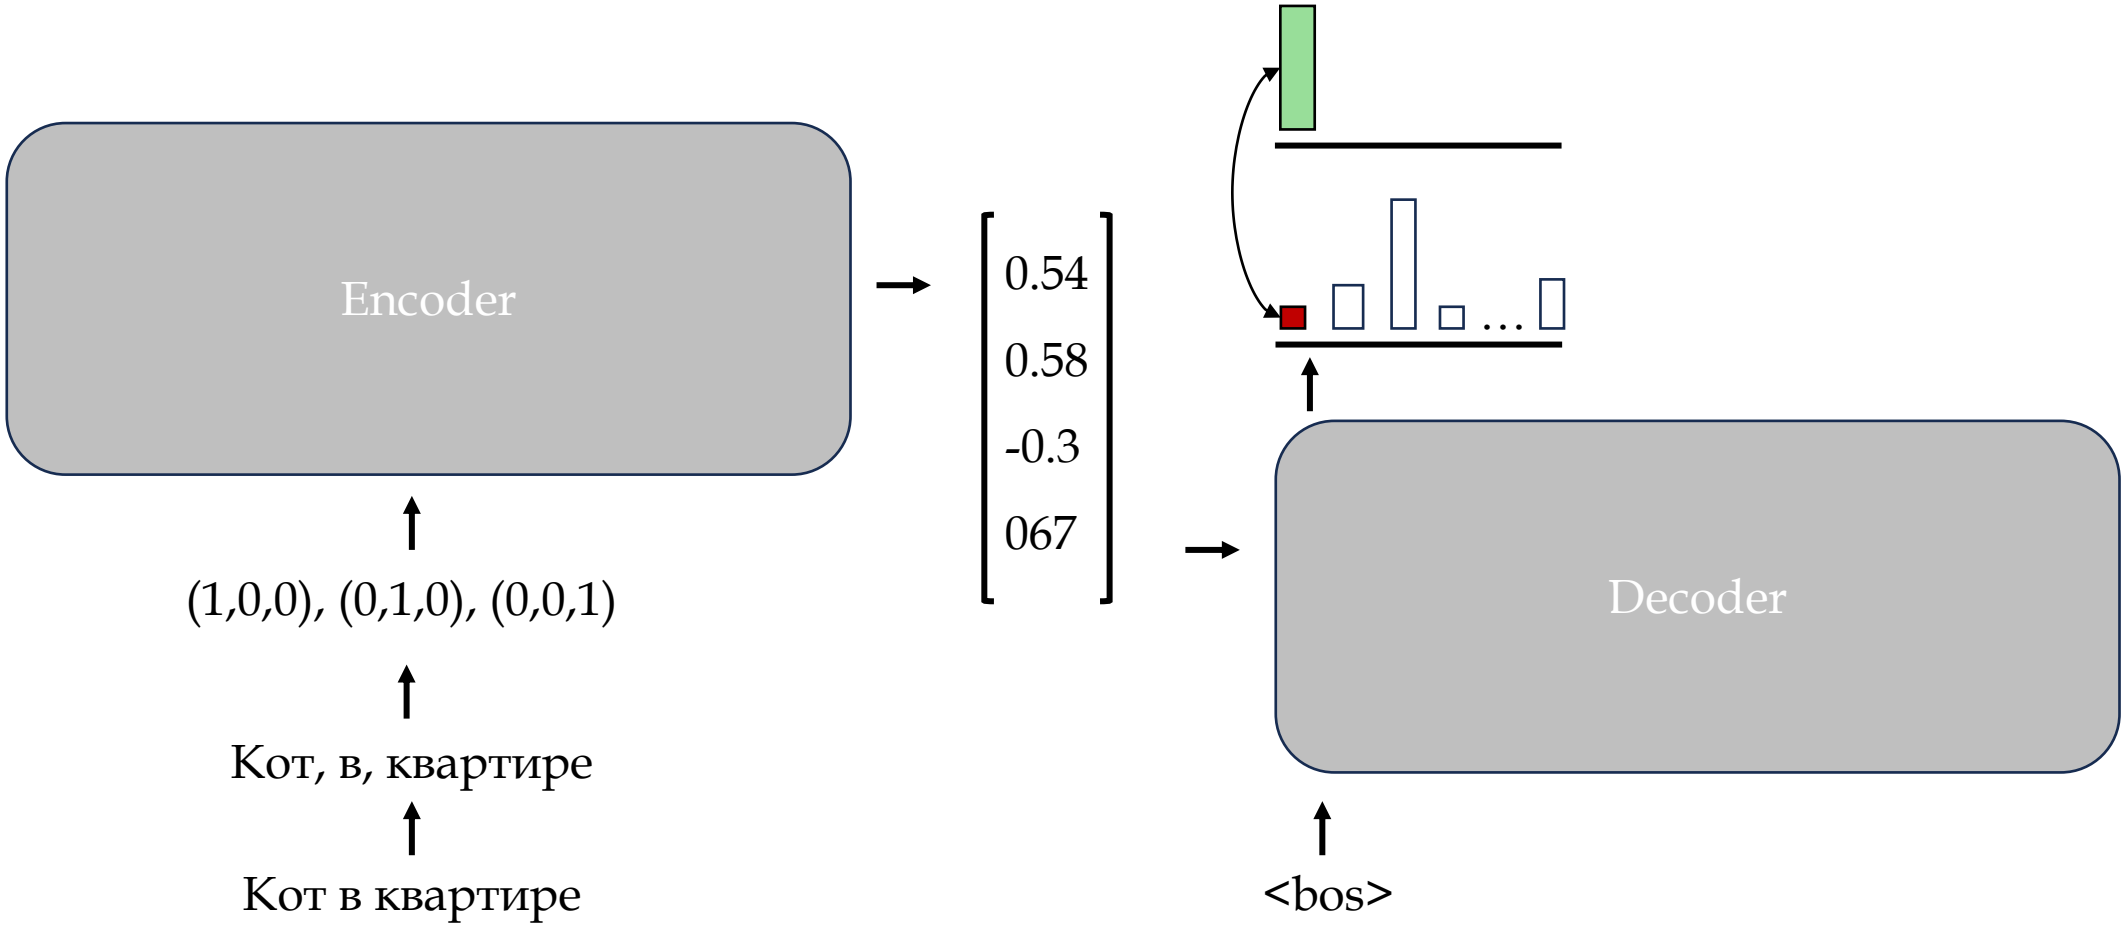

Декодировщик предсказывает следующий токен пока не сгенерирует специальный токен остановки генерации

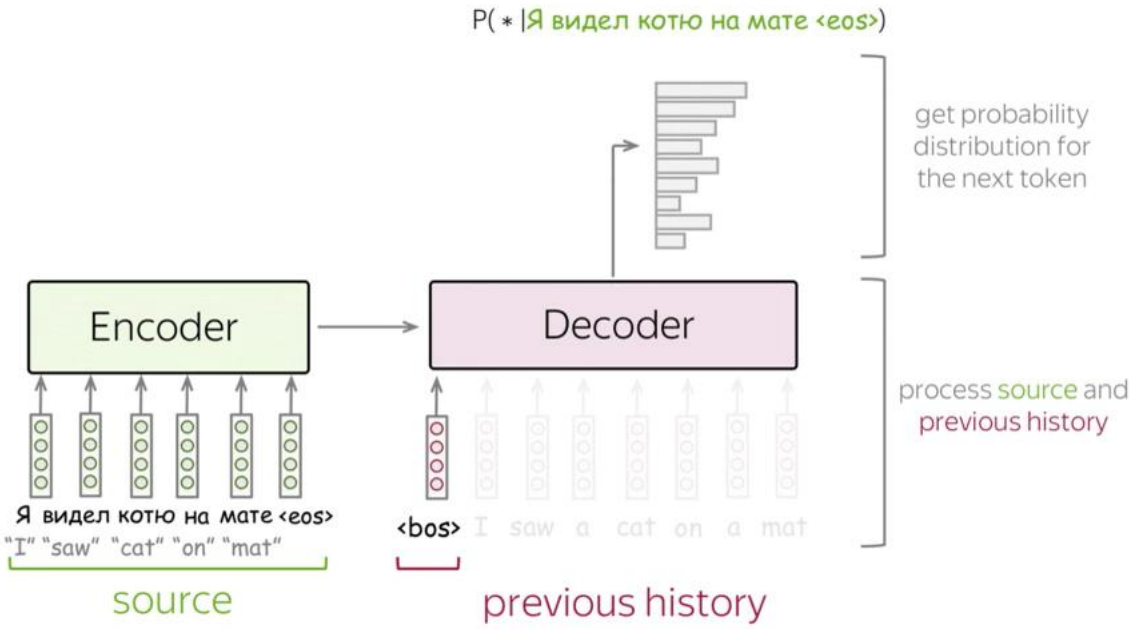


Источник: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

RNN принимает на вход предыдущее скрытое состояние и предсказанный токен, производит следующее скрытое состояние и предсказывает следующий токен

Источник: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Скрытое состояние на выходе из кодировщика является бутылочным горлышком

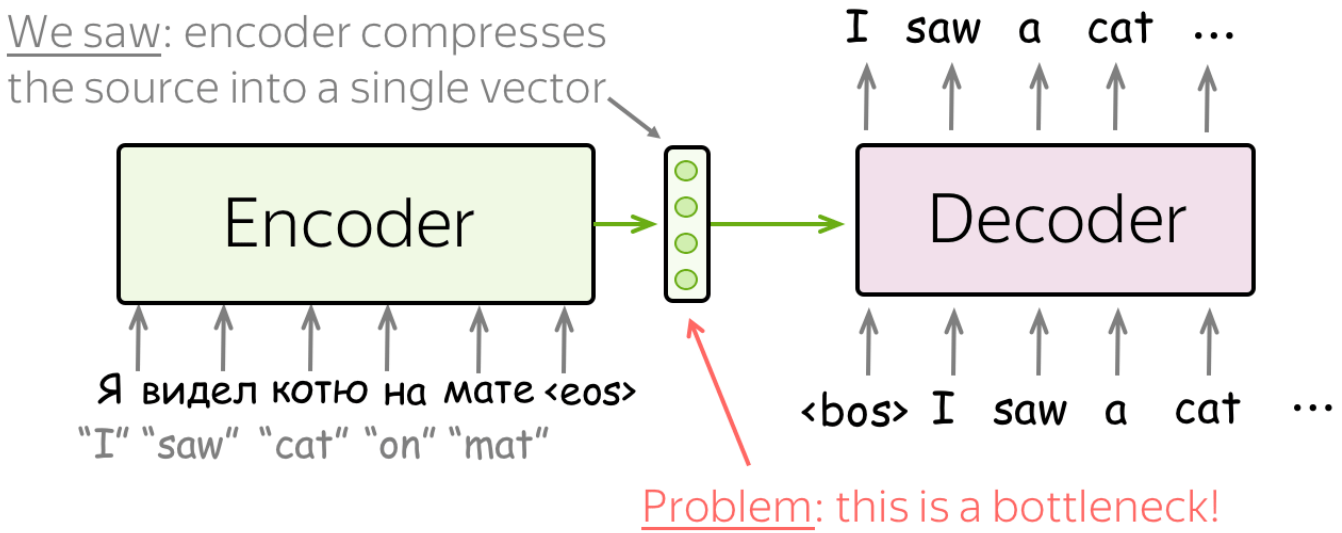


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

Произведение матриц можно интерпретировать как набор скалярных произведений соответствующих строк и столбцов.

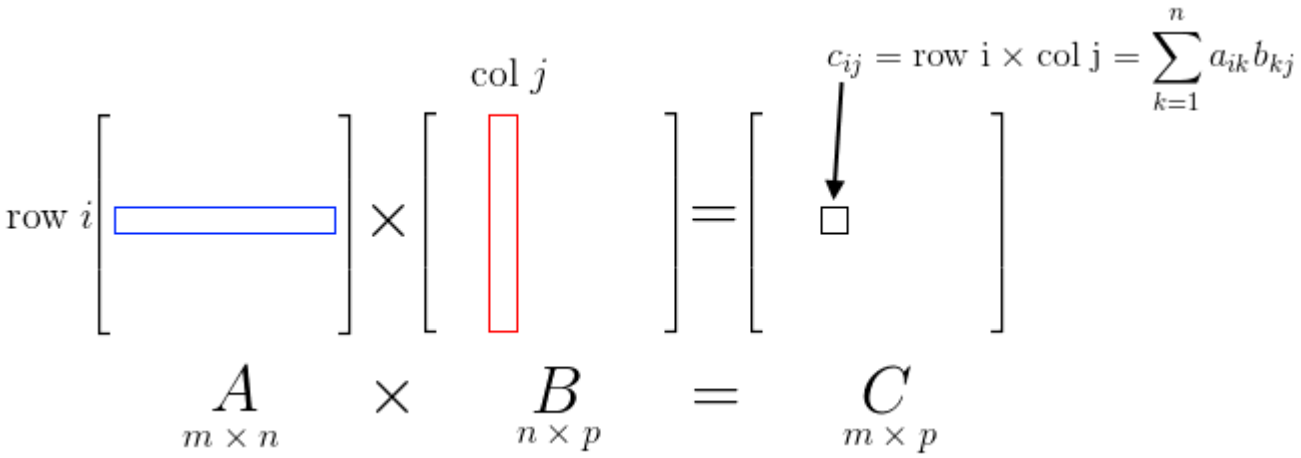

# Обзор механизма внимания в RNN

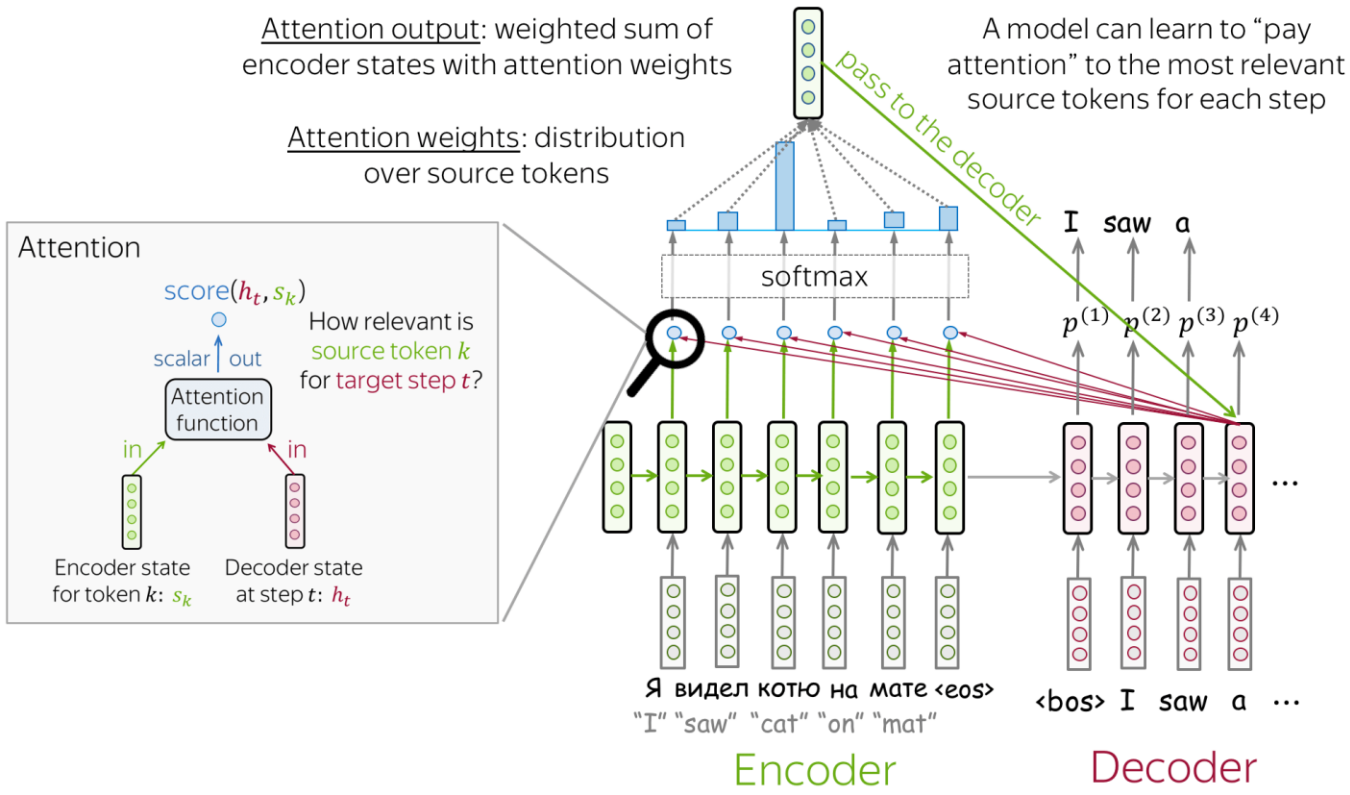


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Скрытые состояния Кодировщика взвешиваются пропорционально их релевантности для Декодировщика

Attention output

$$c^{(t)} = a_1^{(t)} s_1 + a_2^{(t)} s_2 + \cdots + a_m^{(t)} s_m = \sum_{k=1}^{m} a_k^{(t)} s_k$$

"source context for decoder step $t$"

(weighted sum)

Attention weights

$$a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_{i=1}^{m} \exp(\text{score}(h_t, s_i))}, \mathrm{k} = 1..\mathrm{m}$$

"attention weight for source token $k$ at decoder step $t$"

(softmax)

Attention scores

$$\text{score}(h_t, s_k), \mathrm{k} = 1..\mathrm{m}$$

"How relevant is source token $k$ for target step $t$?"

Attention input

$s_1, s_2, \ldots, s_m$ — all encoder states

$h_t$ — one decoder state

Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Скрытые состояния Кодировщика взвешиваются пропорционально их релевантности для Декодировщика

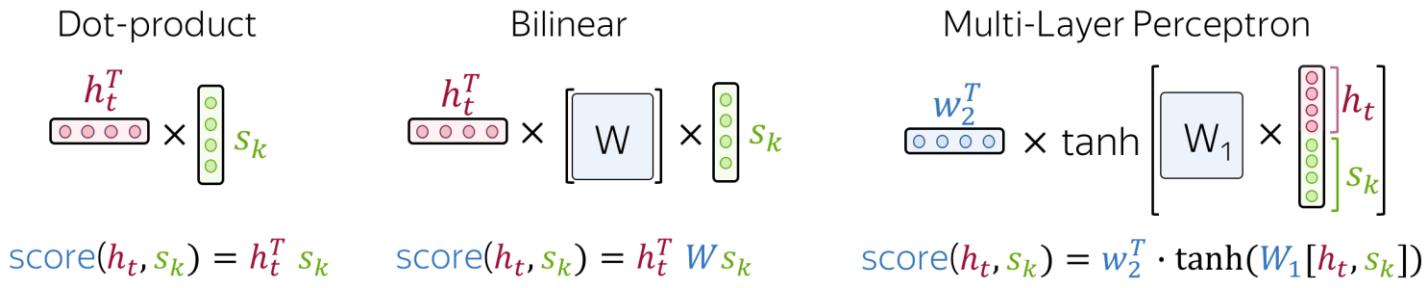


Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Finding the next token is not that trivial

$$y' = \arg\max_{y} p(y|x) = \arg\max_{y} \prod_{t=1}^{n} p(y_t|y_{<t}, x)$$

How to find the argmax?

Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Жадное декодирование не гарантирует нам оптимального результата

$$\arg\max_{y} \prod_{t=1}^{n} p(y_t | y_{<t}, x) \neq \prod_{t=1}^{n} \arg\max_{y_t} p(y_t | y_{<t}, x)$$

Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Один из способов бороться с этим – Лучевой поиск (Beam search)

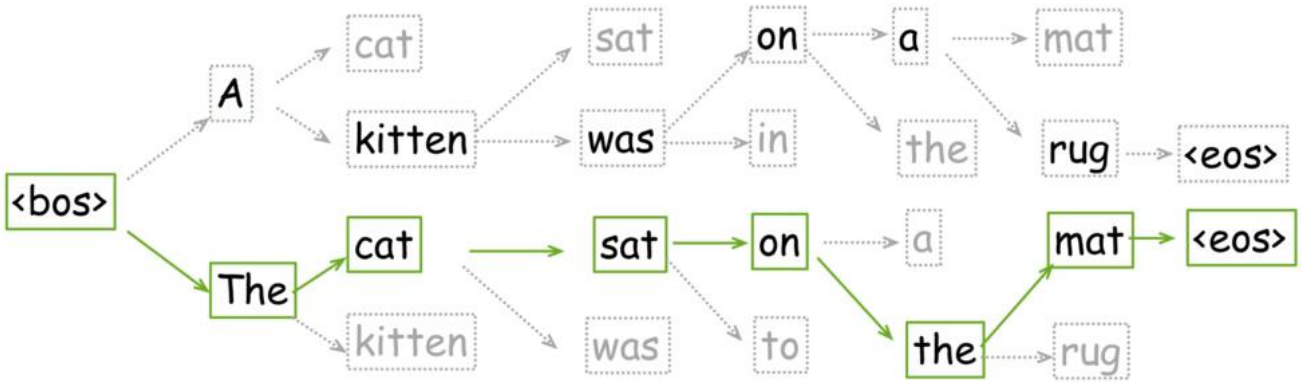


Pick the hypothesis with the highest probability

Source: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Альтернатива – Top-P генерация

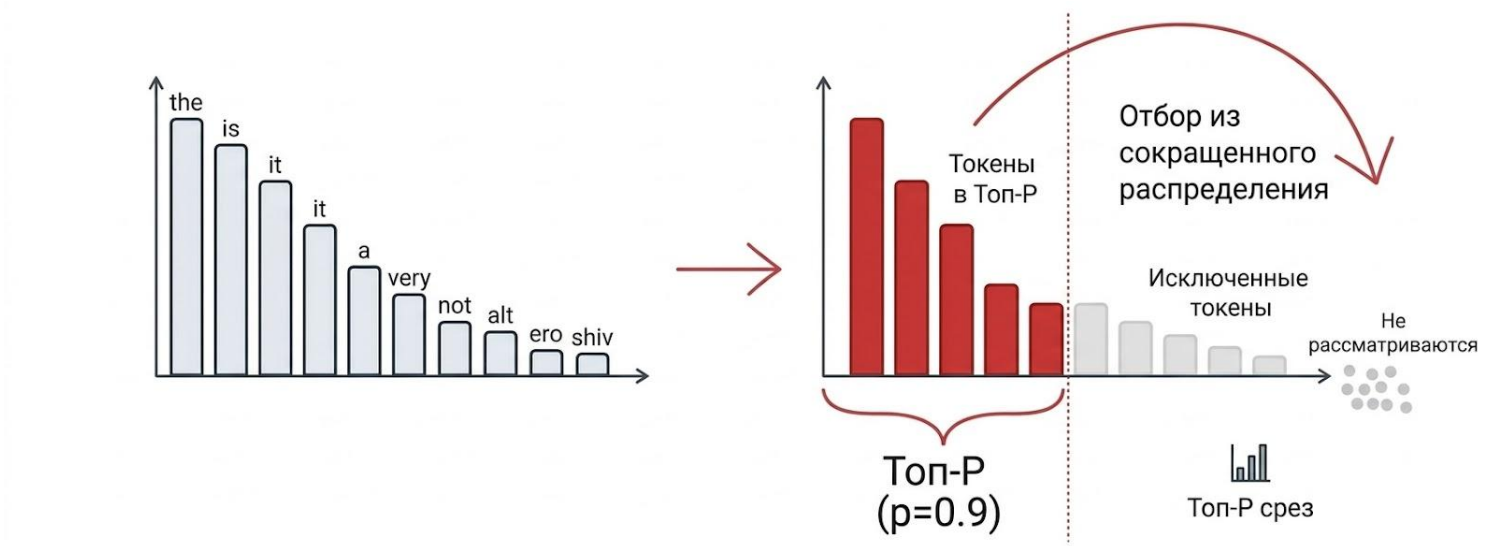

# Температура задает степень хаотичности распределения

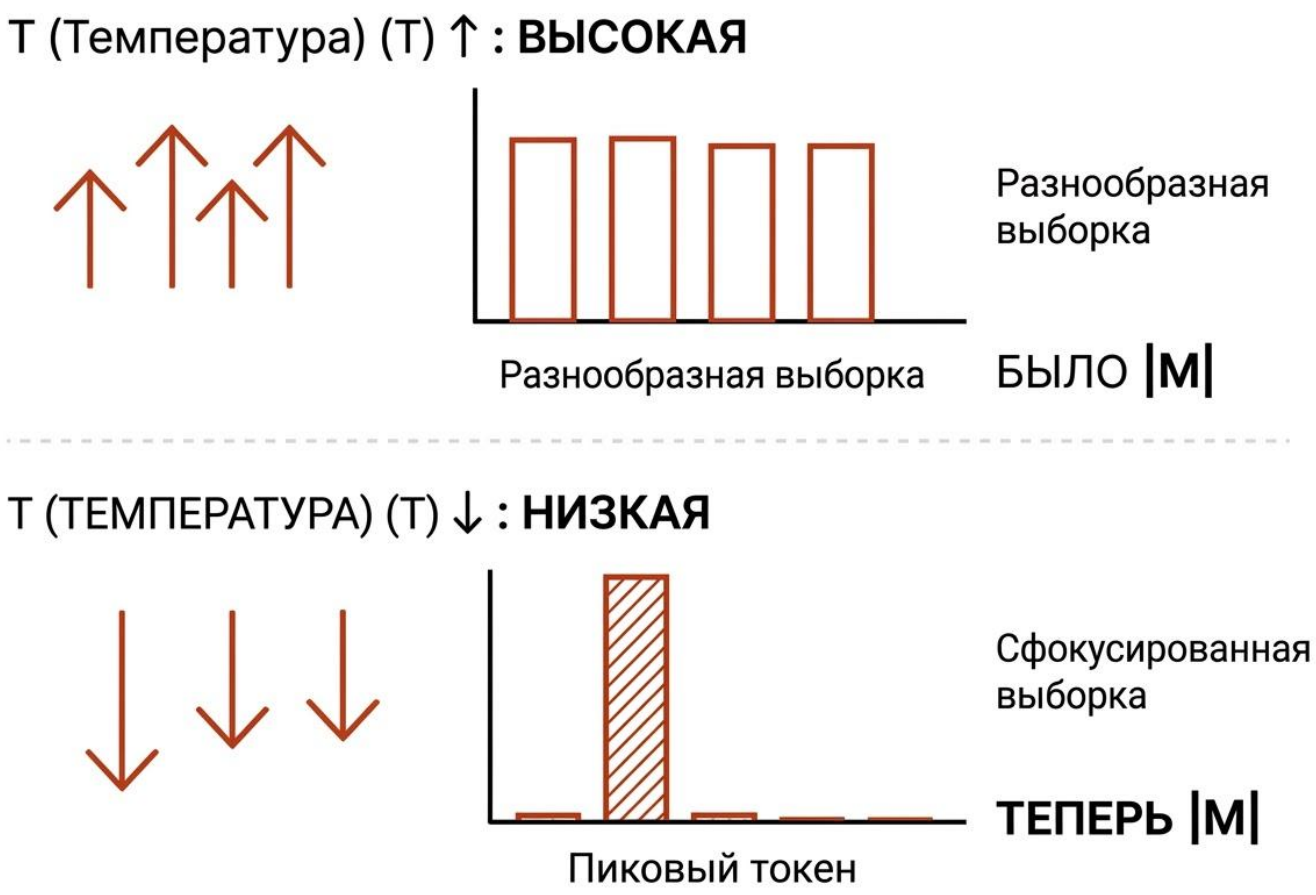


$$w_{next} \sim \frac{P(w_{next}|X)^{1/\tau}}{\sum_{\hat{w}} P(\hat{w}|X)^{1/\tau}}$$

- -

# Содержание

- Закодировали, раскодировали
- **«Т» значит «Трансформер»**

Трансформер – частный случай уже знакомой нам архитектуры **encoder-decoder**

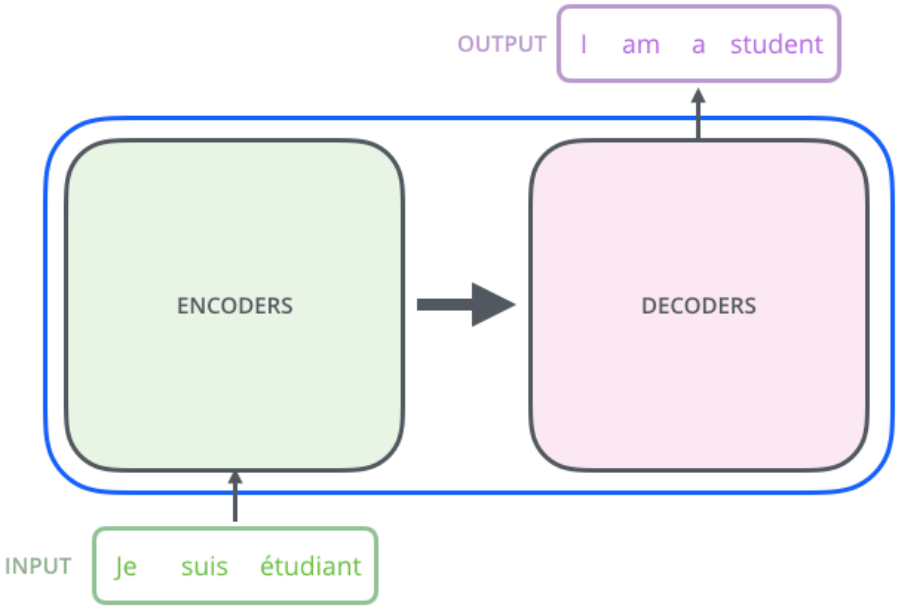


Источник: The Illustrated Transformer by Jay Alammar

Encoder и Decoder похожи друг на друга с точки зрения архитектуры

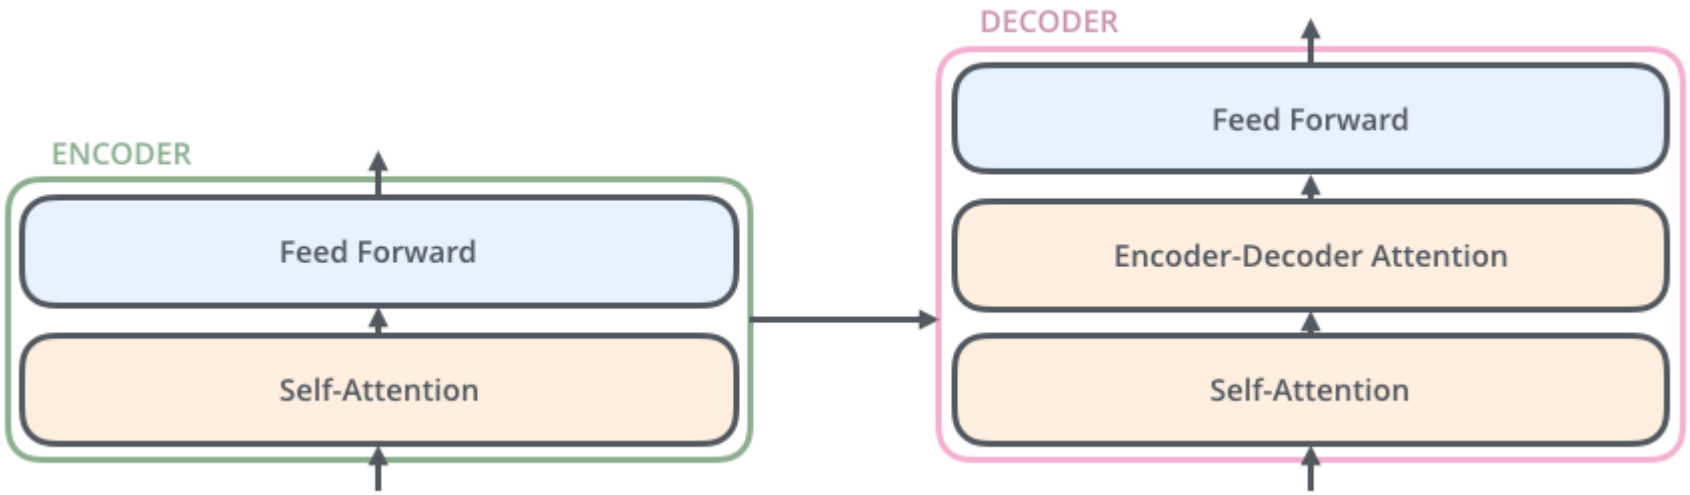


Источник: The Illustrated Transformer by Jay Alammar

# Основные этапы обработки данных – механизм внимания и полносвязные слои

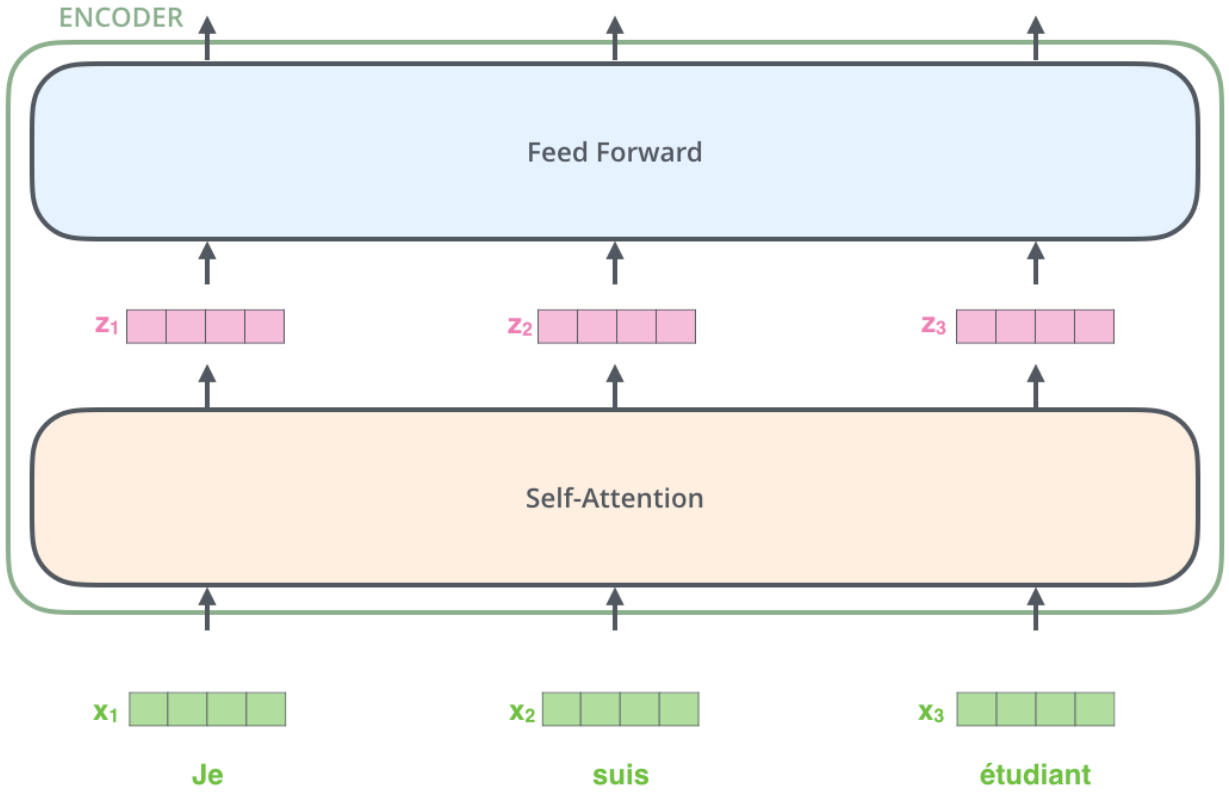


Источник: The Illustrated Transformer by Jay Alammar

# Основные этапы обработки данных – механизм внимания и полносвязные слои

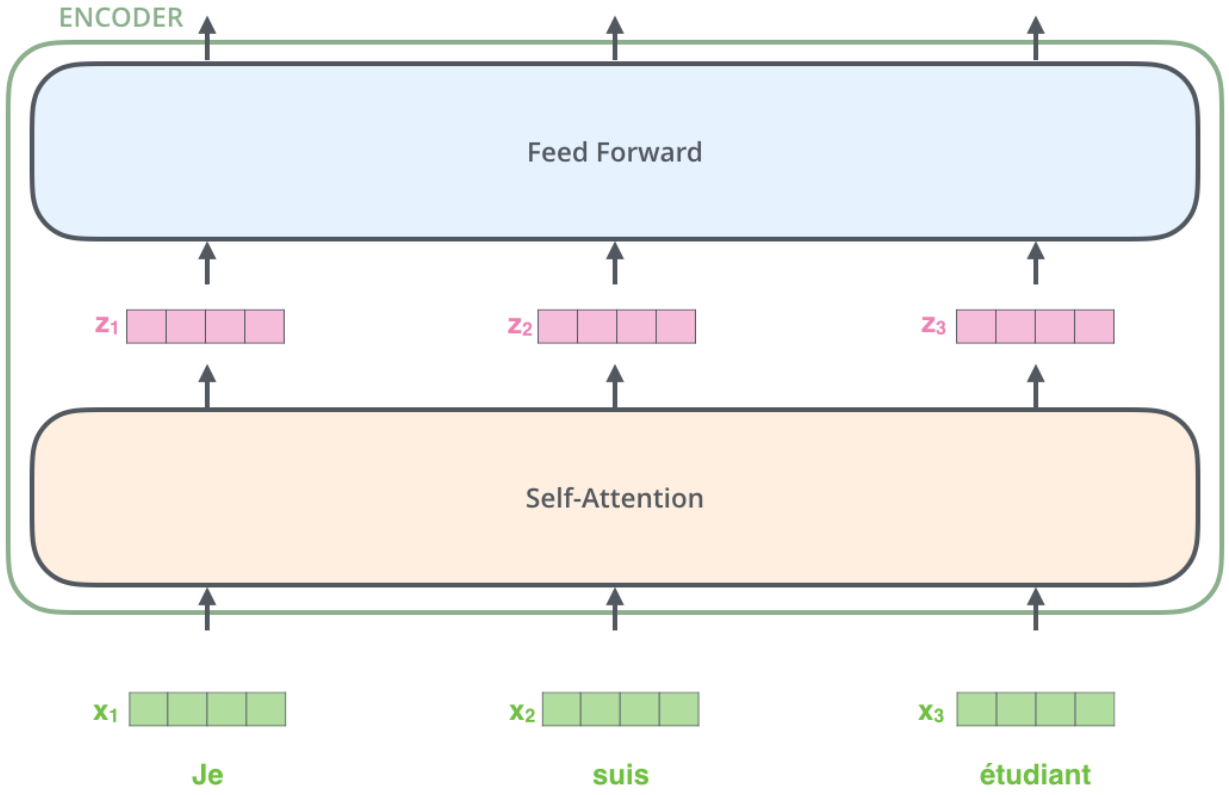


Источник: The Illustrated Transformer by Jay Alammar

# Рассмотрим работу механизма внимания

*Механизм внимания*

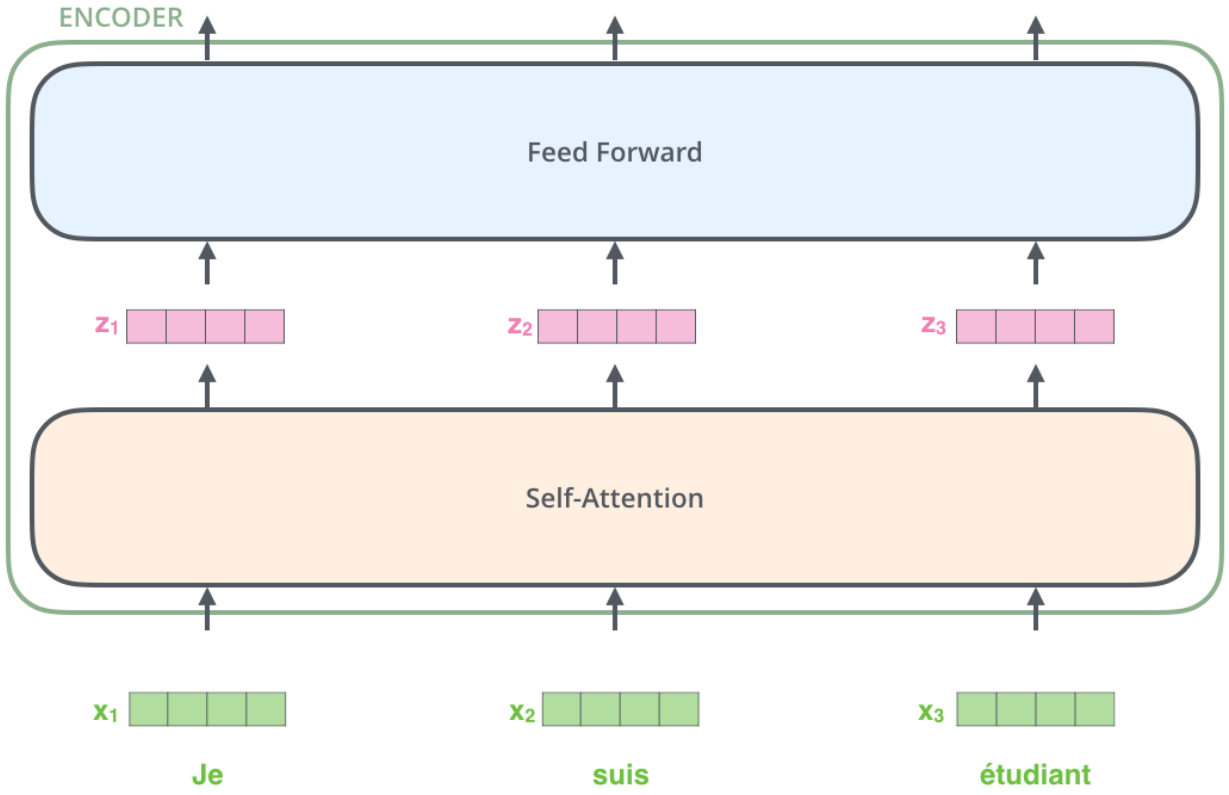


Источник: The Illustrated Transformer by Jay Alammar

Вектор каждого входного токена представим в трех ипостасях i.e. Queries, Keys, Values

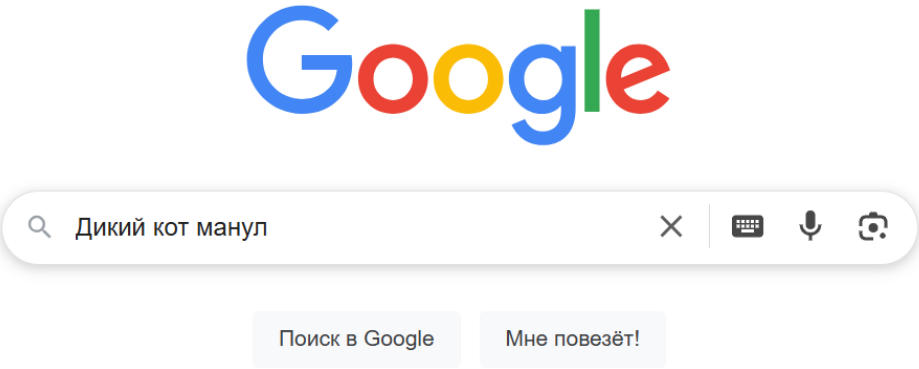

Вектор каждого входного токена представим в трех ипостасях i.e. Queries, Keys, Values

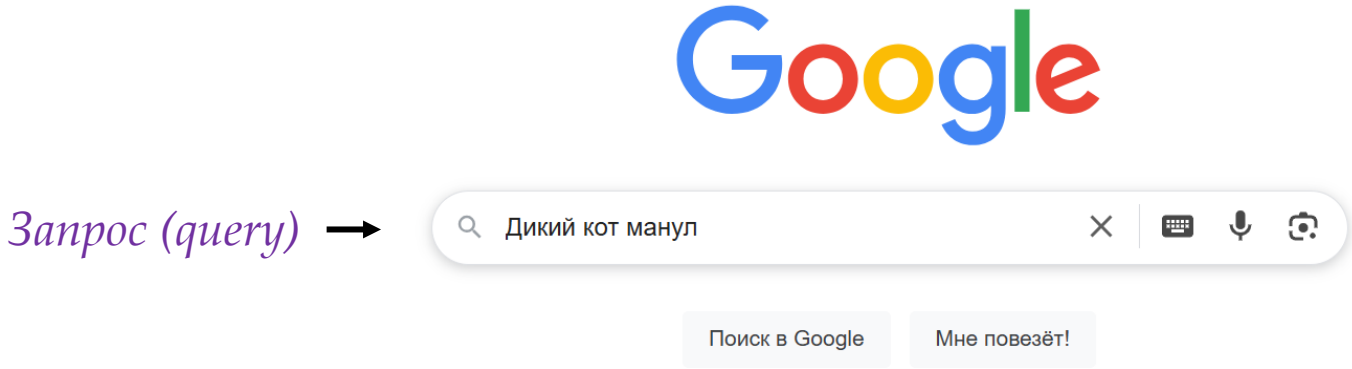

Вектор каждого входного токена представим в трех ипостасях i.e. Queries, Keys, Values

*Запрос (query)* →

Дикий кот манул

Поиск в Google | Мне повезёт!

## Золотистый ретривер собака

История золотистых ретриверов тесно связана с британским лордом Твидмаутом. Он давно мечтал приобрести охотничью собаку и приобрел необычного щенка золотистого цвета – единственного в помете черного ретривера

## Манул: где посмотреть на самую редкую кошку в России

Расскажите друзьям:

Хищное млекопитающее с вечно недовольной мордой очень похоже на домашнюю кошку, но ведет себя совсем по-другому. «Комсомольская правда» расскажет о рационе, повадках и особенностях жизни брутального степного кота - манула.

Название «манул» по-монгольски значит «дикий кот». Другое имя - палласов кот - зверь получил в честь германского ученого Петра Симона Палласа, впервые описавшего этот вид кошачьих. Манулы встречаются в азиатских степях и предгорьях - от Западного Ирана до Тибета. Благодаря густому пушистому меху, они прекрасно чувствуют себя в суровом континентальном климате, живут в безлюдных местах, где выпадает немного снега, и легко выдерживают большие перепады температур. В природе встречается три подвида палласовых котов - сибирский, тибетский и закаспийский манулы.

«Манул» по-монгольски значит «дикий кот».

Вектор каждого входного токена представим в трех ипостасях i.e. Queries, Keys, Values

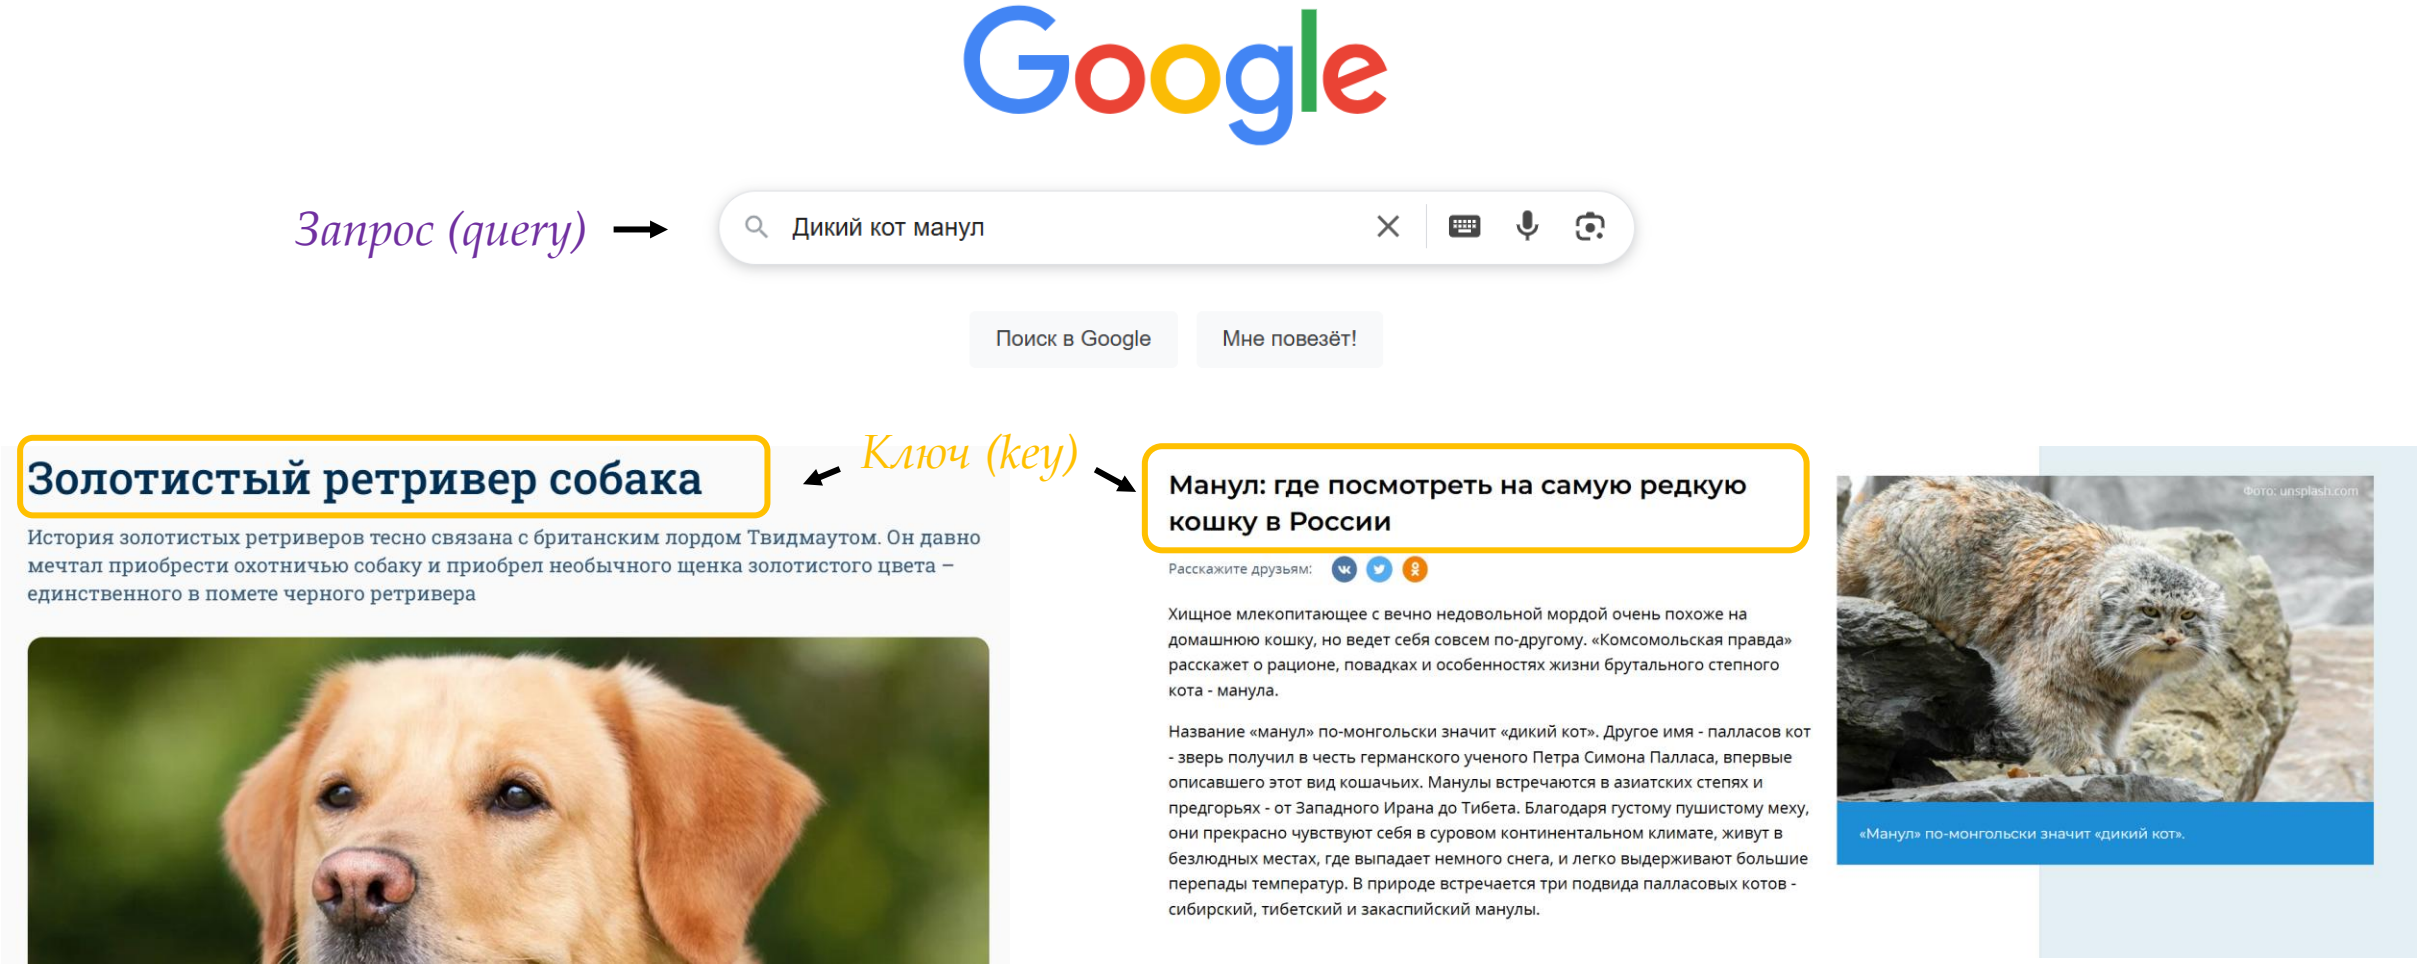

Вектор каждого входного токена представим в трех ипостасях i.e. Queries, Keys, Values

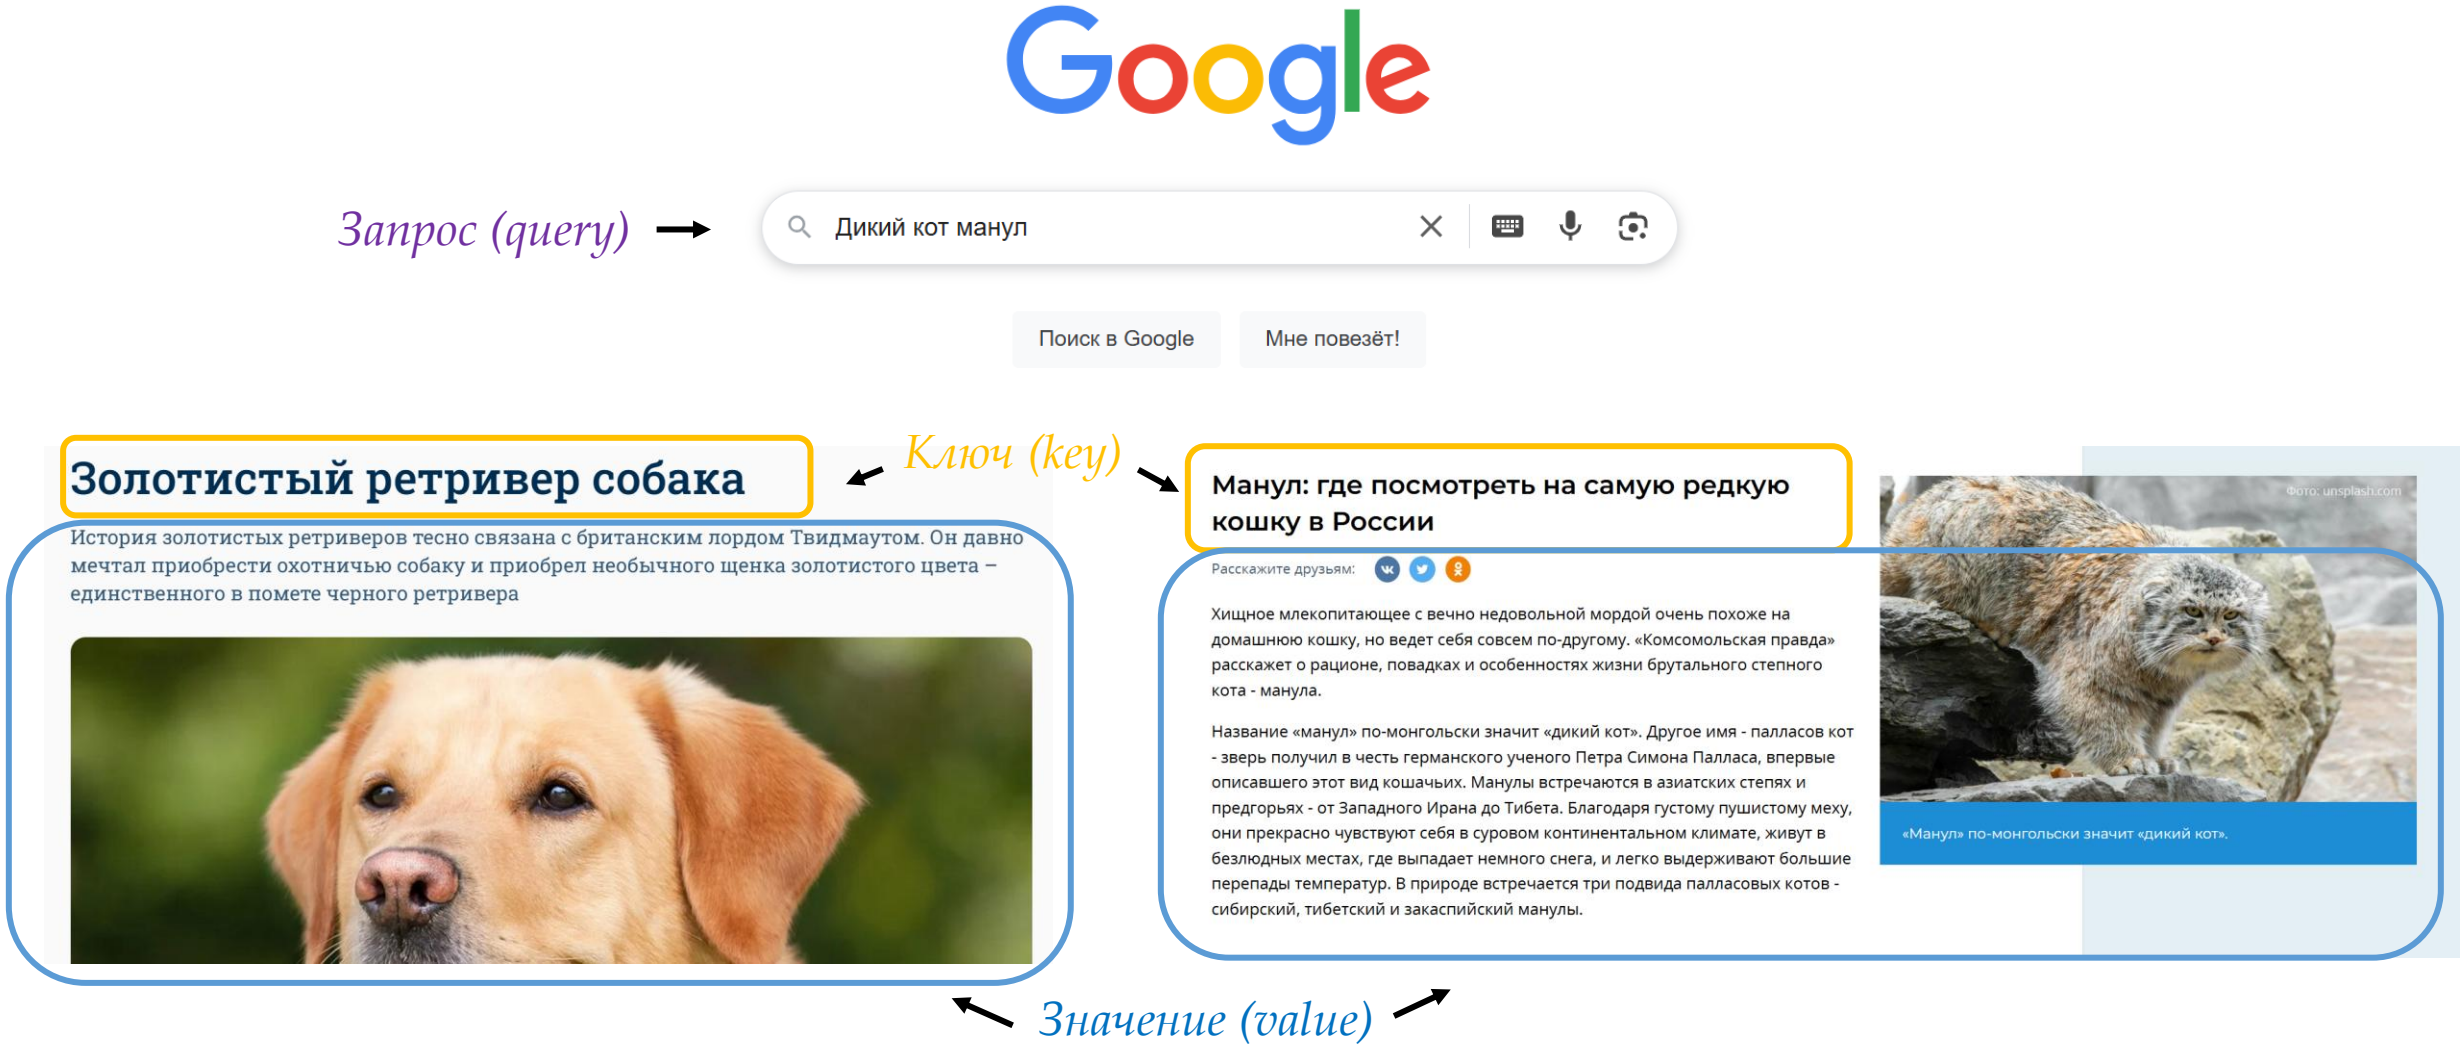

Вектор каждого входного токена представим в трех ипостасях i.e. Queries, Keys, Values

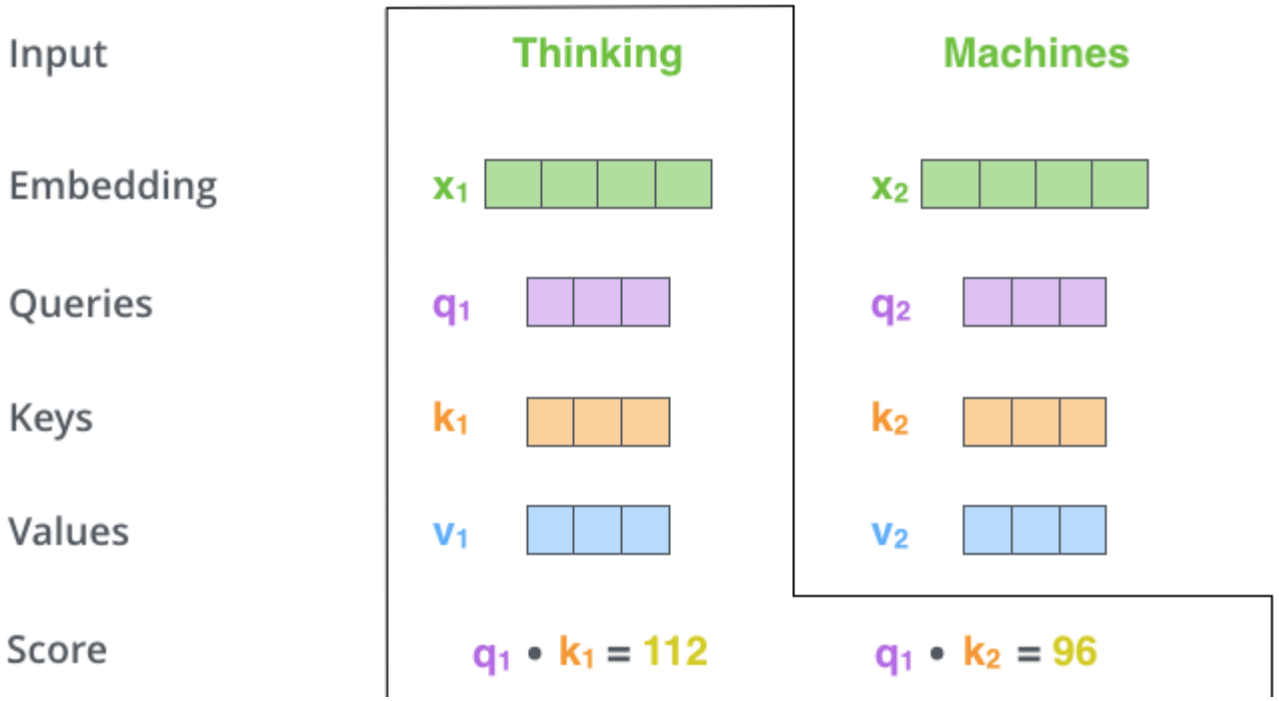


Источник: The Illustrated Transformer by Jay Alammar

Итоговые контекстно-зависимые вектора – значения Values, взвешенные пропорционально близости соответствующих Queries, Keys

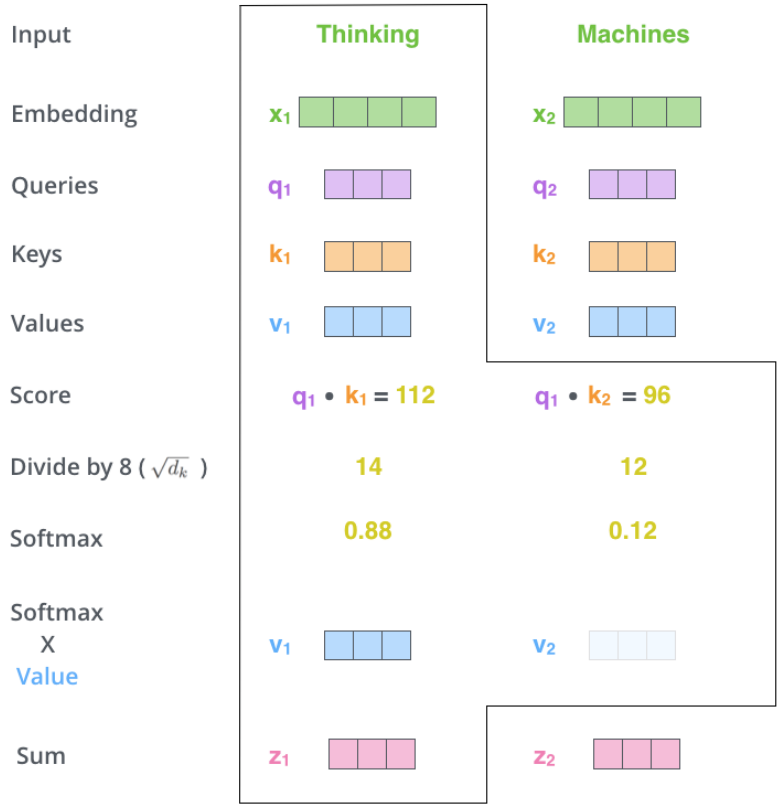


Источник: The Illustrated Transformer by Jay Alammar

Механизм внимания связывает каждый токен с прочими, которые важны для его контекста

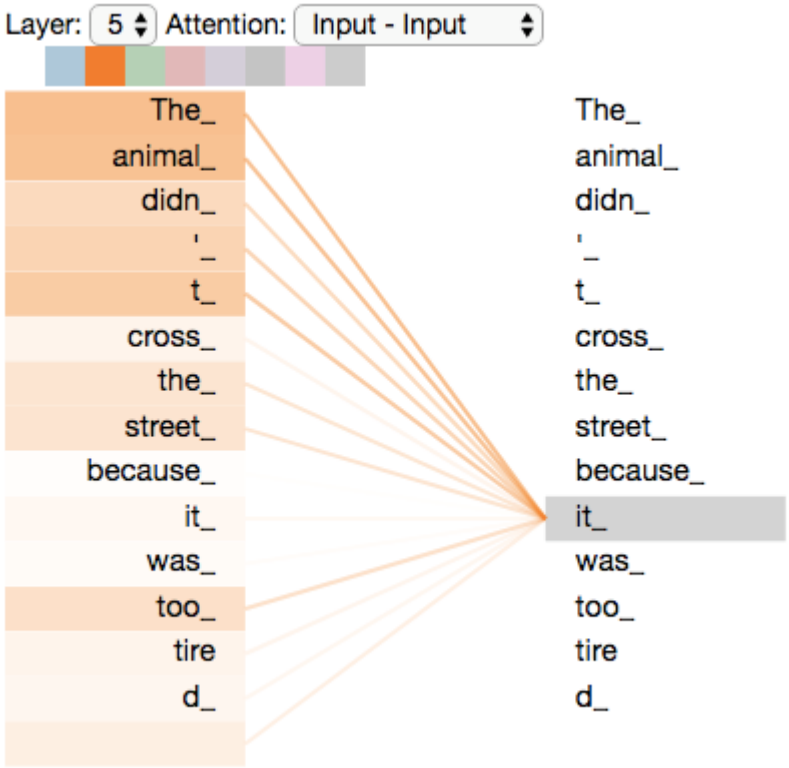


Источник: The Illustrated Transformer by Jay Alammar

Выход из механизма внимания отдается в полносвязные слои

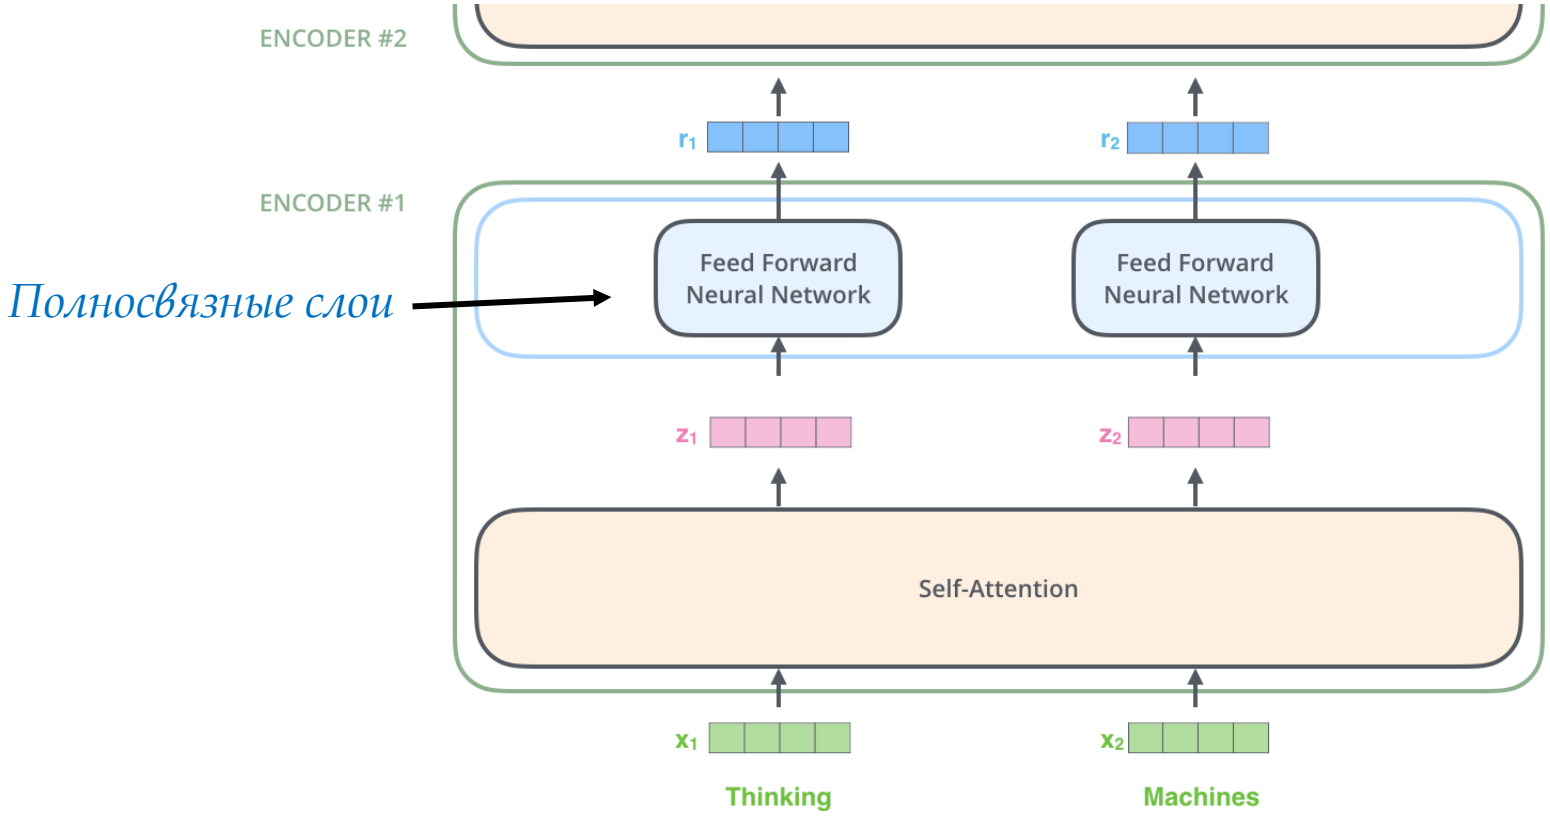


Источник: The Illustrated Transformer by Jay Alammar

Полносвязные слои – архиваторы данных, которые модель видела на этапе обучения

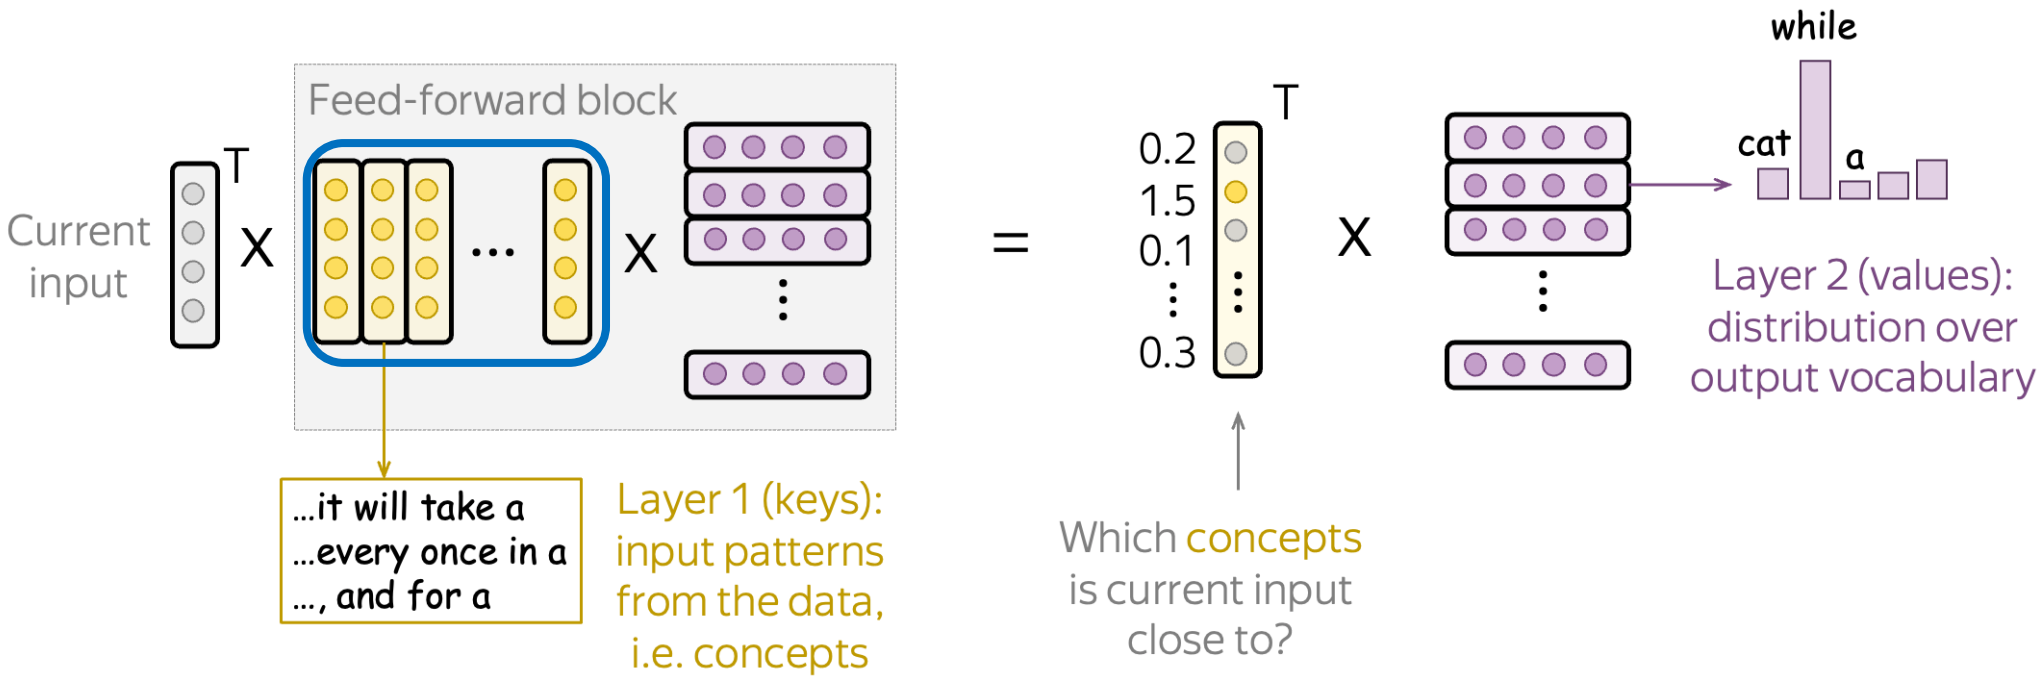


Источник: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

Полносвязные слои – архиваторы данных, которые модель видела на этапе обучения

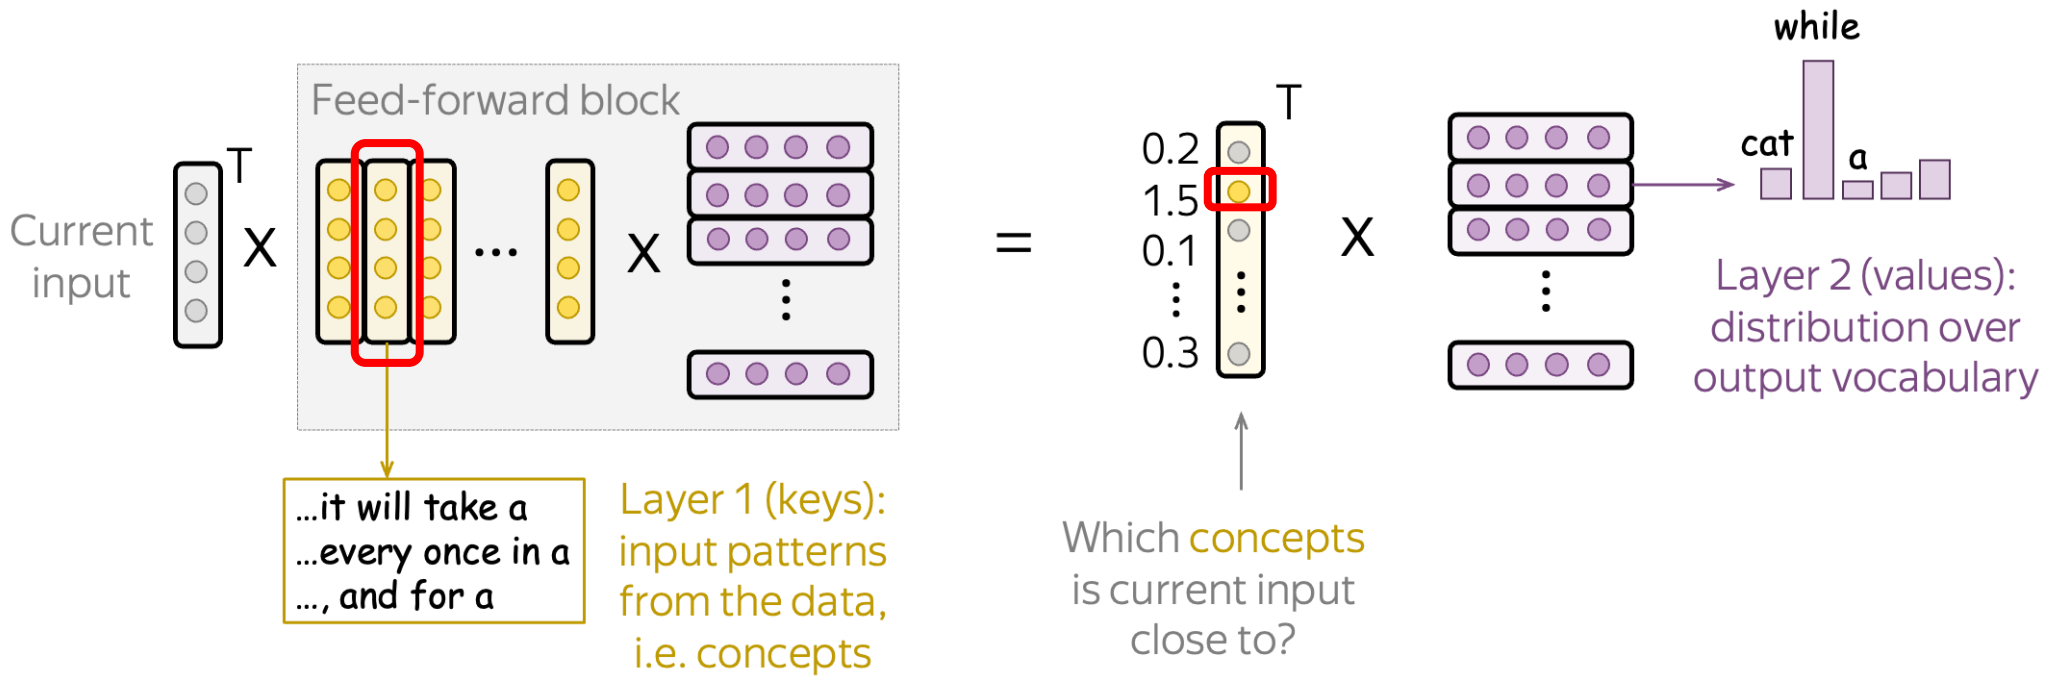


Источник: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

# Еще раз взглянем на архитектуру трансформера

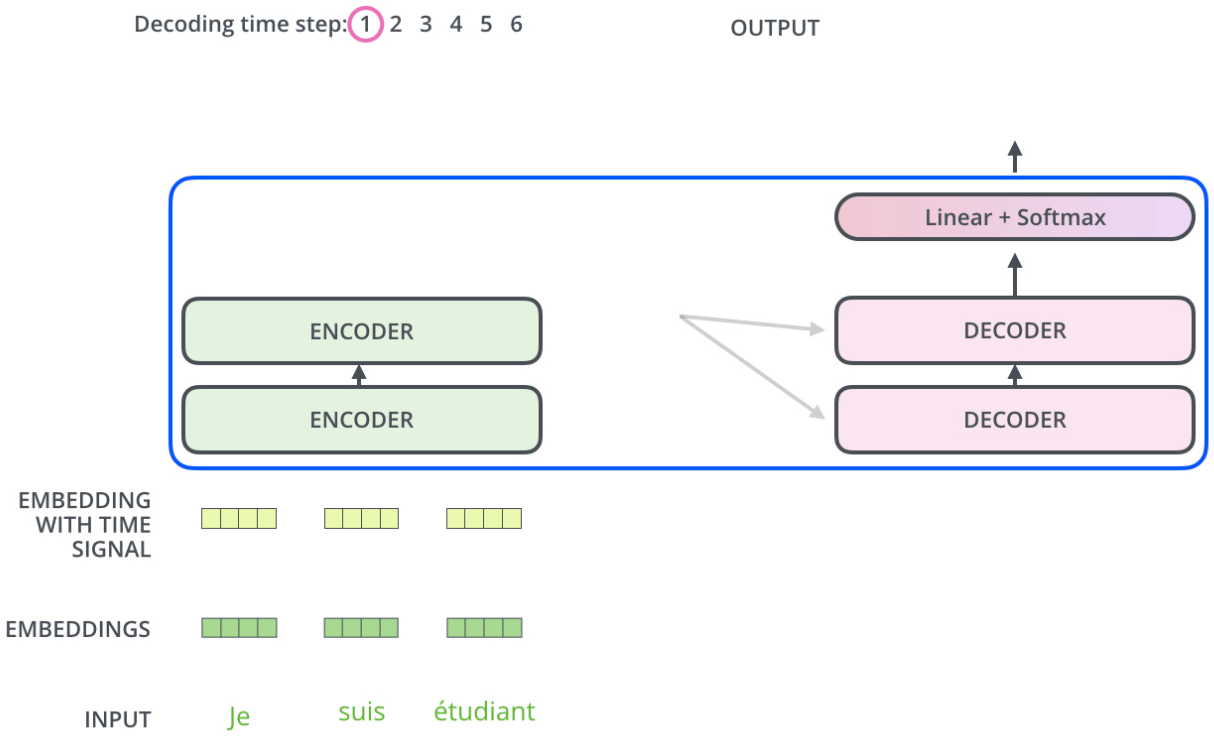


Источник: The Illustrated Transformer by Jay Alammar

# Спасибо за внимание!


## Мурат Хажгериев

CTO @ Pilloai

Приглашенный преподаватель
ФКН ВШЭ

@greedisneutral
makhazhgeriev@gmail.com