Информационный поиск

Мурат Хажгериев

Содержание

- **RAG**
- Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги
- Строим RAG пайплайн
- Приложение

Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос: «Сколько урона у лука в 5й редакции DnD?»

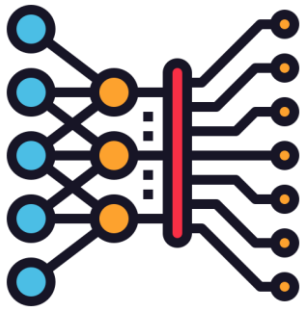

Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос: «Сколько урона у лука в 5й редакции DnD?»

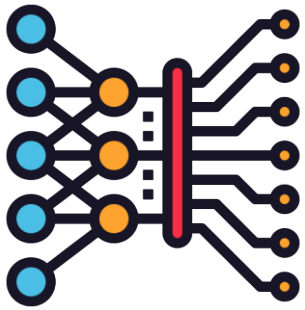

Ответ модели: «Мне не знакомы правила DnD.»

Добавление внешней базы данных позволяет качественно поменять характер модели

Вопрос: «Сколько урона у лука в 5й редакции DnD?»

Контекст: *найденные релевантные факты из базы данных*

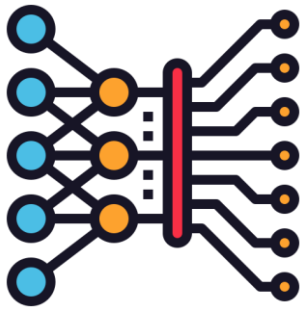

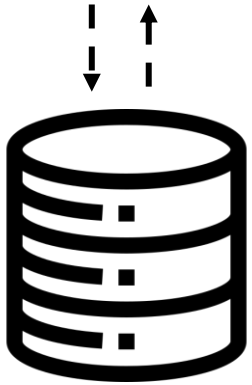

Данные из векторной базы:
«В 5й редакции DnD короткий лук дает 1d4 урона…»

Добавление внешней базы данных позволяет качественно поменять характер модели

Вопрос: «Сколько урона у лука в 5й редакции DnD?»

Контекст: *найденные релевантные факты из базы данных*

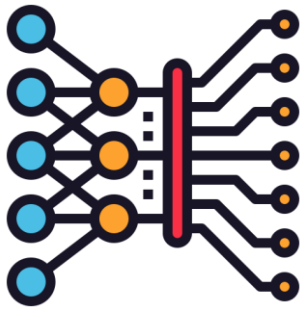

Ответ модели: «5 редакция Dungeons and Dragons предполагает 1d4 урона для короткого лука (плюс модификатор характеристики)»

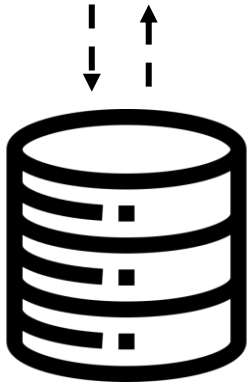

Данные из векторной базы:
«В 5й редакции DnD короткий лук дает 1d4 урона…»

Взгляд на работу пайплайна RAG

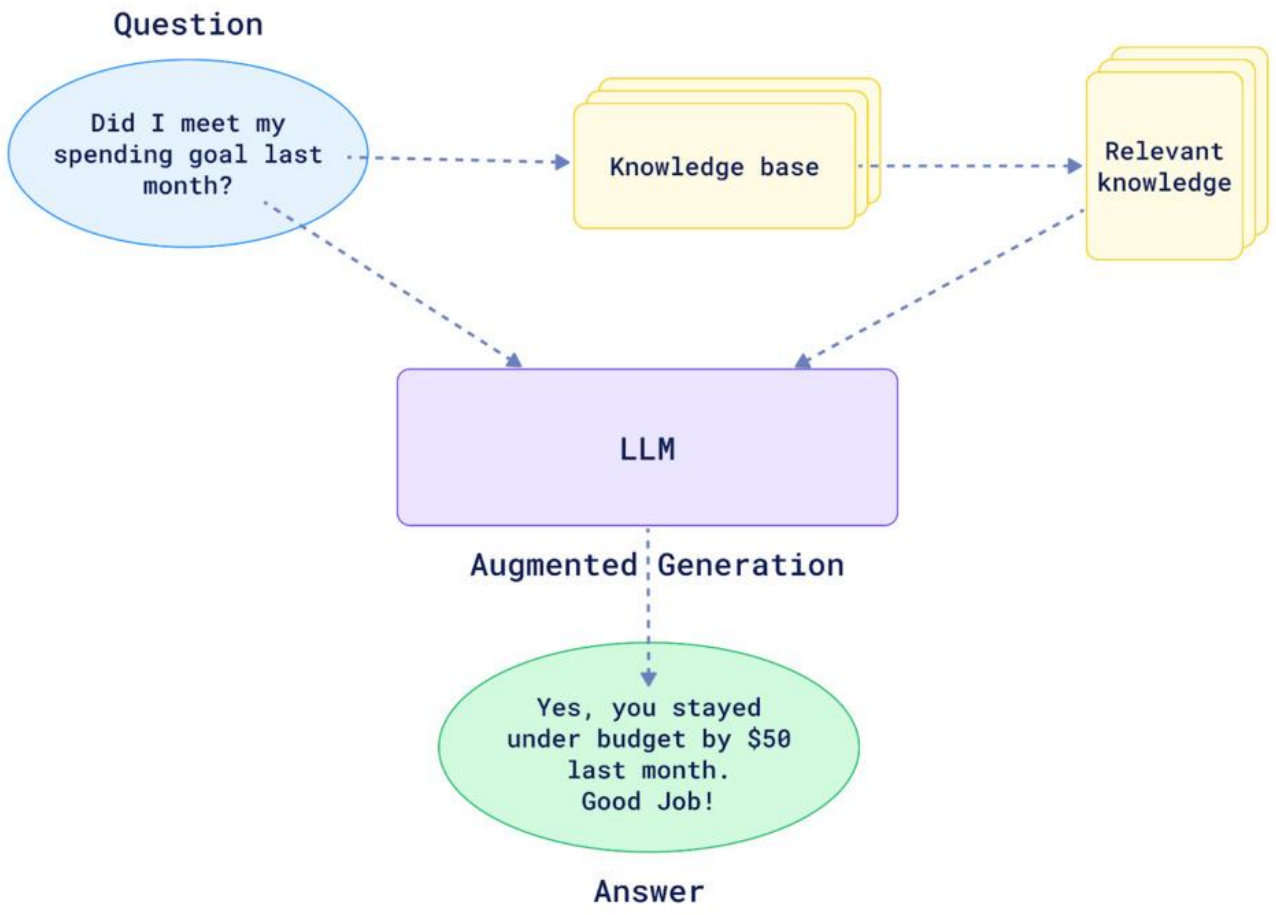

Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: Retriever

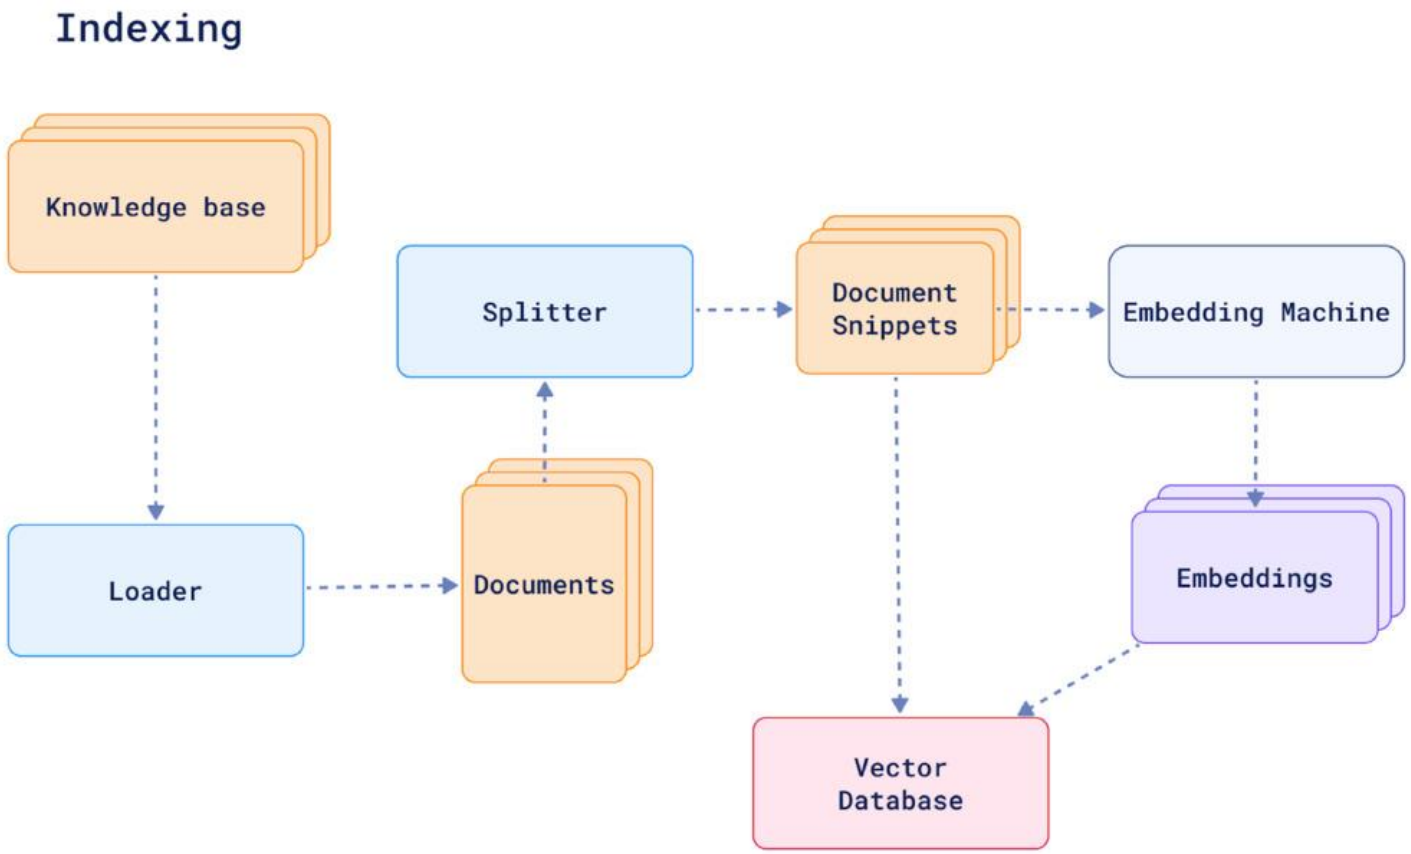

Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: Retriever

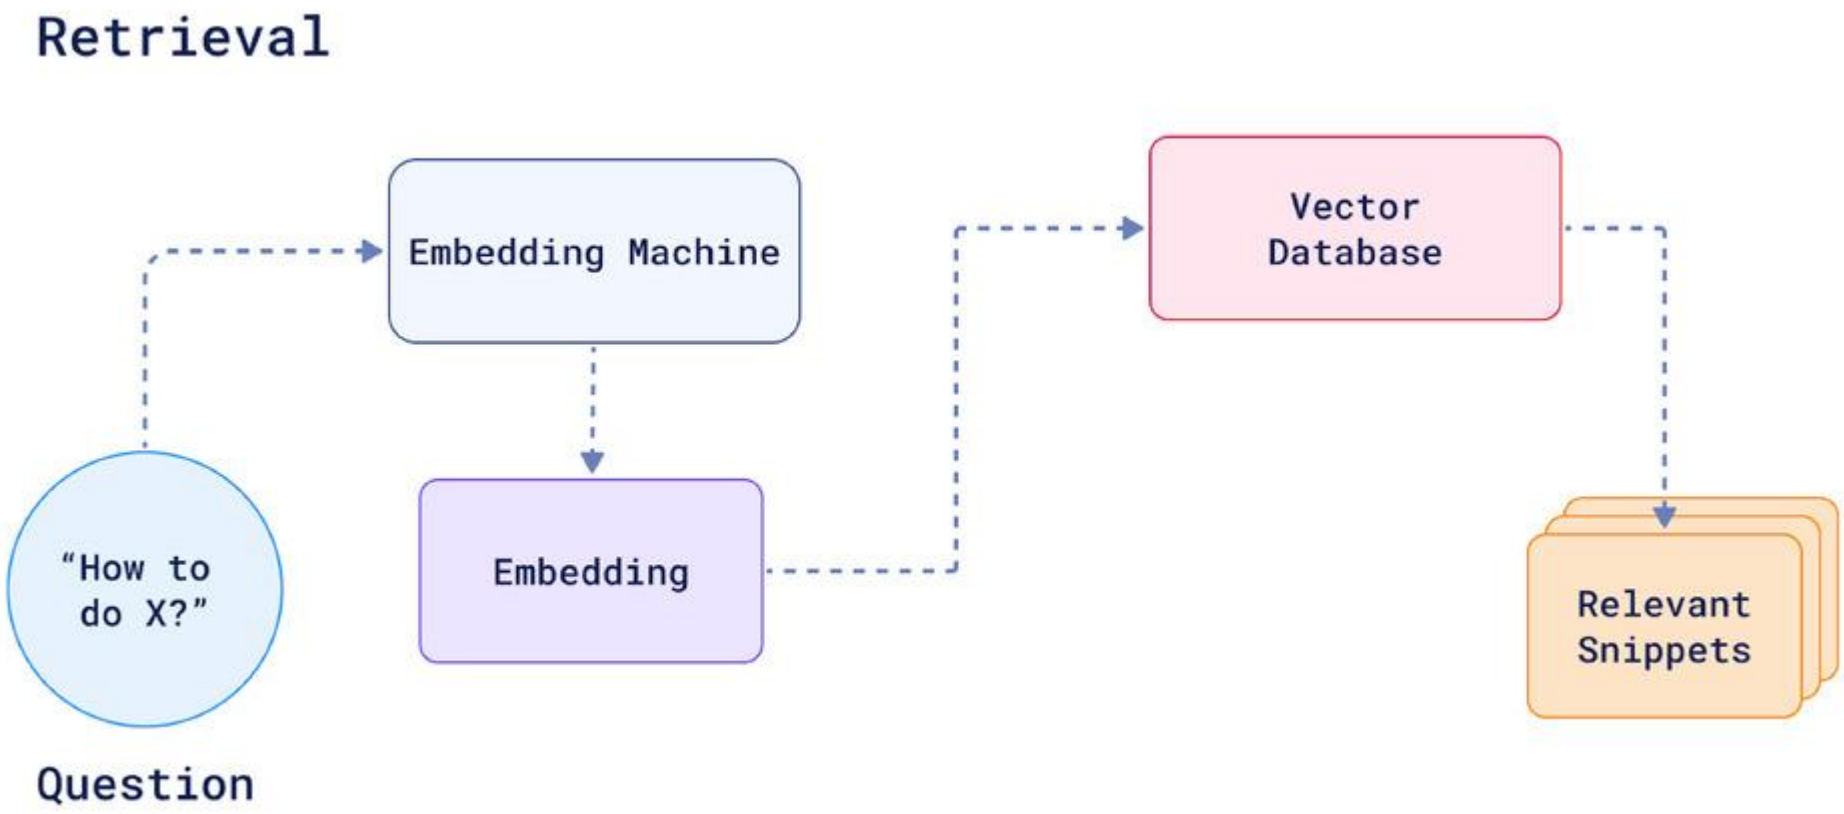

Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: Generator

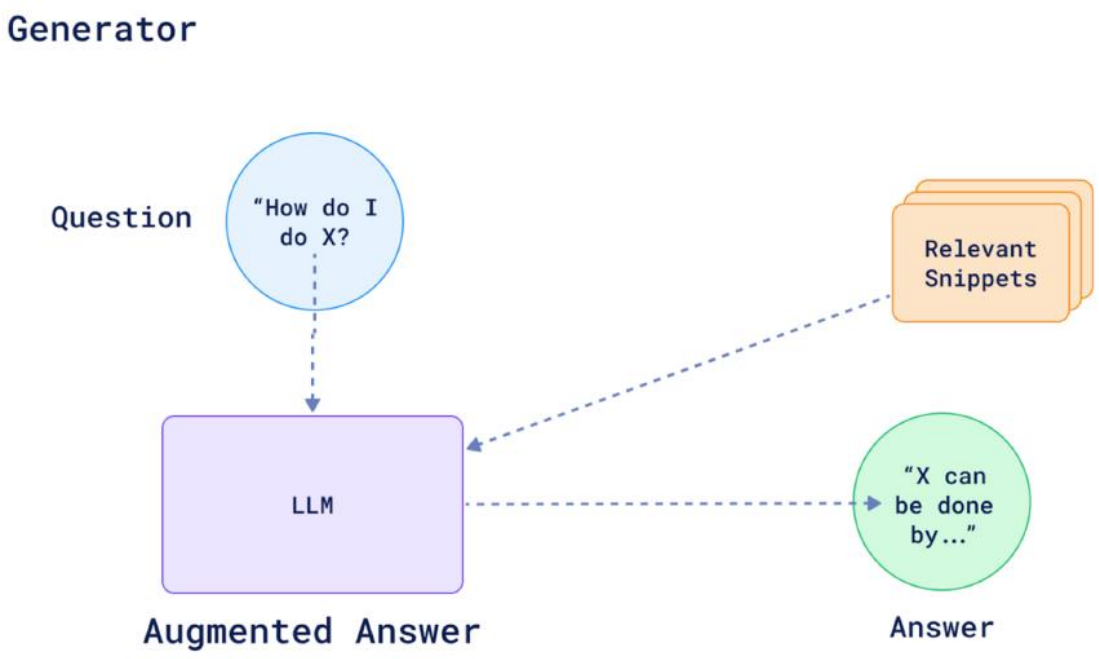

Источник: https://qdrant.tech/articles/what-is-rag-in-ai

RAG Pipeline: собираем вместе

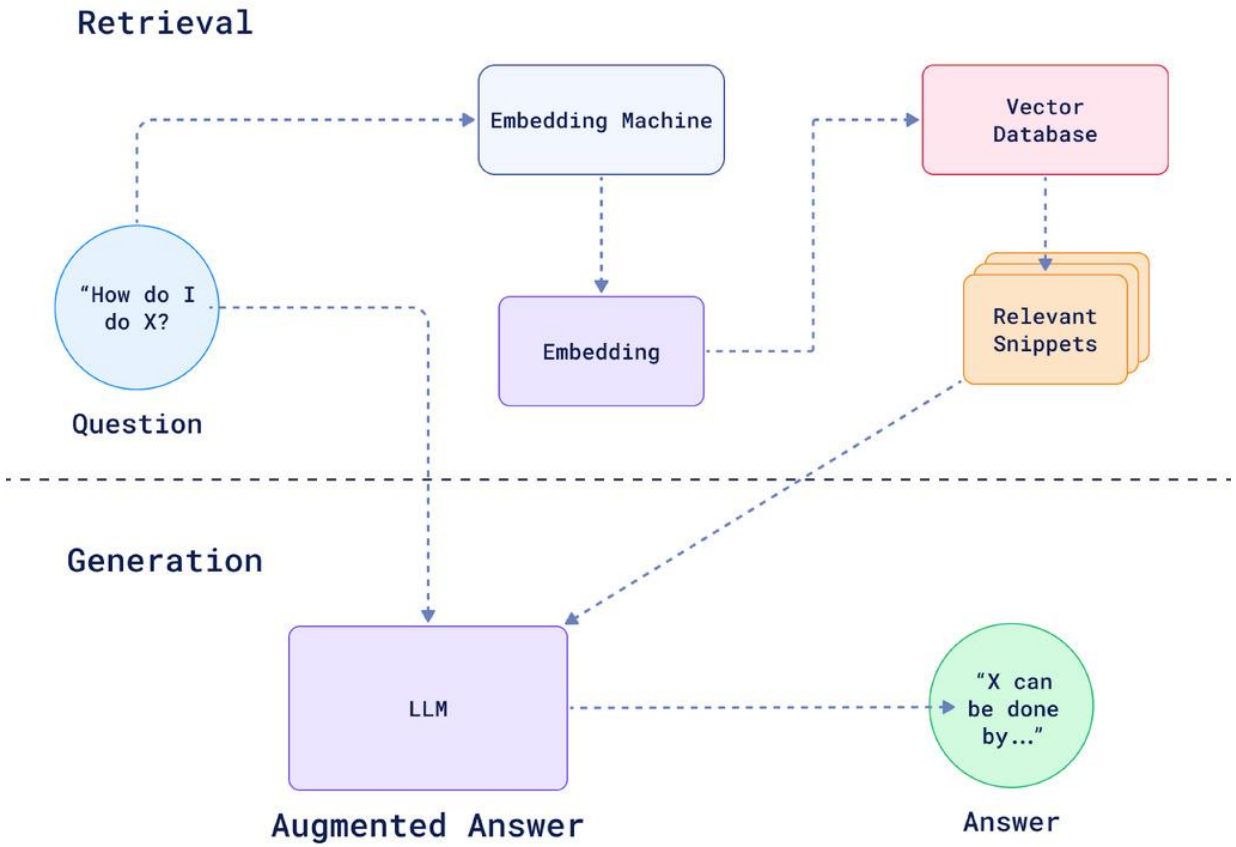

Источник: https://qdrant.tech/articles/what-is-rag-in-ai

На практике релевантные куски данных часто еще раз реранжируются

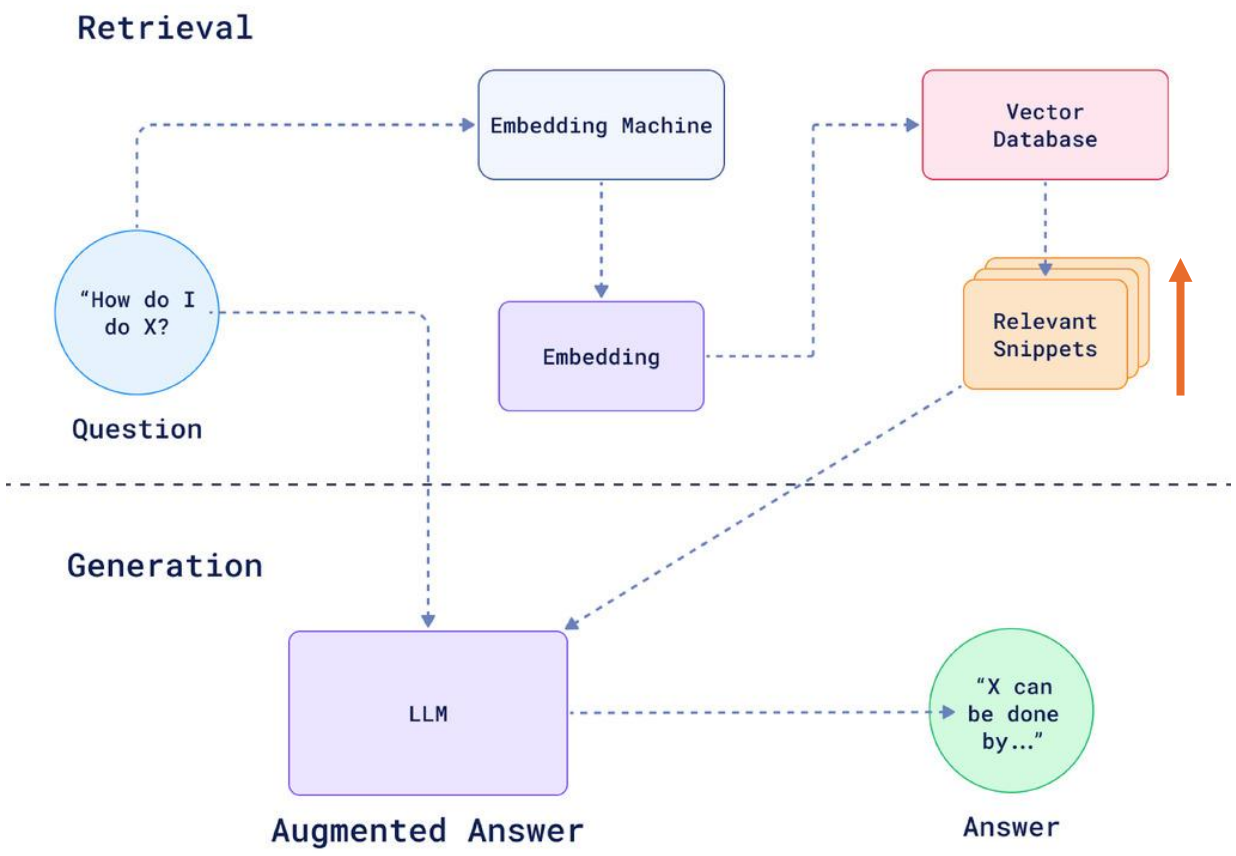

Источник: https://qdrant.tech/articles/what-is-rag-in-ai

Векторные базы данных хранят эмбеддинги объектов

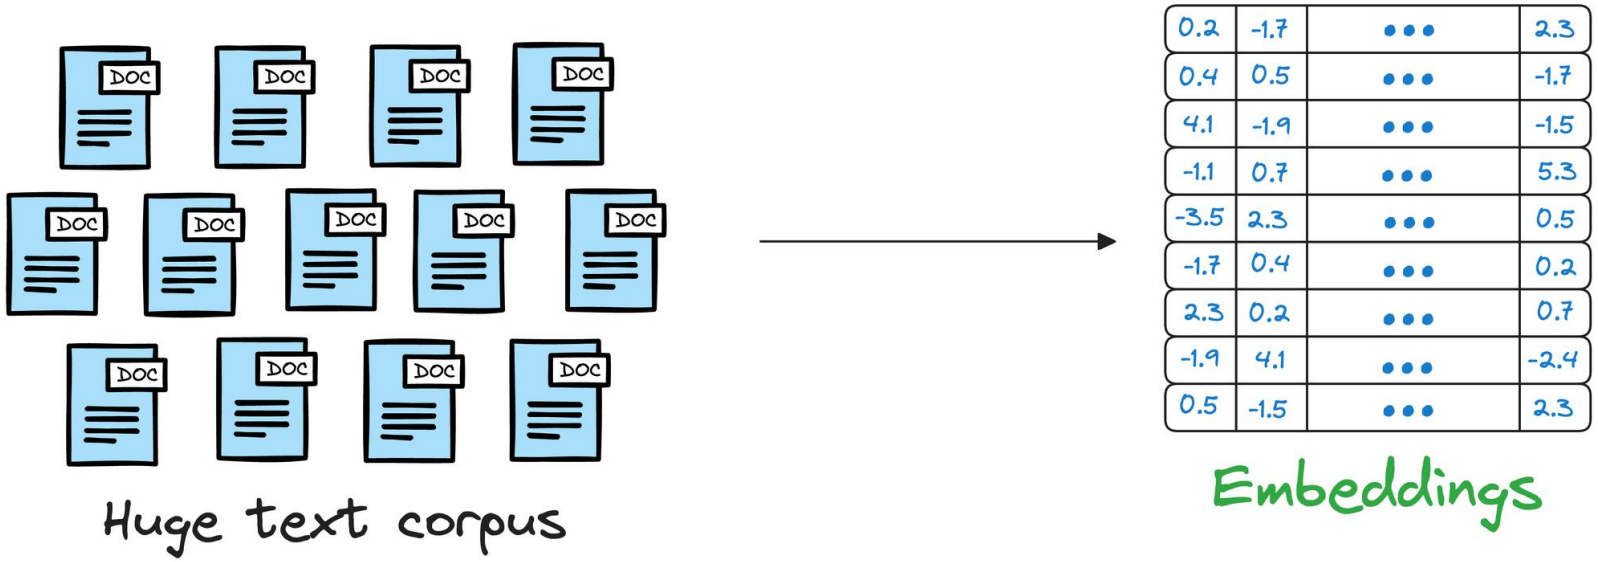

Источник: https://www.dailydoseofds.com/a-beginner-friendly-and-comprehensive-deep-dive-on-vector-databases/

Эмбеддинги генерируются, например, Encoder частью трансформера (BERT)

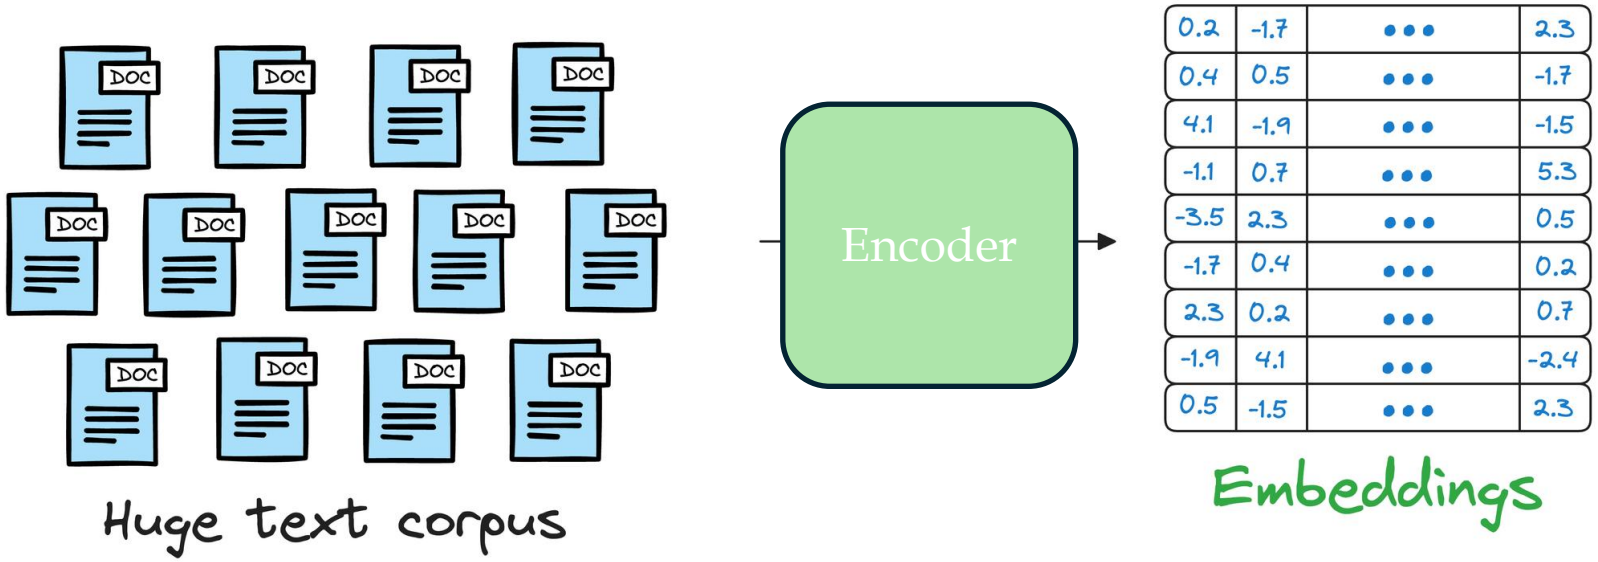

Источник: https://www.dailydoseofds.com/a-beginner-friendly-and-comprehensive-deep-dive-on-vector-databases/

Мы также можем фильтровать объекты в базе данных по тегам

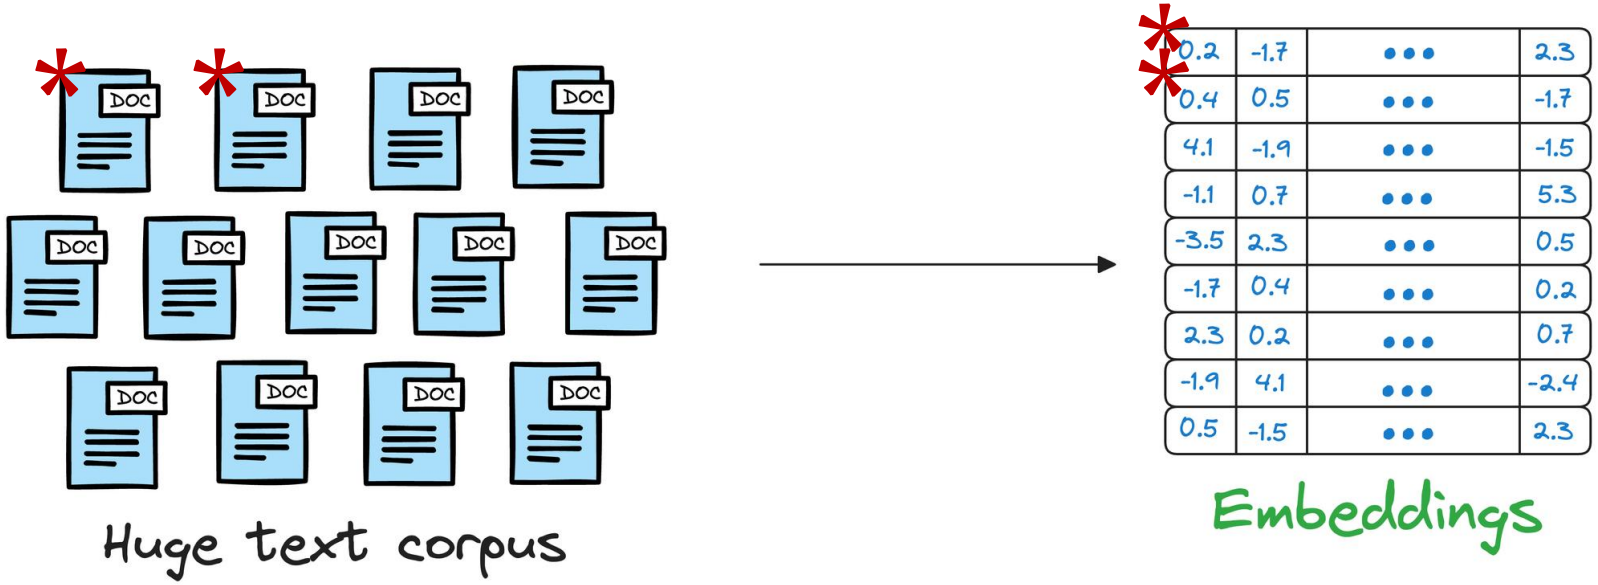

Источник: https://www.dailydoseofds.com/a-beginner-friendly-and-comprehensive-deep-dive-on-vector-databases/

Мы также можем использовать графовые базы данных для обогащения знания

Источник: https://blog.langchain.com/enhancing-rag-based-applications-accuracy-by-constructing-and-leveraging-knowledge-graphs/

Устройство Graph RAG

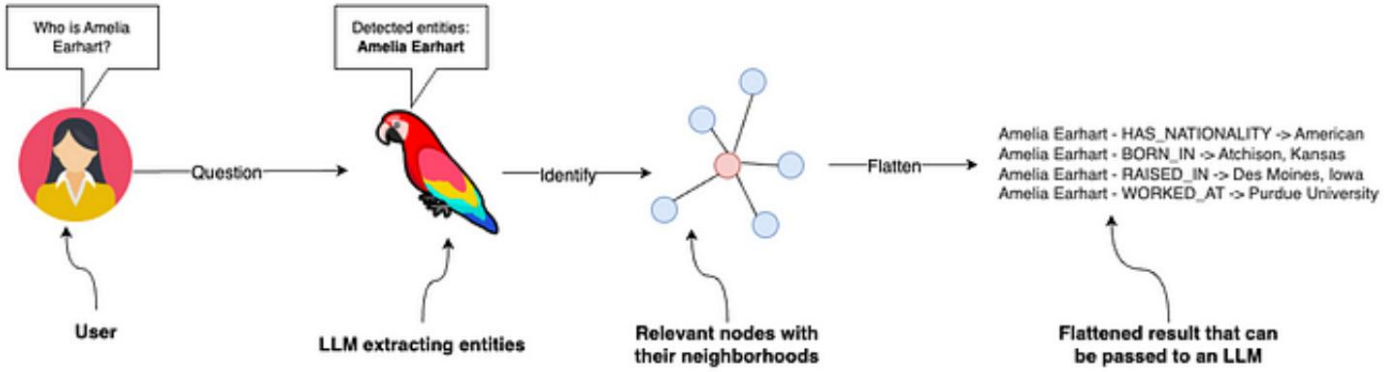

Источник: https://blog.langchain.com/enhancing-rag-based-applications-accuracy-by-constructing-and-leveraging-knowledge-graphs/

Мы можем объединять информацию из разных типов баз данных вместе

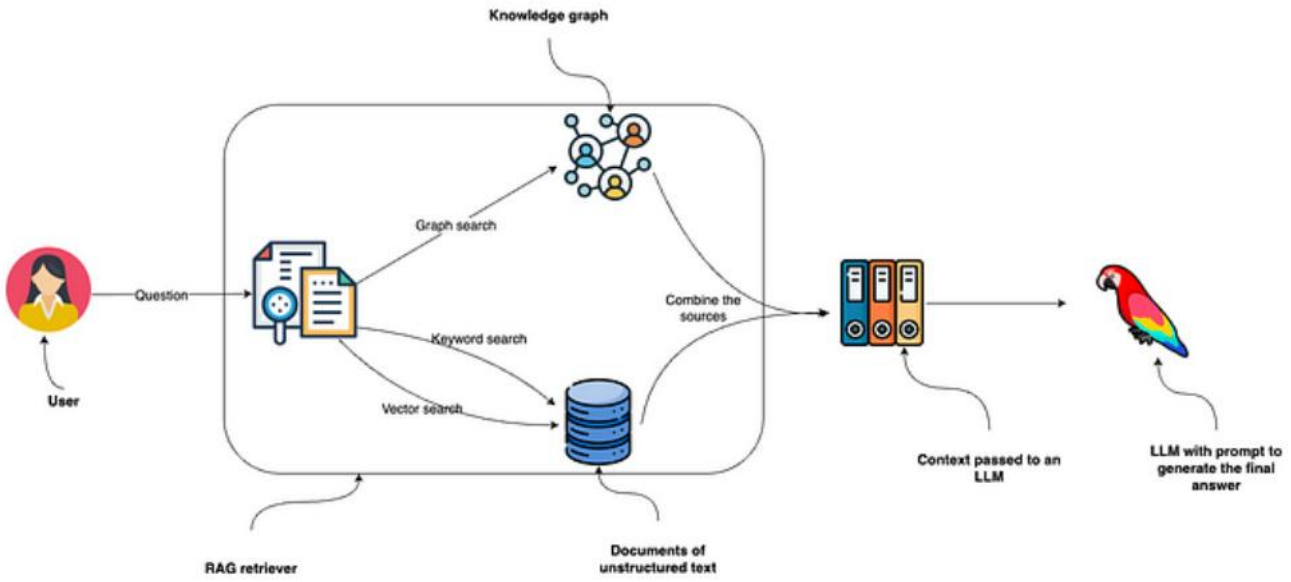

Источник: https://blog.langchain.com/enhancing-rag-based-applications-accuracy-by-constructing-and-leveraging-knowledge-graphs/

Содержание

- RAG
- **Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги**
- Строим RAG пайплайн
- Приложение

Энкодер генерирует контекстно-зависимые вектора для каждого входного токена

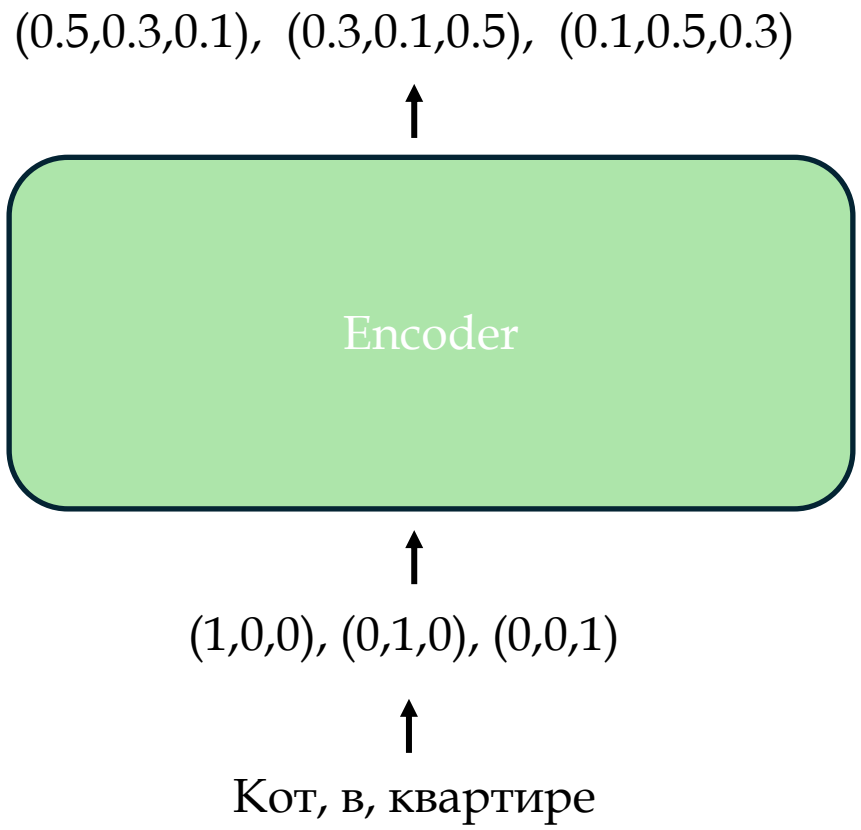

Мы можем получить вектор входной последовательности, например, аггрегировав вектора-выходы энкодера

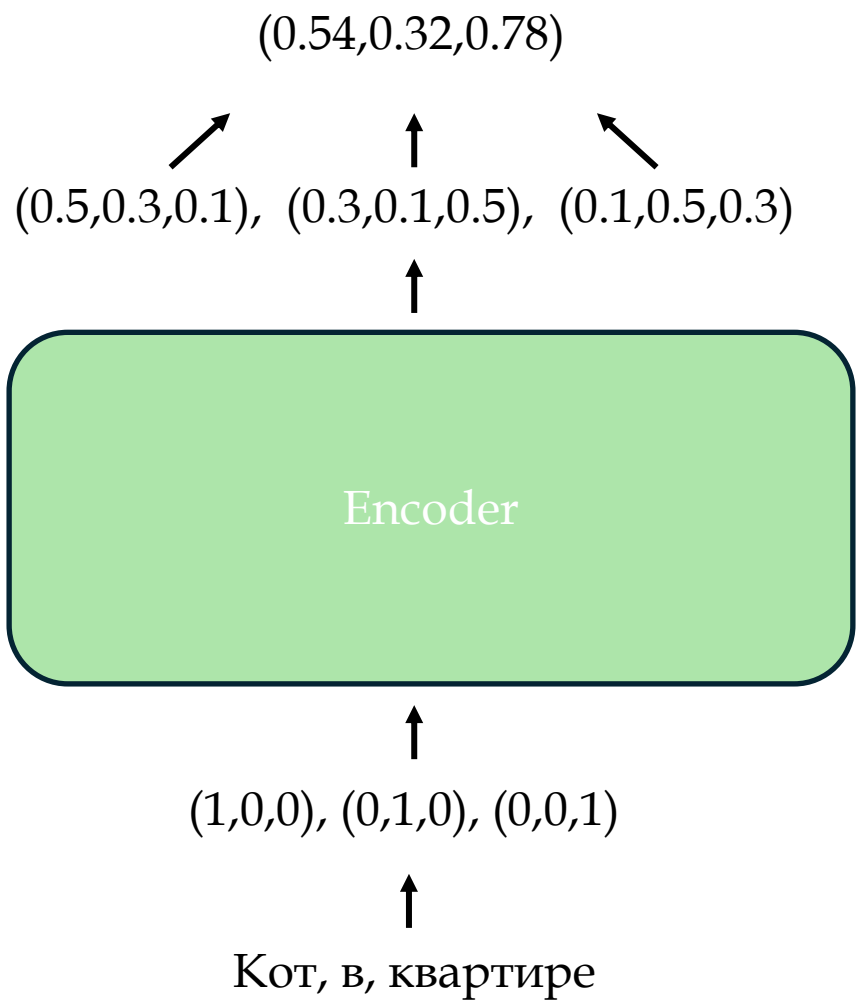

Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.

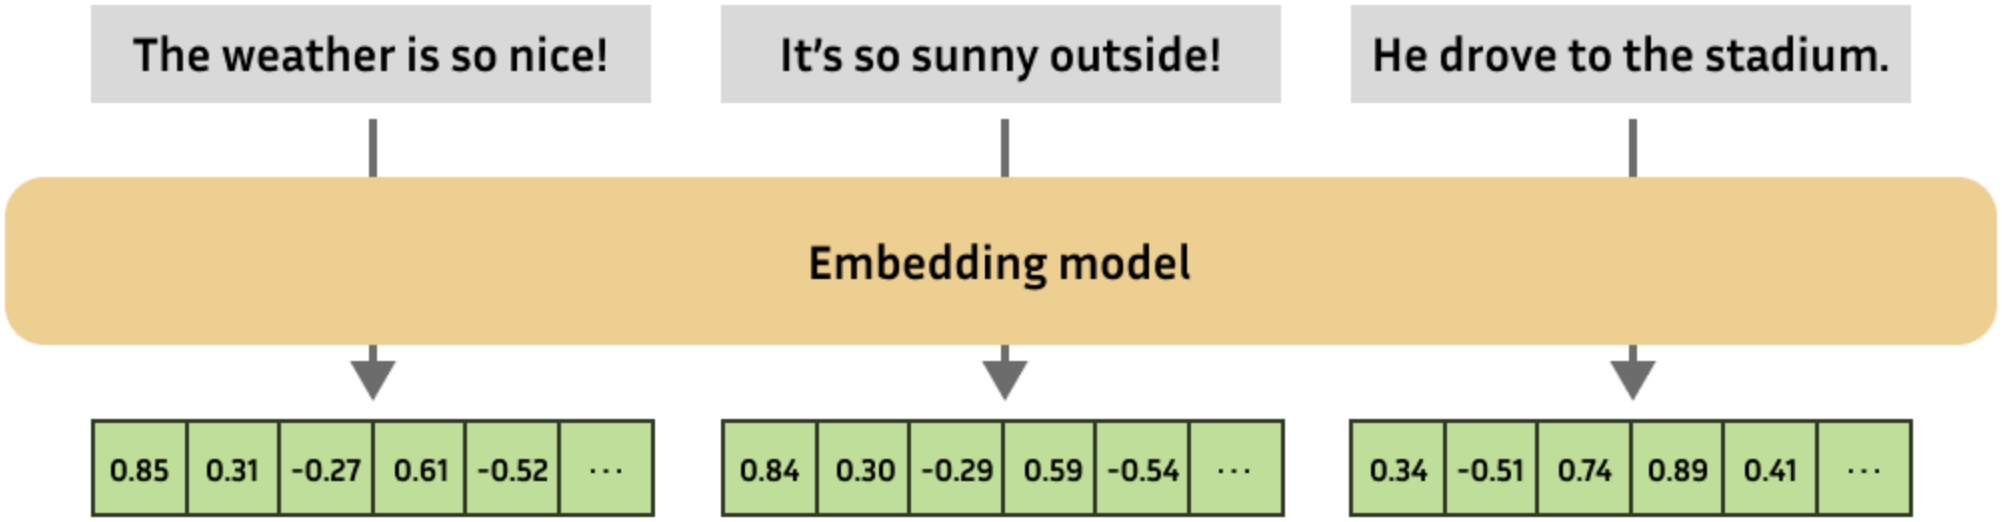

Источник: https://huggingface.co/blog/matryoshka

Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.

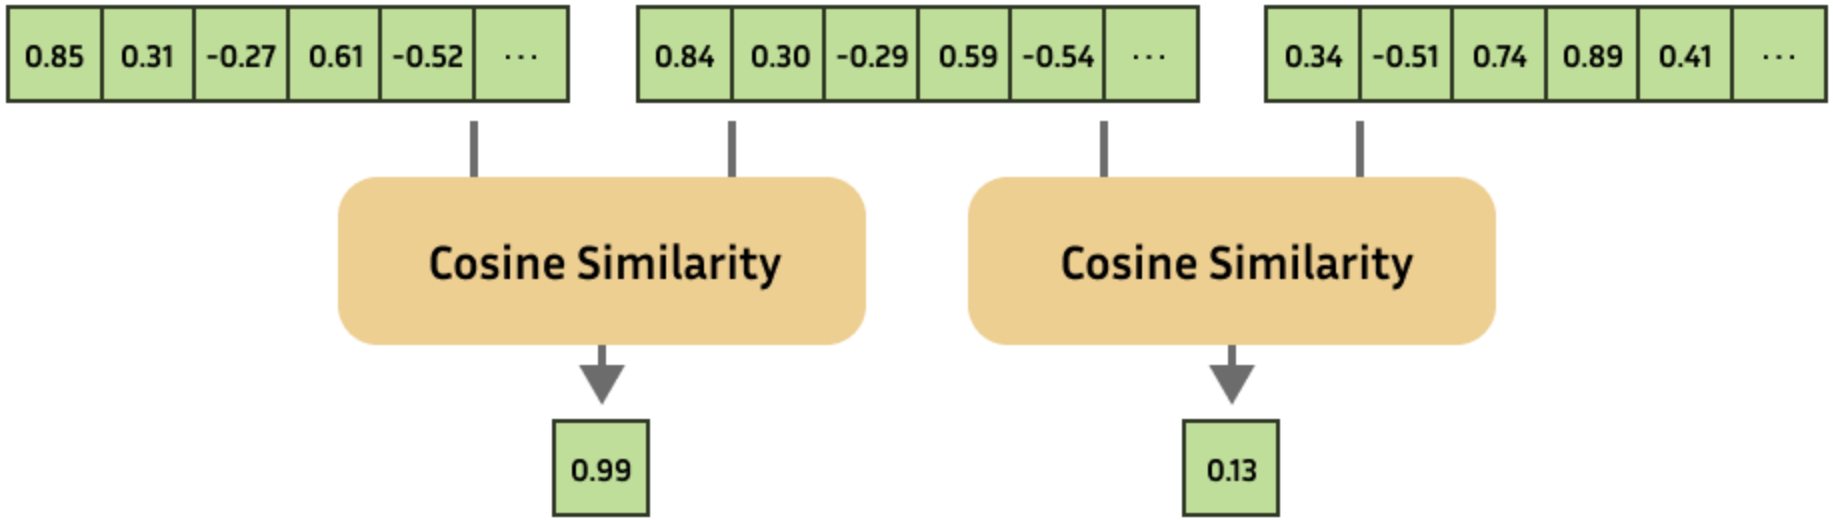

Источник: https://huggingface.co/blog/matryoshka

Другой подход - обрабатывать вход парами (Cross-Encoder)

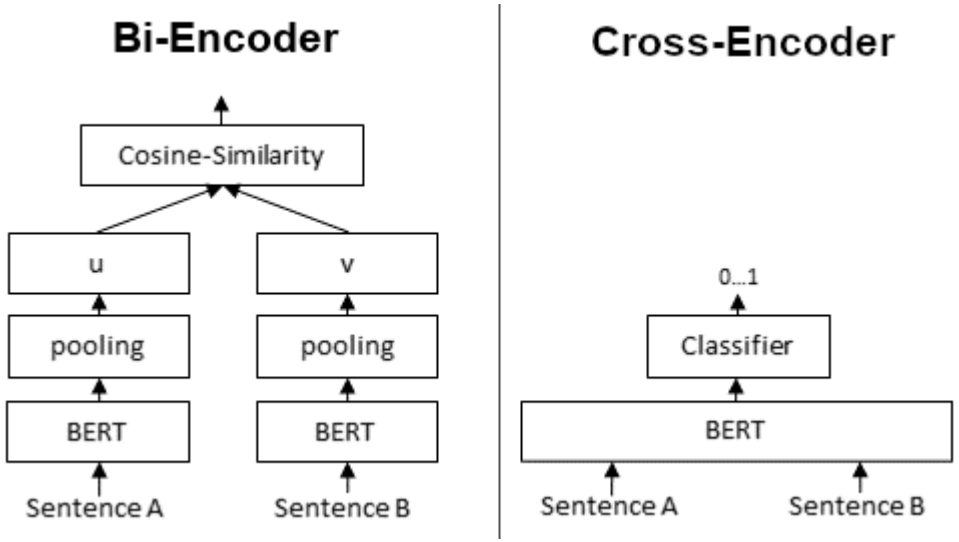

Источник: https://sbert.net/examples/cross_encoder/applications/README.html

Обучаем с помощью Contrastive Loss

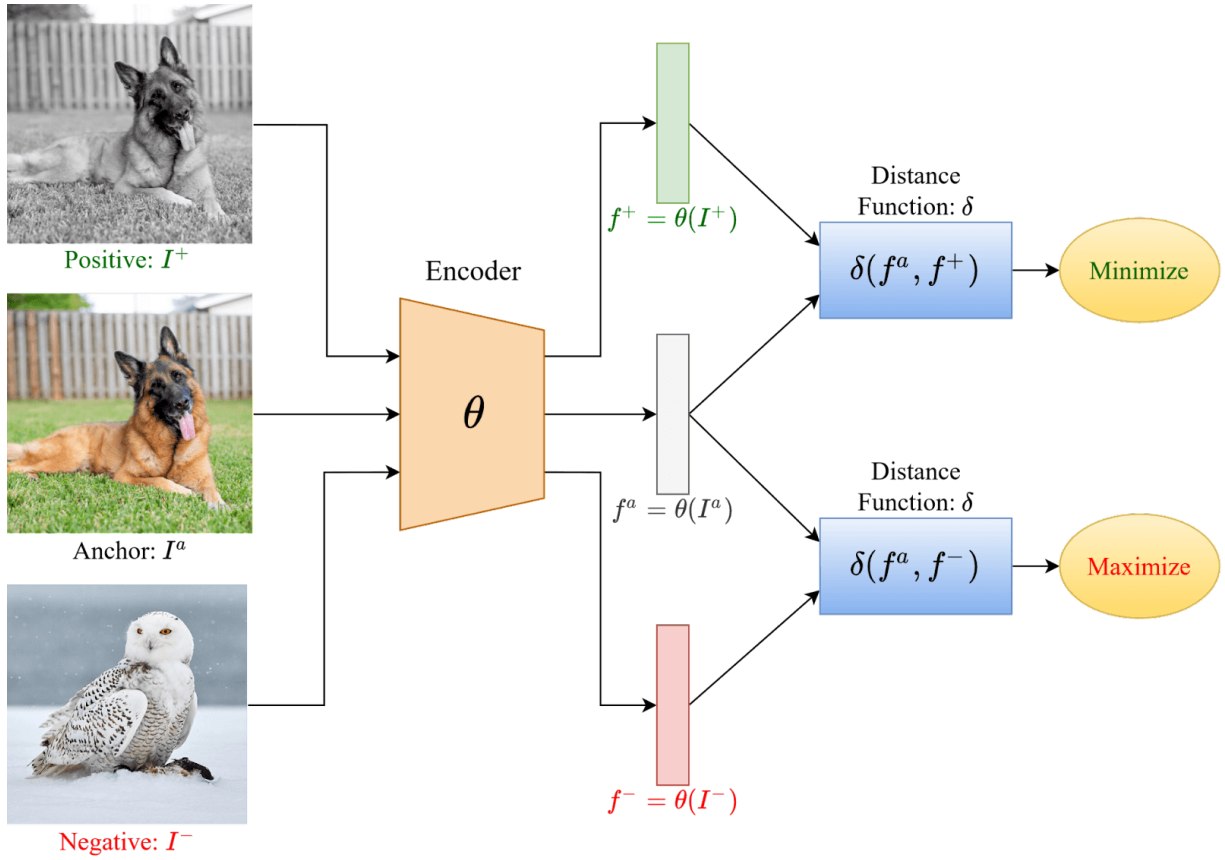

InfoNCE / Multiple Negatives Ranking Loss

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(q, d^+)/\tau)}{\exp(\text{sim}(q, d^+)/\tau) + \sum_{i=1}^{K} \exp(\text{sim}(q, d_i^-)/\tau)}$$

$$\text{Batch:} \begin{cases} query_0 : doc_0 \\ q_3 : doc_1 \\ q_1 : doc_2 \\ q_2 : doc_3 \end{cases}$$

$$\overset{+}{\longleftrightarrow}$$

$$q_0 : doc_0$$

$$\underbrace{q_0 : doc_{1..s}}_{-}$$

Современные архитектуры для задачи similarity search обучаются в парадигме Matryoshka

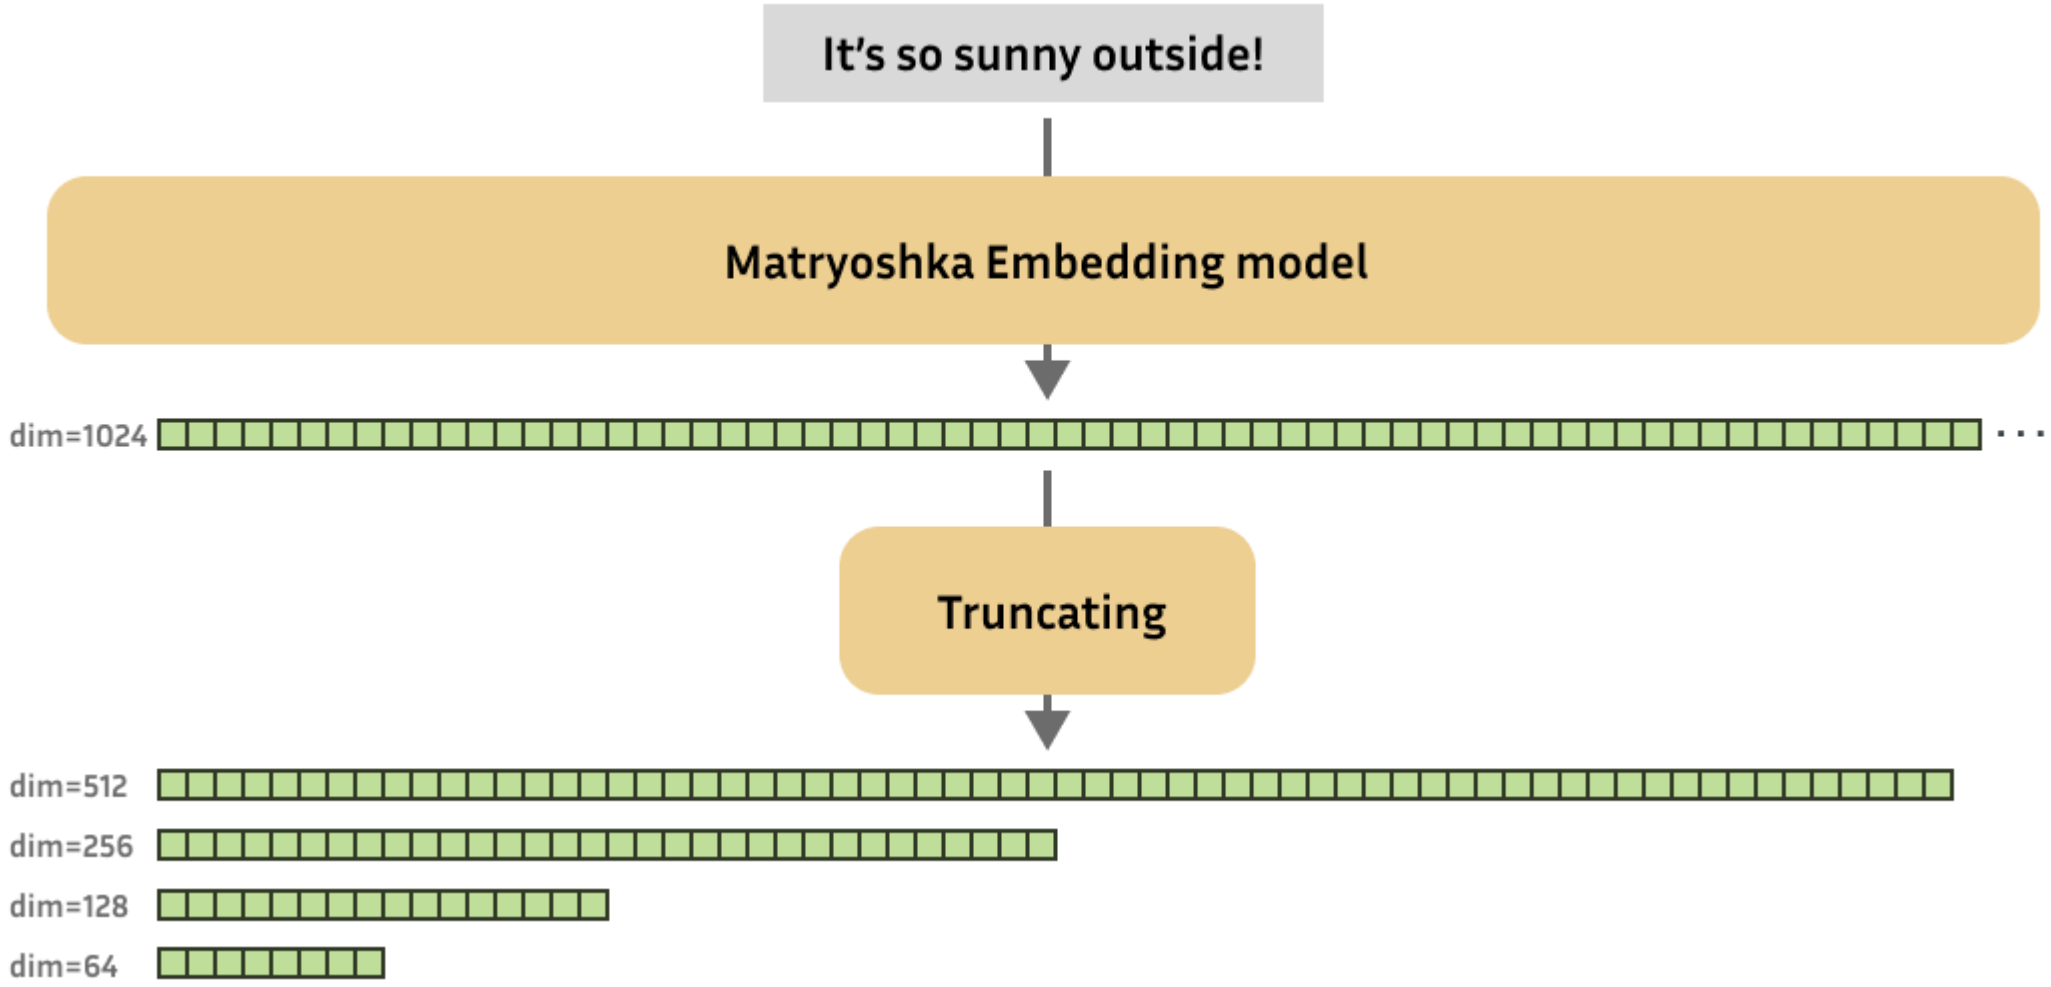

Источник: https://huggingface.co/blog/matryoshka

Содержание

- RAG
- Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги
- **Строим RAG пайплайн**
- Приложение

Пример эффективного RAG пайплайна (зависит от вашего домена)

Этап 0: retrieval

Sparse: Ключевые слова/BM25/BGE

Dense: Матрешка (малая размерность)

Этап 1: retrieval

Dense: Матрешка (большая размерность)

Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$

Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

Sort documents by score

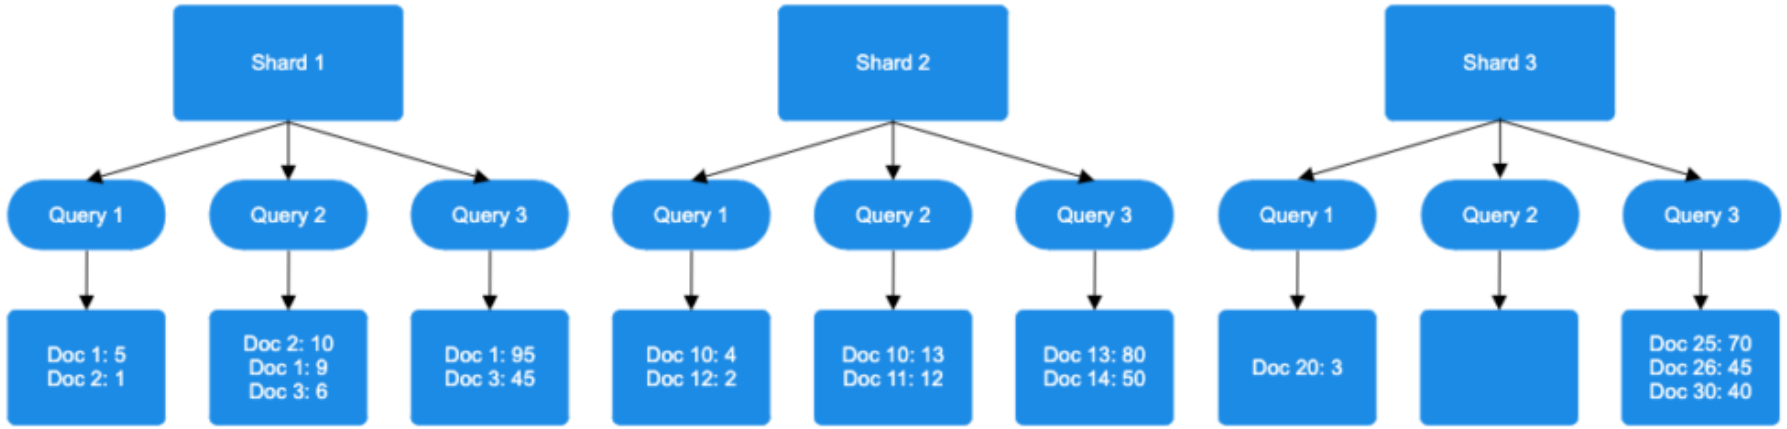

Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

Assign rank positions

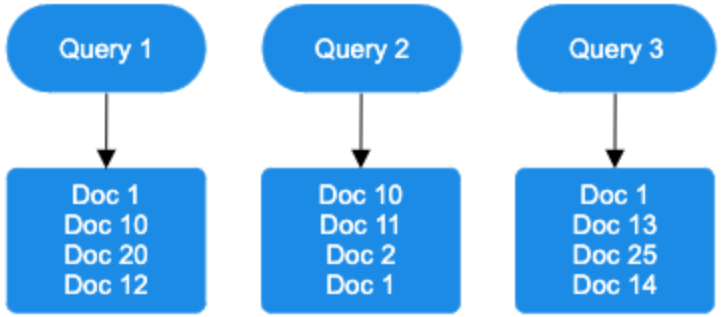

Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

Apply the RRF formula

$$RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$$

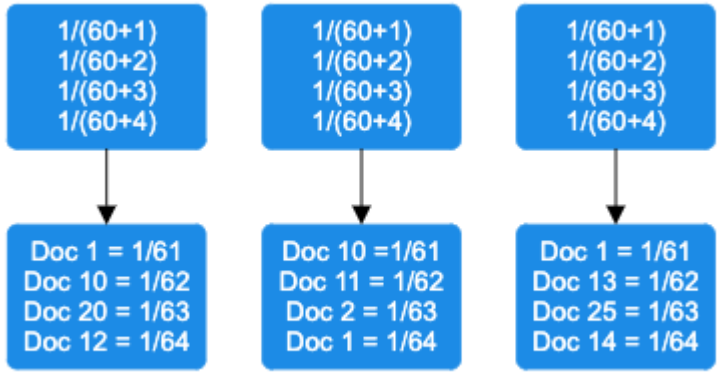

Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

Add rank contributions, Return the top results

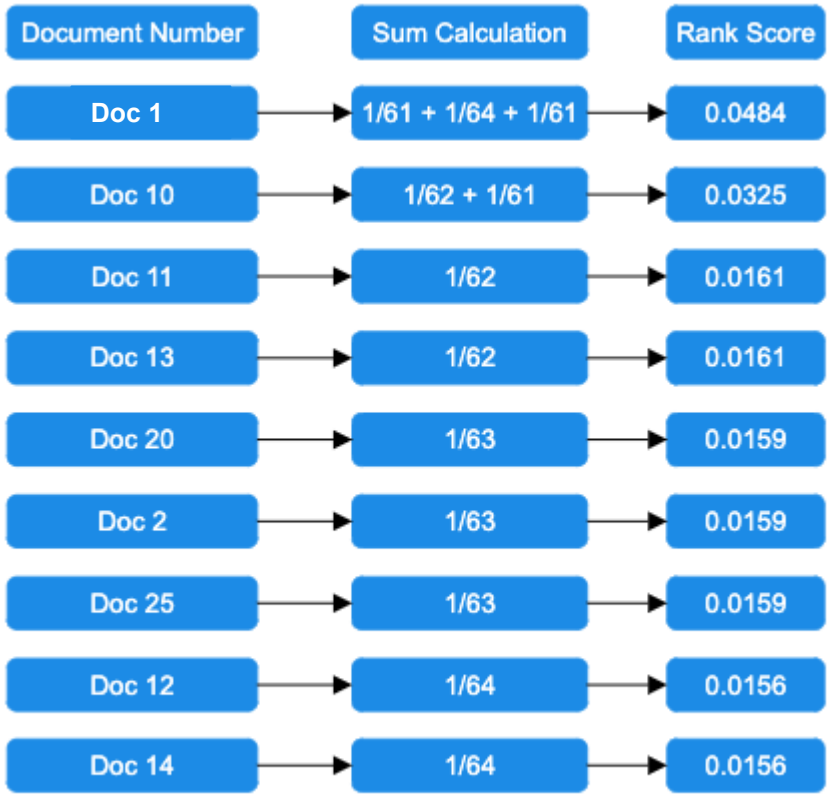

Источник: https://opensearch.org/blog/introducing-reciprocal-rank-fusion-hybrid-search/

Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$
- Cross-Encoder

Источник: https://en.wikipedia.org/wiki/Okapi_BM25

Пример эффективного RAG пайплайна (зависит от вашего домена)

Этап 0: retrieval

Sparse: Ключевые слова/BM25/BGE

Dense: Матрешка (малая размерность)

Этап 1: retrieval

Dense: Матрешка (большая размерность)

Этап 2: Reranking

Cross-Encoder

Содержание

- RAG
- Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги
- Строим RAG пайплайн
- **Приложение**

Содержание

- RAG
- Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги
- Строим RAG пайплайн
- Приложение
  - **Как я могу этому доверять?**
  - Matryoshka Embeddings Loss
  - BM25

Как померить качество?

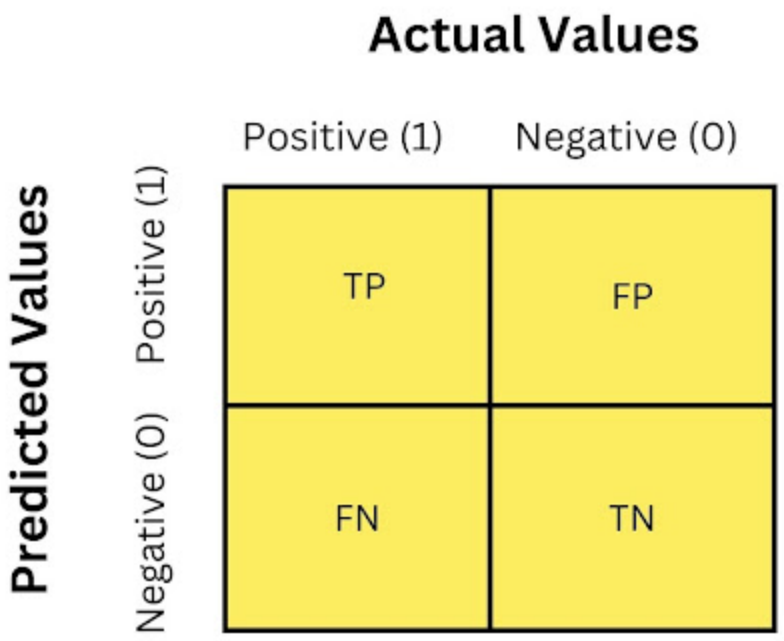

Precision, Recall

$$\text{Precision at } K = \frac{\text{Number of relevant items in } K}{\text{Total number of items in } K}$$

$$\text{Recall at } K = \frac{\text{Number of relevant items in } K}{\text{Total number of relevant items}}$$

Источник: https://www.evidentlyai.com/ranking-metrics/precision-recall-at-k

Mean Average Precision (MAP)

$$\text{MAP@K} = \frac{1}{U} \sum_{u=1}^{U} \text{AP@K}_u$$

Источник: https://www.evidentlyai.com/ranking-metrics/mean-average-precision-map

Mean Average Precision (MAP)

Rank	Item	Precision@k
1		1/1 = 1
2		1/2 = 0.5
3		1/3 = 0.33
4		2/4 = 0.5
5		3/5 = 0.6
6		3/6 = 0.5

Average precision

$$AP@6 = \frac{1 + 0.5 + 0.6}{3} = 0.7$$

Not relevant Relevant

Источник: https://www.evidentlyai.com/ranking-metrics/mean-average-precision-map

Mean Reciprocal Rank (MRR)

$$\text{MRR} = \frac{1}{U} \sum_{u=1}^{U} \frac{1}{rank_i}$$

Источник: https://www.evidentlyai.com/ranking-metrics/mean-average-precision-map

Normalized Discounted Cumulative Gain (NDCG)

$$\text{CG@K} = \sum_{k=1}^{K} G_i$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

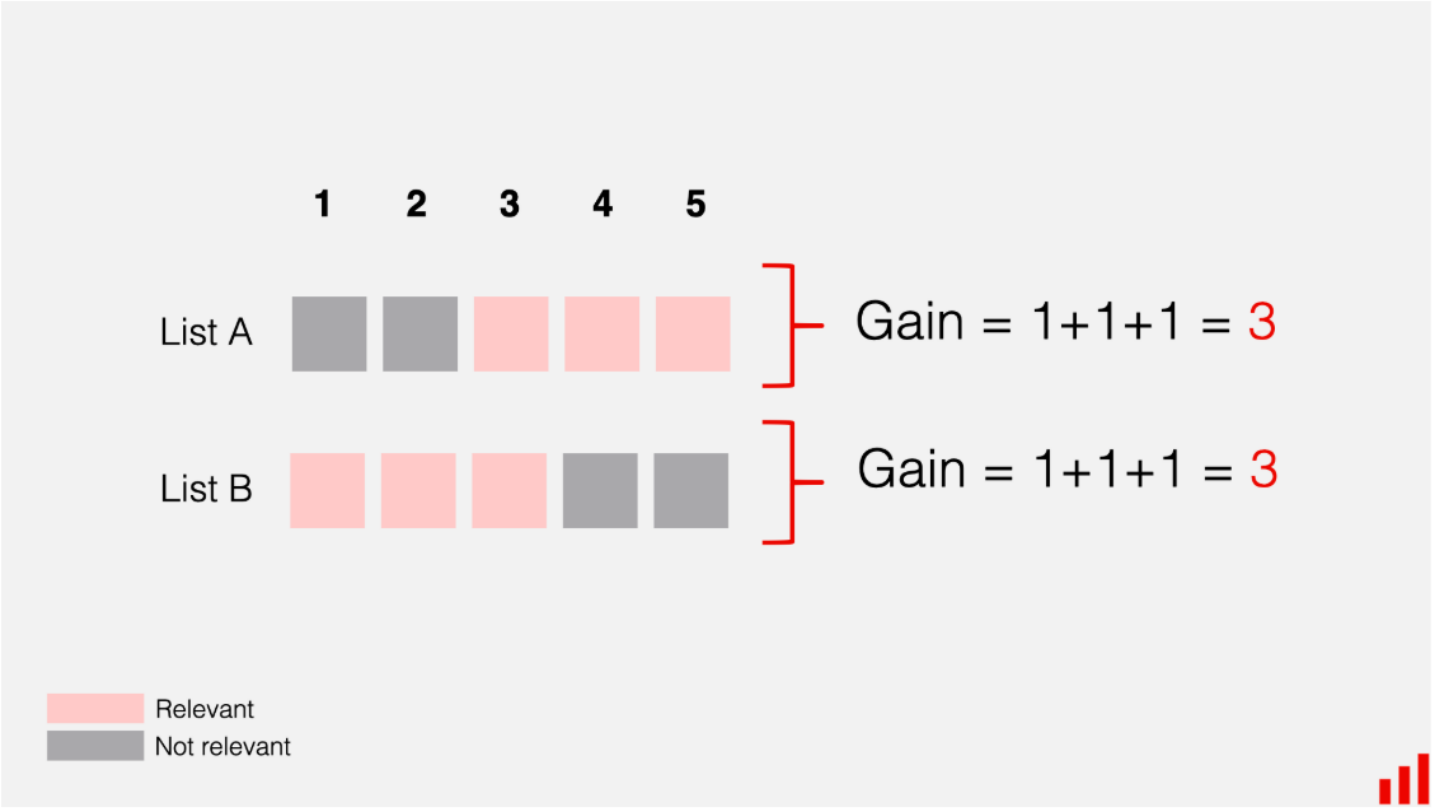

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

$$\text{DCG@K} = \sum_{k=1}^{K} \frac{rel_i}{\log_2(i+1)}$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

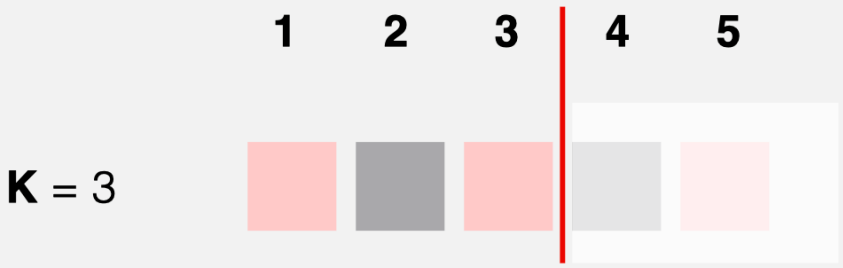

$$\text{DCG@3} = \frac{1}{\log_2(1+1)} + \frac{0}{\log_2(1+2)} + \frac{1}{\log_2(1+3)}$$

$$\text{DCG@3} = 1 + 0 + 0.5 = 1.5$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

$$k = 1: \frac{1}{\log_2(1+1)} = \frac{1}{\log_2(2)} = \frac{1}{1} = 1$$

$$k = 2: \frac{1}{\log_2(1+2)} = \frac{1}{\log_2(3)} \approx \frac{1}{1.585} \approx 0.63$$

$$k = 3: \frac{1}{\log_2(1+3)} = \frac{1}{\log_2(4)} = \frac{1}{2} = 0.5$$

$$k = 4: \frac{1}{\log_2(1+4)} \approx \frac{1}{\log_2(5)} \approx \frac{1}{2.322} \approx 0.43$$

$$k = 5: \frac{1}{\log_2(1+5)} \approx \frac{1}{\log_2(6)} \approx \frac{1}{2.585} \approx 0.39$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

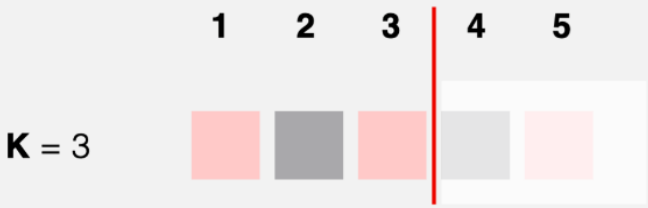

$$\text{DCG@3} = \frac{1}{\log_2(1+1)} + \frac{0}{\log_2(1+2)} + \frac{1}{\log_2(1+3)}$$

$$\text{DCG@3} = 1 + 0 + 0.5 = 1.5$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

Normalized Discounted Cumulative Gain (NDCG)

$$\text{NDCG@K} = \frac{DCG@K}{IDCG@K}$$

Источник: https://www.evidentlyai.com/ranking-metrics/ndcg-metric

RAG Triad

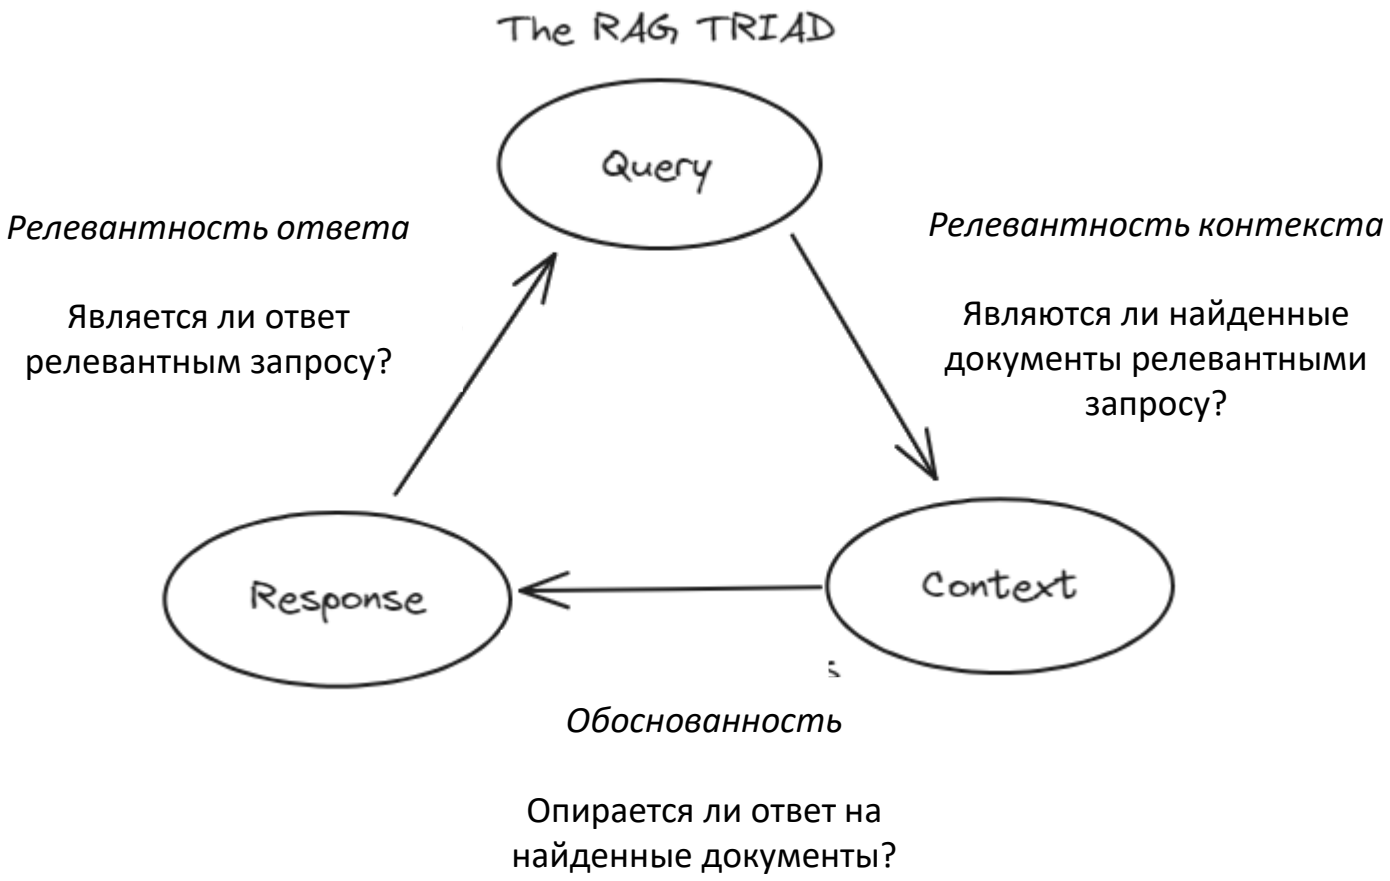

Источник: https://deepeval.com/guides/guides-rag-triad

Содержание

- RAG
- Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги
- Строим RAG пайплайн
- Приложение
  - Как я могу этому доверять?
  - **Matryoshka Embeddings Loss**
  - BM25

Функция потерь MRL составная с участием эмбеддингов

$$\mathcal{L}_{\text{MRL}} = \sum_{m \in \mathcal{M}} c_m \cdot \mathcal{L}_{\text{base}}(z_{1:m}, y)$$

Источник: https://huggingface.co/blog/matryoshka

Содержание

- RAG
- Плотные (Dense) vs. Разреженные (Sparse) эмбеддинги
- Строим RAG пайплайн
- Приложение
  - Как я могу этому доверять?
  - Matryoshka Embeddings Loss
  - **BM25**

Term Frequency-Inverse Document Frequency (TF-IDF)

$$\mathrm{tfidf}(t, d, D) = \mathrm{tf}(t, d) \cdot \mathrm{idf}(t, D)$$

Источник:https://jaketae.github.io/study/tf-idf/

Term Frequency-Inverse Document Frequency (TF-IDF)

$$\mathrm{tfidf}(t, d, D) = \mathrm{tf}(t, d) \cdot \mathrm{idf}(t, D)$$

$$\mathrm{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

Источник:https://jaketae.github.io/study/tf-idf/

Term Frequency-Inverse Document Frequency (TF-IDF)

$$\mathrm{tfidf}(t, d, D) = \mathrm{tf}(t, d) \cdot \mathrm{idf}(t, D)$$

$$\mathrm{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

$$\mathrm{idf}(t, D) = 1 + \log\left(\frac{1 + |D|}{1 + \sum_{t \in D} t}\right)$$

Источник:https://jaketae.github.io/study/tf-idf/

BM25 (best matching 25)

$$\text{score}(D,Q) = \sum_{i=1}^{n} \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$$\text{IDF}(q_i) = \ln\left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1\right)$$

Источник: https://en.wikipedia.org/wiki/Okapi_BM25

BM25 (best matching 25)

$$\text{score}(D,Q) = \sum_{i=1}^{n} \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$$\text{IDF}(q_i) = \ln\left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1\right)$$

Источник: https://en.wikipedia.org/wiki/Okapi_BM25

Спасибо за внимание!